

Guías

Estadística Computacional 2026-2C

Guía 5

Contraste de hipótesis y comparaciones múltiples

Tests para un parámetro

Ejercicio 1. Para verificar un generador de números pseudoaleatorios que debería producir valores con distribución $\mathcal{U}(0, 1)$, se generan $n = 100$ valores y se obtiene $\bar{x} = 0.558$.

- Plantee las hipótesis para decidir si la media del generador difiere de la teórica. Construya un estadístico cuya distribución bajo H_0 sea conocida y deduzca la zona de rechazo de nivel α .
- Decida con $\alpha = 0.05$ y calcule el p-valor.
- Construya los intervalos de confianza de nivel 0.95 y 0.99 para la media. ¿Qué relación encuentra con la decisión del test a los niveles 0.05 y 0.01?
- ¿Cambia la conclusión si la sospecha previa era que el generador produce valores sesgados hacia arriba?

Ejercicio 2. [MEFE 2025 (guía 9, 14)]

La eficiencia de un detector en condiciones normales es 50 %, y para verificar que no disminuya se contrasta periódicamente $H_0: p = 1/2$ vs $H_1: p < 1/2$ realizando n ensayos y midiendo la fracción de detecciones $\hat{p} = n_{\text{detecciones}}/n$. Suponga que para $n = 40$ ya es válida la aproximación normal $\hat{p} \approx \text{Normal}(p, p(1-p)/n)$.

- Determine la zona de rechazo para un nivel de significación $\alpha = 0.05$.
- Suponga que si la eficiencia cae por debajo de $1/3$ los datos se vuelven inutilizables. En esa situación se necesita una alta probabilidad de detectar una disminución de tal magnitud, si esta se produce (verdadero positivo). ¿Cuál es la potencia $1 - \beta$ del test si el valor real de la eficiencia es $p = 1/3$?
- Dada la importancia de no cruzar el límite de $1/3$, ¿qué tamaño muestral debería elegir para que la potencia del test en $p = 1/3$ sea 0.97?

Ejercicio 3. [ProbEstad 2022 (guía 9, 3)]

Se diseñó un nuevo sistema de riego con el objetivo de que el desvío estándar del tiempo de activación sea menor que 6 segundos. Se lo prueba 11 veces, obteniéndose los siguientes tiempos de activación, en segundos: 27, 41, 22, 27, 23, 35, 30, 24, 27, 28, 22. Suponiendo que el tiempo de activación es una variable aleatoria con distribución normal:

- Plantee las hipótesis y determine, con nivel de significación 0.05, para qué valores del estadístico rechazaría. ¿Puede afirmar que el sistema cumple con la especificación?
- Acote el p-valor.

Comparación de dos poblaciones

Ejercicio 4. Se quiere saber si una nueva implementación B de un algoritmo es más rápida que la implementación actual A . Para eso se corren ambas sobre las mismas 10 instancias de prueba, de tamaños muy distintos, y se registran los tiempos de ejecución en milisegundos:

Instancia	1	2	3	4	5	6	7	8	9	10
A	142	388	95	610	254	823	177	469	301	736
B	134	371	92	581	245	779	170	452	284	701

- Calcule las diferencias $D_i = A_i - B_i$ y, suponiendo que tienen distribución normal, decida con nivel de significación 0.05 si hay evidencia de que B es más rápida. Acote el p-valor.
- Un colega no advierte que las mediciones se hicieron sobre las mismas instancias y aplica un test t para dos muestras independientes (con varianzas iguales). Repita el análisis de esa forma. ¿Por qué las conclusiones son tan distintas? ¿Cuál de los dos análisis corresponde?

- c) Si cada implementación se hubiera corrido sobre un conjunto distinto de 10 instancias elegidas al azar, ¿qué test correspondería? ¿Qué esperaría de su capacidad para detectar la mejora?

Ejercicio 5. [Behavioral Insights (A/B test: efecto de correos más cortos)]

Un equipo envió a los directivos de 7000 escuelas una encuesta por correo electrónico, en un A/B test: la mitad, elegida al azar, recibió un correo de 127 palabras (versión A) y el 2.7 % respondió la encuesta; la otra mitad recibió un correo de 49 palabras (versión B) y el 4.8 % respondió.¹

- Plantee las hipótesis para decidir si el largo del correo afecta la tasa de respuesta. Decida con nivel de significación 0.05 y calcule el p-valor.
- Expresé la mejora en términos absolutos y relativos. ¿Es relevante en la práctica? ¿Qué información adicional necesitaría para decidir si conviene acortar todos los correos futuros?
- El equipo quiere planificar un nuevo A/B test para otro cambio de formato, del que espera un efecto menor: que la tasa pase de 2.7 % a 3.5 %. ¿Cuántos directivos por grupo necesita para detectar ese efecto con potencia 0.8 y el mismo nivel de significación? ¿Qué potencia tendría con 3500 por grupo, como en este experimento?

Interpretación y comparaciones múltiples

Ejercicio 6. [ProbEstad 2022 (guía 9, 7)]

En cada caso indique si la afirmación es verdadera o falsa y justifique:

- El nivel de significación de un test es igual a la probabilidad de que la hipótesis nula sea cierta.
- Un error de tipo II es más grave que un error de tipo I.
- Si el p-valor es 0.3, el test correspondiente rechazará H_0 al nivel de significación 0.01.
- Si un test rechaza H_0 al nivel de significación 0.06, entonces el p-valor es menor o igual a 0.06.
- Si un intervalo de confianza de nivel 0.99 para la media μ de una distribución normal calculado a partir de una muestra da como resultado (2.1, 3.3), entonces el test para las hipótesis $H_0: \mu = 3$ vs $H_1: \mu \neq 3$ basado en los mismos datos rechazará la hipótesis nula al nivel de significación 0.01.

Ejercicio 7. [Teórica (comparaciones múltiples)]

Se quiere evaluar un antifebril en N personas. A cada una se le mide la temperatura corporal antes y después de tomarlo y, con esos datos, se realiza para esa persona un test de nivel de significación α para las hipótesis

$$H_0: \text{su temperatura no disminuyó} \quad \text{vs} \quad H_1: \text{su temperatura disminuyó.}$$

Se realizan así N tests, uno por persona, que se suponen independientes. Suponga que el antifebril no tiene ningún efecto, es decir que H_0 es verdadera en las N personas. Aun así, alguno de los tests puede rechazarla por azar, lo que constituye un falso positivo.

- Modele con una distribución binomial el número de falsos positivos entre los N tests y calcule la probabilidad de obtener al menos uno.
- Evalúe esa probabilidad para $\alpha = 0.05$ y $N = 1, 10, 20, 100$. ¿Cómo se compara con la probabilidad de falso positivo de cada test individual?
- ¿Qué nivel de significación debería usar cada test para que la probabilidad de obtener al menos un falso positivo sea a lo sumo 0.05? Compárelo con la corrección de Bonferroni, que usa α/N en cada test. *Sugerencia:* $1 - (1 - x)^N \leq Nx$.

Ejercicio 8. Para cada una de las siguientes situaciones indique qué test usaría, cómo quedan planteadas H_0 y H_1 (en particular, si el test es unilateral o bilateral) y qué supuestos está asumiendo. Si el planteo tiene algún problema, señálelo. No hace falta hacer las cuentas.

- Se implementó una nueva función de hash y se quiere verificar que el tiempo medio de inserción esté por debajo de 50 ns. Se realizan 8 corridas independientes y no se dispone de información previa sobre la variabilidad.
- Un proveedor afirma que la tasa de fallas de su API es del 1 %. Un cliente sospecha que es mayor y registra 5000 llamadas.

¹Página 8 en <https://www.cfo.gov/assets/files/Behavioral%20Insights%20Guide%20for%20Improving%20Payment%20Integrity.pdf>

- c) Se mide el consumo pico de memoria de 25 aplicaciones antes y después de activar un recolector de basura nuevo, y se quiere saber si el consumo bajó.
- d) Dos versiones de una aplicación se prueban con dos grupos distintos de usuarios, 6 por grupo, y se comparan los tiempos de sesión. El test no rechaza y el equipo concluye que las dos versiones son equivalentes.
- e) Un laboratorio compró una balanza nueva. El fabricante afirma que el desvío estándar de sus mediciones no supera los 0.5 mg, pero se sospecha que es mayor. Se pesa 25 veces una misma masa patrón.
- f) En un A/B test se comparan dos versiones de la página de pago de una tienda, con 4000 visitantes por versión. Al ver que la versión B convirtió mejor, el equipo plantea $H_1: p_B > p_A$, "porque ya sabemos que B es mejor".
- g) En ese mismo A/B test el equipo midió además 15 métricas secundarias. Una de ellas dio un p-valor de 0.03 y la reportan como hallazgo del experimento.

Ejercicios con implementación computacional

Ejercicio 9. [Teórica (distribución de los p-valores)]


Genere 10000 datos provenientes de una distribución normal $\text{Normal}(\mu, \sigma^2)$. Repártalos en $M = 1000$ muestras de tamaño $n = 10$ y calcule, para cada muestra, el p-valor del test t para el contraste $H_0: \mu = 0$ vs $H_1: \mu > 0$.

- a) Tome $\mu = 0, \sigma^2 = 1$ como representación de un escenario de hipótesis nula verdadera. ¿Qué distribución aproximada tienen los p-valores?
- b) Compare con un escenario de hipótesis nula falsa, por ejemplo eligiendo $\mu = 1, \sigma^2 = 1$. ¿Qué distribución tienen los p-valores? ¿Cambia con el valor de μ ?
- c) Ahora suponga una situación realista donde lo único que tiene es una de dichas muestras con p-valor muy pequeño, es decir, que permite rechazar H_0 . ¿Puede determinar en qué escenario se encuentra? (Hipótesis nula verdadera, falso positivo vs. hipótesis nula falsa, verdadero positivo.) ¿Qué le dice esto sobre las malas interpretaciones del p-valor?

Ejercicio 10. [Teórica (significancia y tamaño de efecto; ver discusión²)]

Suponga que está midiendo el resultado de una intervención experimental donde se realiza un cambio en la interfaz de usuario para un grupo reducido de personas seleccionadas al azar y como resultado se mide la diferencia en el nivel de satisfacción.

Genere datos sintéticos para representar los escenarios mostrados en la figura. Suponga que la diferencia en el nivel de satisfacción tiene una distribución normal (ya sea porque las respuestas se obtienen por medio de un control deslizante o porque se usan valores discretos pero en un rango amplio, de 0 a 100). Las barras gruesas y delgadas indican los intervalos de confianza de nivel 0.90 y 0.95, respectivamente. La hipótesis nula es que el cambio en el nivel de satisfacción es cero. Un cambio "trivial" en el nivel de satisfacción sería uno que se encuentre, por ejemplo, entre -10 y 10 , y en ese caso no vale la pena implementar las modificaciones a gran escala (la flecha hacia la izquierda significa que el intervalo de confianza termina fuera de la figura).



- a) Para cada escenario de la figura, elija el tamaño muestral, la media y el desvío que reproduzcan aproximadamente el intervalo mostrado, y genere los datos correspondientes.
- b) Para cada escenario tome dos decisiones por separado: si rechaza H_0 con nivel de significación 0.05, y si el efecto es relevante, es decir si el intervalo queda fuera de la banda trivial $(-10, 10)$. Cruce ambas decisiones en una tabla. ¿Aparecen los cuatro casos posibles? ¿En cuáles implementaría el cambio a gran escala?
- c) Tome un escenario cuyo efecto sea trivial y que no haya resultado significativo. ¿Cuántas personas harían falta para que ese mismo efecto resultara significativo? ¿Qué conclusión saca sobre leer un p-valor sin mirar el tamaño del efecto?
- d) En el escenario de hipótesis nula falsa, la fracción de p-valores menores que α estima la potencia del test. Calcúlela para $\alpha = 0,05$ y varios valores de μ entre 0 y 2, y grafique la potencia en función de μ . ¿Qué valor toma cuando $\mu \rightarrow 0$? Repita con $n = 30$ y superponga ambas curvas. ¿Qué pasa si además cambia α ?

²<https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2022.962132/full>

Ejercicio 11. [Teórica (cuando las comparaciones múltiples penalizan demasiado)]

Considere una situación como la del ejercicio 7, pero esta vez suponga un escenario de hipótesis nula falsa, es decir, con efecto verdadero: el antifebril reduce la temperatura en 2° con respecto al valor previo. Se mide una sola vez a cada una de N personas y para cada una se contrasta, con $\alpha = 0.05$, si su temperatura disminuyó. Simule las mediciones (cambios respecto del valor previo) con distribución Normal($-2, 1$), en grados.

- a) Penalice las comparaciones individuales ajustando el α por Bonferroni. Para $N = 1$ no hay penalización y podría rechazar la hipótesis nula midiendo a una sola persona. ¿Qué ocurre con la proporción de rechazos individuales a medida que mide y compara más personas?
- b) Un escenario más realista es uno en el que el antifebril funciona solo en algunas personas. Suponga $N = 1000$ personas: en 100 de ellas el cambio es Normal($-2, 1$) y en las 900 restantes es Normal($0, 1$). Aplique los contrastes de tres maneras: sin corrección, con Bonferroni y con el procedimiento de Benjamini–Hochberg con $q = 0.05$. Este último consiste en ordenar los p-valores $p_{(1)} \leq \dots \leq p_{(N)}$, buscar el mayor k tal que $p_{(k)} \leq k q / N$ y rechazar las k hipótesis con menor p-valor. Repitiendo la simulación muchas veces, estime para cada método el número medio de verdaderos positivos, el de falsos positivos y la proporción de falsos positivos entre los rechazos. ¿Qué error controla cada método? ¿En qué situación preferiría cada uno?

PD: antes de apurarse a sacar conclusiones equivocadas, recuerde que en la práctica nunca se sabe si se está en el escenario de hipótesis nula verdadera o en el de hipótesis nula falsa.