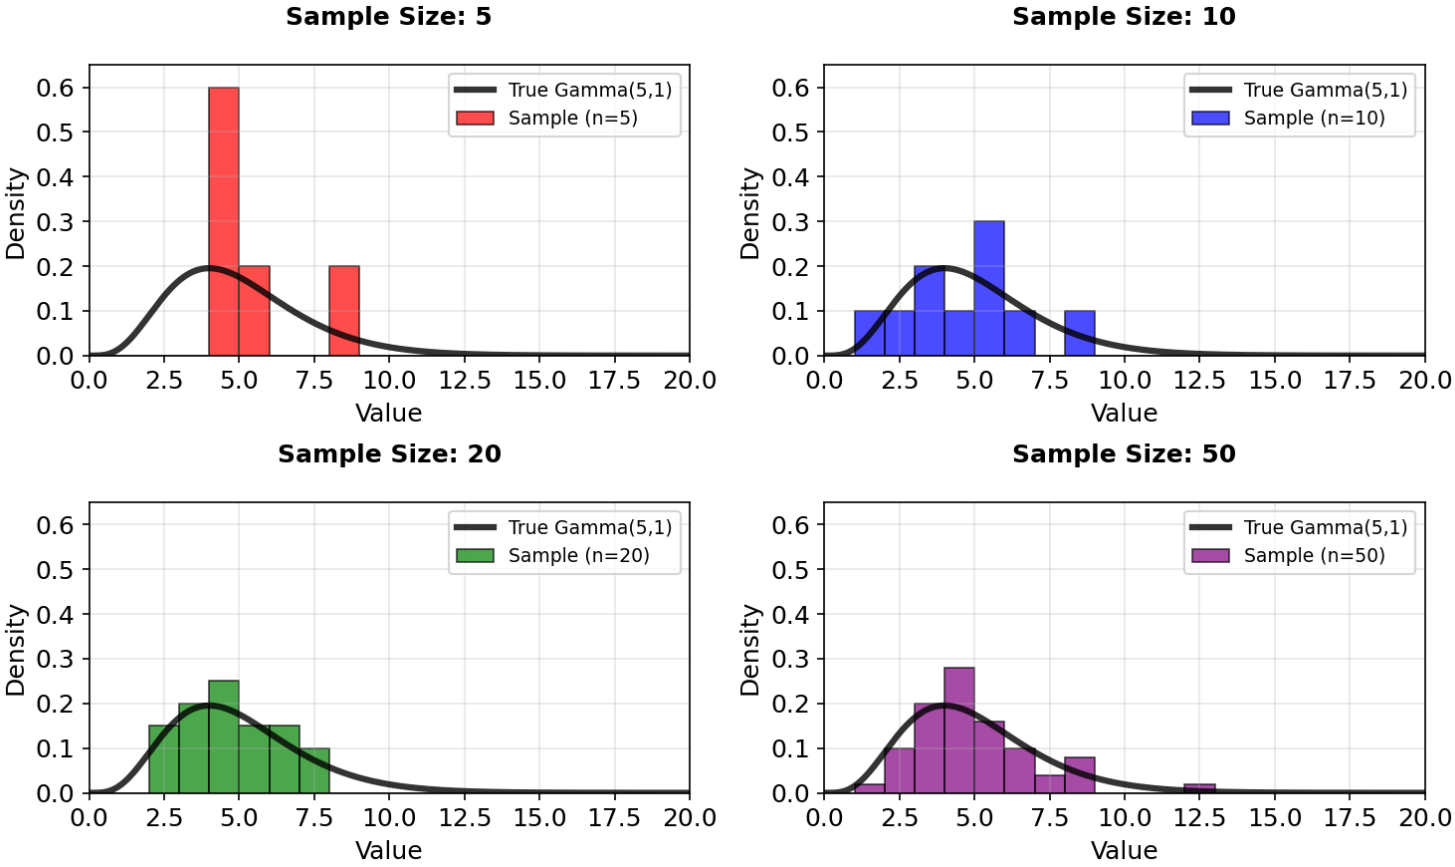
Boostrapping

Cómo calcular el intervalo de confianza para un estimador cuando no conozco la varianza (y mucho menos la distribución) del estimador

Bootstrapping

Idea: usar la muestra como expresión de la distribución subyacente.

La distribución de valores de una muestra es similar a la distribución de valores de la población, inclusive si la muestra es relativamente chica!



...pero cómo la usamos?

Bootstrapping = “remuestreo con reposición”

- Construimos nuevas muestras en base a los valores de la muestra original.
- Si la muestra original tiene N valores, de entre ellos tomamos al azar CON REPOSICION un conjunto de N valores.
- En las muestras “remuestreadas” seguramente habrá valores repetidos (si la muestra es una buena expresión de la distribución subyacente, la frecuencia de cada valor será representativa de la frecuencia real).

Ejemplo: calcular intervalo de confianza

1. Aproximación normal
2. Intervalo exacto
3. Bootstrapping

Encuesta a 5 personas por gusto de helado: ¿menta granizada sí o no?
Pregunta: ¿cuál es la fracción de personas en Argentina a las que les gusta la menta granizada?
Queremos dar estimación e intervalo de confianza.

Modelamos la decisión de cada persona como un ensayo de Bernoulli con probabilidad p:
Muestra de tamaño n=5 (cada ensayo de Bernoulli: Bin(1,p))

Primero con aproximación normal (ver clase 10, contraste para una proporción):

1. Aproximando por normal (clase 10):
Si np y n(1-p) son suficientemente grandes entonces

$$\text{Bin}(n, p) \xrightarrow[d]{} \text{Normal}(np, np(1-p))$$

Estandarizo: $$Z = \frac{p_{sample} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

busco los valores críticos etc.

Y sin aproximación?
Qué distribución esperamos que tenga p_{sample} sin hacer la aproximación normal? (intervalo exacto)

2. Intervalo exacto

Similar a la clase pasada: definimos la variable suma

$$Y = \sum_{i=1}^{5} X_i \sim \text{Bin}(5, p)$$

(suma de binomiales es binomial con n igual a la suma de los ns)

cuyo valor esperado es

$$E(Y) = np$$

que podemos estimar por la media muestral, pero ojo! Estamos hablando de la media muestral de la variable suma… de la cual tenemos una muestra de tamaño 1 (Y_1 = la suma de los 5 valores $X_{1,5}$):

$$E(Y) = \bar{Y} = \frac{1}{1} Y_1 = \sum_{i=1}^{5} X_i$$

y entonces

$$p_{sample} = \frac{1}{5} Y_{sample} \sim \text{Bin}(5, p)$$

(p_{sample} e Y_{sample} no son iguales, pero son idénticamente distribuidas)

$$p_{sample} = \frac{1}{5} Y \sim \text{Bin}(5, p)$$

(p_{sample} e Y_{sample} no son iguales, pero son idénticamente distribuidas)

Y_{sample}	$p_{sample}=Y_{sample}/5$	**P(y) = P(p_{sample}) ~ Bin(5,0.45)** (ejemplo)
0	0	0.05033
1	0.2	0.20589
2	0.4	0.33691
3	0.6	0.27565
4	0.8	0.11277
5	1	0.01845

Intervalo de confianza: tengo que buscar p tal que la p_{sample} observada tenga una probabilidad que coincida con el valor crítico apropiado

$$p_{sample} = \frac{1}{5} Y_{sample} \sim \text{Bin}(5, p)$$

Conociendo la distribución exacta podría encontrar $p_{critico}$ tal que el valor observado de p_{sample} sea más extremo que el valor crítico dado un nivel de confianza y con eso construir el intervalo de confianza.

Es decir, por ej para el borde izquierdo busco el mínimo p_{crit} tal que
$prob[Bin(5,p_{crit}) \geq Y_{sample}] > 0.025$

Borde derecho: busco máximo p_{crit} tal que
$prob[Bin(5,p_{crit}) \leq Y_{sample}] < 0.025$

Tiene solución fácil pero con cuidado (debido a que es una distribución discreta y el parámetro p es desconocido)

Intervalo de Clopper-Pearson:

Utilizando que

$$X \sim \text{Bin}(n, p) \;\Rightarrow\; P_p(X \geq x) = P(Y \leq p) \quad \text{donde} \quad Y \sim \text{Beta}(x, n-x+1)$$

Podemos escribir el intervalo exacto de confianza para p en términos de la función Beta:

$$\text{Beta}(\alpha/2; Y_{sample}, n - Y_{sample} + 1) \;<\; p \;<\; \text{Beta}(1-\alpha/2; Y_{sample}+1, n - Y_{sample})$$

(notar que pasamos del parámetro de una distribución a la variable de otra!)

Y si no quiero aproximar pero tampoco conozco la distribución exacta o es muy difícil de resolver?

3. Bootstrapping

Usamos bootstrapping para estimar variabilidad (por ejemplo, construir un intervalo de confianza)

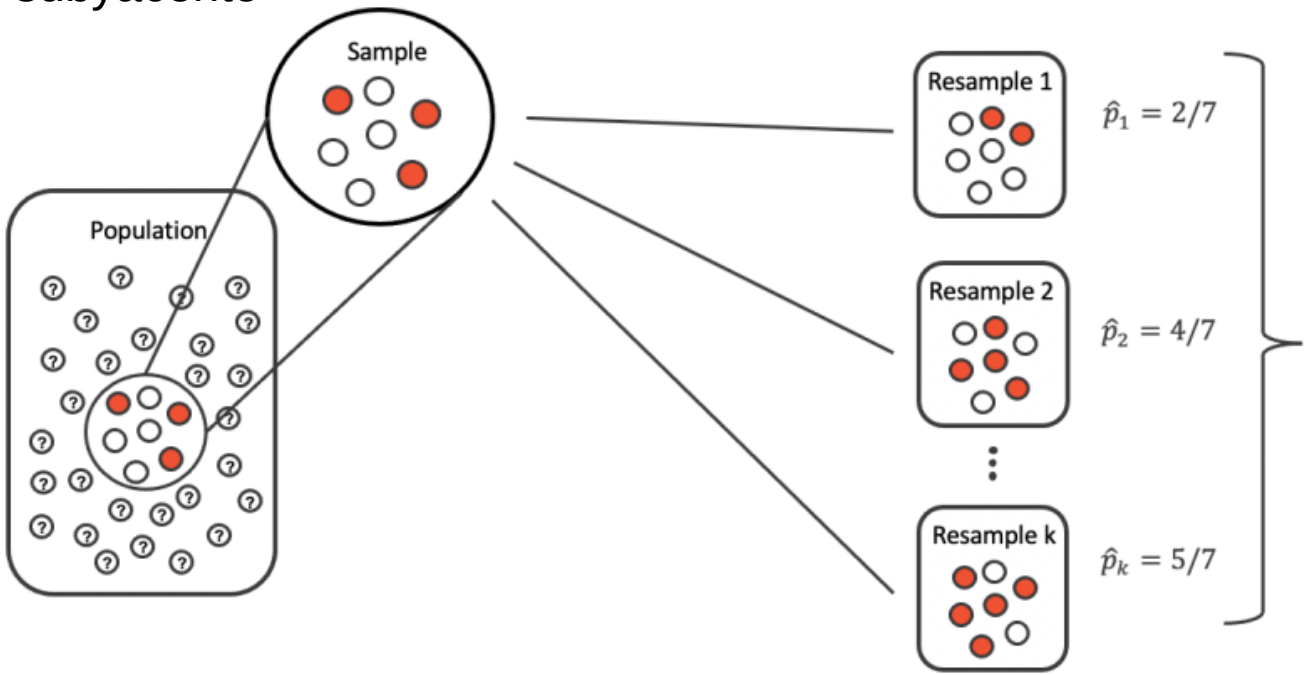
Muestra original: [1 0 1 1 0]
Proporción muestral: p_{sample} = sum[1 0 1 1 0]/5 = 0.6

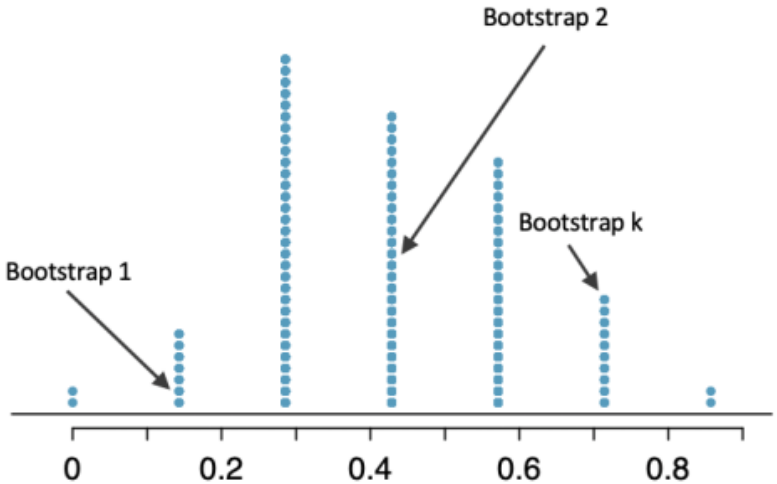
Muestra bootstrap #1: [1 0 1 1 0], p_bstrp=0.6
Muestra bootstrap #2: [1 1 1 0 1], p_bstrp=0.8
Muestra bootstrap #3: [1 0 1 1 1], p_bstrp=0.8
etc...

Población subyacente

Muestra

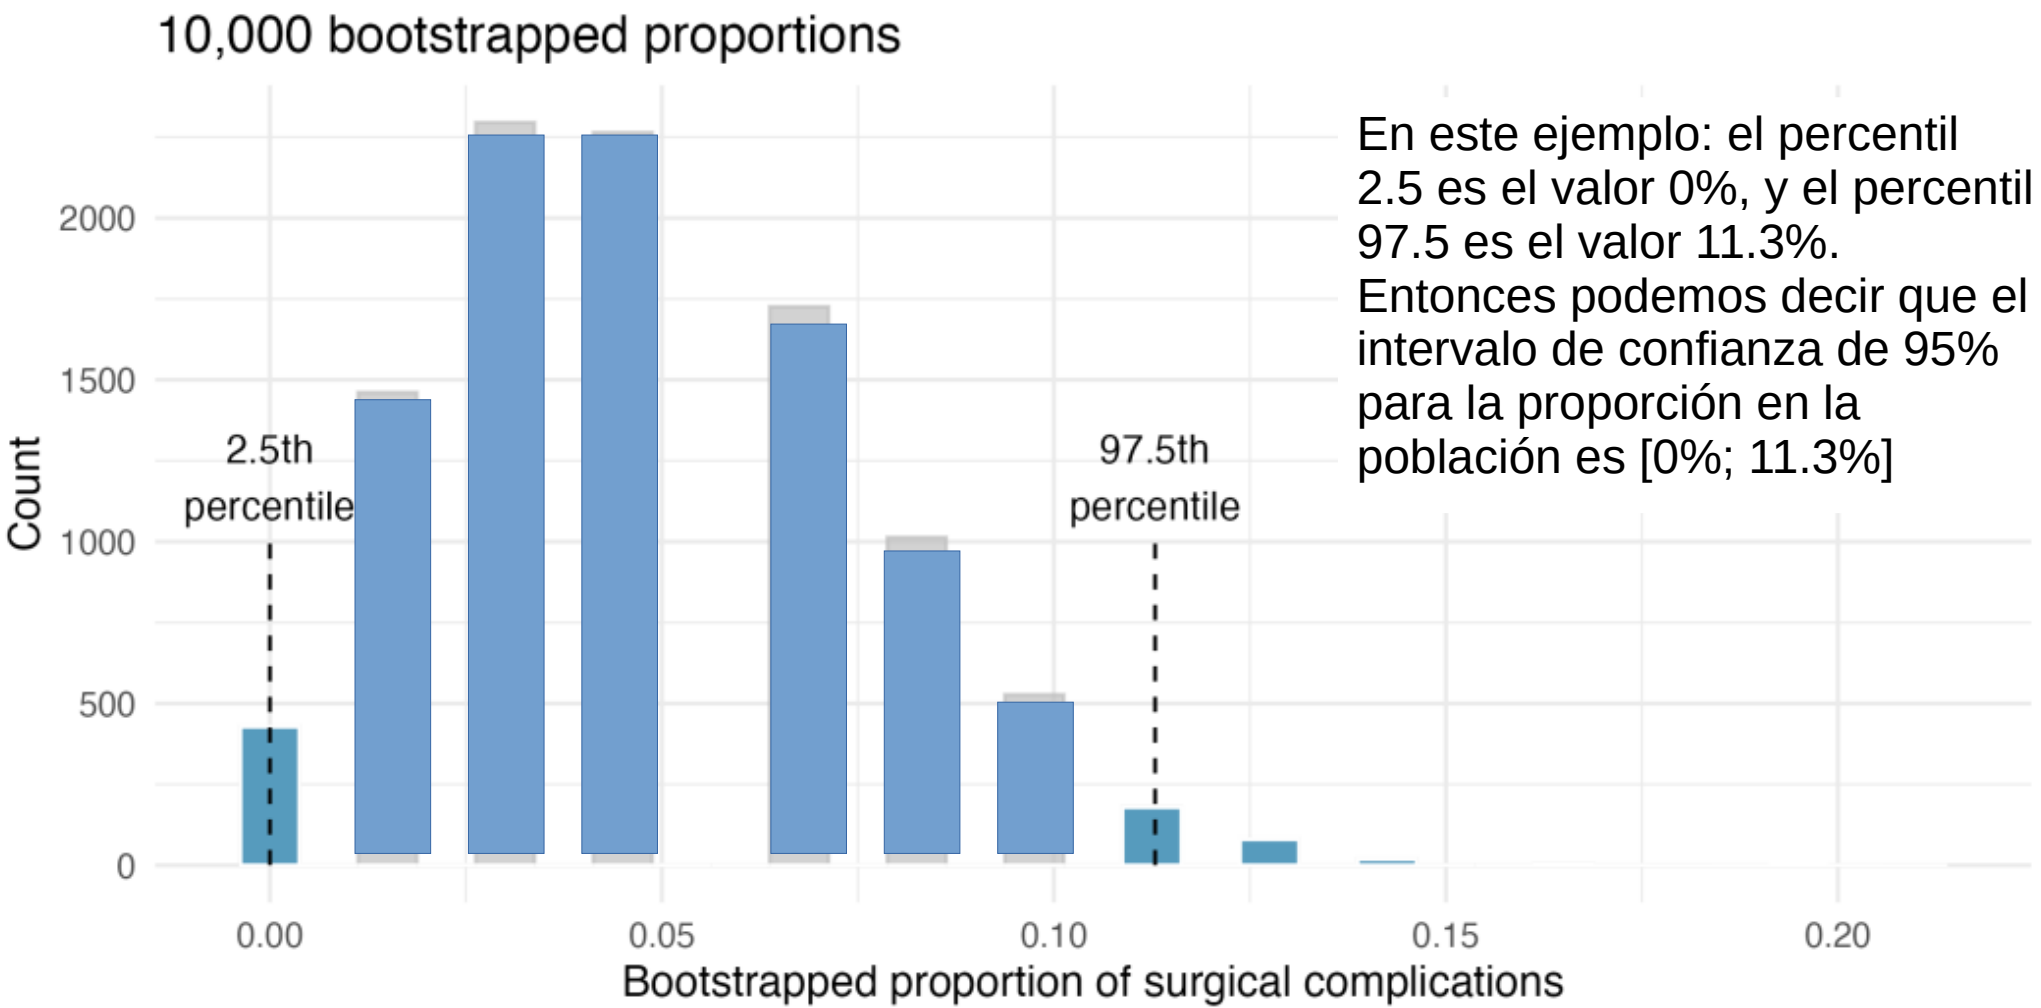
Remuestreo con reposición **de la muestra**





Luego podemos encontrar los percentiles 2.5 y 97.5 en esta distribución: son los bordes del intervalo de confianza de 95%

Cetinkaya-Rundel & Hardin 2024



En este ejemplo: el percentil 2.5 es el valor 0%, y el percentil 97.5 es el valor 11.3%. Entonces podemos decir que el intervalo de confianza de 95% para la proporción en la población es [0%; 11.3%]

Cetinkaya-Rundel & Hardin 2024

Receta para bootstrap:

1. Tenemos una muestra $X_1 ... X_n$
2. Definimos el estadístico θ que nos interese (media, proporción, etc)
3. Generamos la distribución bootstrap del estadístico:
    3.a. Remuestrear con reposición la muestra: $X_1^* ... X_n^*$
    3.b. Calcular el valor del estadístico θ^*
    3.c. Volvemos al paso 3.a y repetimos muchas veces
4. Dado un nivel de confianza α, encontramos los percentiles apropiados en la distribución bootstrap $\theta_{\alpha/2}$ y $\theta_{1-\alpha/2}$ (la distribución bootstrap podría no ser simétrica, por lo tanto el intervalo de confianza tampoco)
5. El intervalo de confianza buscado es $[\theta_{\alpha/2} ; \theta_{1-\alpha/2}]$

Referencias para bootstrapping:

Waserman 2003, capítulo 8
Cetinkaya-Rundel Hardin 2024, capítulo 12
Casella Berger 2024, sección 10.1.4
Efron Hastie 2016, capítulo 10 (Efron es el inventor de bootstrap!)

Ejemplo

Cuanto más grande la muestra, más parecida la distribución bootstrap a la distribución subyacente (y más chico el intervalo de confianza).

En amarillo: el intervalo de confianza de 95% calculado con bootstrap

