

Clase 1. Teoría de conjuntos, espacio muestral, eventos, probabilidad.

(referencias a Casella Berger 2024)

Definición 1.1.1

El conjunto S de todos los posibles resultados de un experimento se llama **espacio muestral**.

Definición 1.1.2

Un **evento** es una colección de posibles resultados de un experimento, o sea, un subconjunto de S (incluyendolo a S). Relaciones de inclusión e igualdad.

Teorema 1.1.4

Para cualesquiera tres eventos, A , B y C , definidos en un espacio muestral S ,

a) Commutativity

$$\begin{aligned}A \cup B &= B \cup A, \\A \cap B &= B \cap A;\end{aligned}$$

b) Associativity

$$\begin{aligned}A \cup (B \cap C) &= (A \cup B) \cap C, \\A \cap (B \cup C) &= (A \cap B) \cup C;\end{aligned}$$

c) Distributive Laws

$$\begin{aligned}A \cap (B \cup C) &= (A \cap B) \cup (A \cap C), \\A \cup (B \cap C) &= (A \cup B) \cap (A \cup C);\end{aligned}$$

d) DeMorgan's Laws

$$(A \cup B)^c = A^c \cap B^c, (A \cap B)^c = A^c \cup B^c.$$

Definición 1.1.5

Dos eventos A y B son **disjuntos (o mutuamente exclusivos)** si $A \cap B = \emptyset$. Estos eventos $A_1, A_2, \dots$ son **disjuntos de a pares (o mutuamente exclusivos)** si $A_i \cap A_j = \emptyset \forall i \neq j$.

Definición 1.1.6

Si $A_1, A_2, \dots$ son disjuntos de a pares, $A_i \neq \emptyset$ y $\bigcup_{i=1}^{\infty} A_i = S$, entonces la colección $A_1, A_2, \dots$ forman una **partición** de S .

Definición 1.2.1

Una colección de subconjuntos de S se lo llama **sigma-algebra (campo de Borel o álgebra de Borel)**, denotada $\mathcal{B}$, si satisface las siguientes propiedades:

- a) $\emptyset \in \mathcal{B}$ (el conjunto vacío es un elemento de $\mathcal{B}$).
- b) Si $A \in \mathcal{B}$, entonces $A^c \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para complemento).
- c) Si $A_1, A_2, \dots \in \mathcal{B}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para uniones numerables).

Definición 1.2.4

Dado un espacio muestral S y un campo de Borel asociado $\mathcal{B}$, una **función de probabilidad** es una función P con dominio $\mathcal{B}$ que satisface los **axiomas de probabilidad**:

1. $P(A) \geq 0 \forall A \in \mathcal{B}$.
2. $P(S) = 1$.

3. Si $A_1, A_2, \dots \in \mathcal{B}$ son mutuamente exclusivos, entonces $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$.

Teorema 1.2.6

Sea $S = \{s_1, \dots, s_n\}$ un conjunto finito. Sea $\mathcal{B}$ un campo de Borel de subconjuntos de S . Sean $p_1, \dots, p_n$ numeros no-negativos que sumen uno. Para cualquier $A \in \mathcal{B}$, se define $P(A)$ como

$$P(A) = \sum_{\{i: s_i \in A\}} p_i$$

Teorema 1.2.8

Si P es una función de probabilidad y A es algun conjunto en $\mathcal{B}$, entonces

- a) $P(\emptyset) = 0$.
- b) $P(A) \leq 1$.
- c) $P(A^c) = 1 - P(A)$.

Teorema 1.2.9

Si P es una función de probabilidad y A y B son conjuntos en $\mathcal{B}$, entonces

- a) $P(B \cap A^c) = P(B) - P(A \cap B)$.
- b) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- c) Si $A \subset B$ entonces $P(A) \leq P(B)$.

Clase 2. Bonferroni, conteo, probabilidad condicional e independencia.

(referencias a Casella Berger 2024)

Teorema 1.2.11

Si P es una función de probabilidad, entonces

- a) $P(A) = \sum_{i=1}^{\infty} P(A \cap C_i)$ para cualquier partición $C_1, C_2, \dots$ **probabilidad total**
- b) $P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$ para cualesquiera conjuntos $A_1, A_2, \dots$ **probabilidad de Boole / desigualdad de Boole**

Ecuación 1.2.10

La **desigualdad de Bonferroni**:

$$P(A \cap B) \geq P(A) + P(B) - 1$$

La **generalización de Bonferroni** es:

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n-1)$$

Teorema 1.2.14

Si un trabajo consiste en k tareas separadas, de las cuales la i -ésima puede resolverse de n_i maneras, $i = 1, \dots, k$, entonces el trabajo completo puede hacerse en $n_1 \times n_2 \times \dots \times n_k$ formas.

Definición 1.2.17

Para numeros no negativos n y r , $n \geq r$, definiumos el **número combinatorio** $\binom{n}{r}$, leído como elegir r de n , como

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}$$

Tabla 1.2.1

Resumen de los cuatro casos básicos de conteo.

	Sin reemplazo	Con reemplazo
Con orden	$\frac{n!}{(n-r)!}$	n^r
Sin orden	$\binom{n}{r}$	$\binom{n+r-1}{r}$

Definición 1.3.2

Si A y B son eventos en S , y $P(B) > 0$, entonces la **probabilidad condicional** de un A dado B , escrito como $P(A|B)$, es

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Ecuación 1.3.3

$$P(A \cap B) = P(A|B)P(B)$$

Ecuación 1.3.4

$$P(A \cap B) = P(B|A)P(A)$$

Ecuación 1.3.5

Regla de Bayes para dos eventos.

$$P(A|B) = P(B|A) \frac{P(A)}{P(B)}$$

Teorema 1.3.5

Regla de Bayes generalizada. Sea $A_1, A_2, \dots$ una partición del espacio muestral, y sea B cualquier conjunto, para cada $i = 1, 2, \dots$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{\infty} P(B|A_j)P(A_j)}$$

Definición 1.3.7

Dos eventos, A y B , son **estadísticamente independientes** si

$$P(A \cap B) = P(A)P(B)$$

Esto implica que:

$$P(A|B) = P(A)$$

Teorema 1.3.9

Si A y B son eventos independientes, entonces los siguientes pares también:

a) A y B^c

b) A^c y B

c) A^c y B^c

Definición 1.3.12

Una colección de eventos $A_1, \dots, A_n$ son **mutuamente independientes** si para cualquier subcolección $A_{i_1}, \dots, A_{i_k}$, se cumple que la probabilidad de la intersección es igual a la factorización de las probabilidades:

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$$

Clase 3. Variables aleatorias.

(referencias a Casella Berger 2024)

Variables aleatorias

Definición 1.4.1

Una **variable aleatoria** es una función de un espacio muestral S a los números reales.

Ecuación 1.4.1

P_X es una función de probabilidad inducida en $\mathcal{X} = \{x_1, \dots, x_m\}$. Definida en los términos de la función original P .

$$P_X(X = x_i) = P(\{s_j \in S : X(s_j) = x_i\})$$

Definición 1.5.1

La **función de distribución acumulada, o fda**, de una variable aleatoria X , donotada como $F_{X(x)}$, es definida por

$$F_X(x) = P_X(X \leq x), \forall x$$

Teorema 1.5.3

La función $F(x)$ es una fda si y solo si las siguientes condiciones se cumplen:

- a) $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow \infty} F(x) = 1$.
- b) $F(x)$ es una función no decreciente de x .
- c) $F(x)$ es continua a la derecha. O sea, para todo número x_0 , $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$.

Definición 1.5.7

Una variable aleatoria X es **continua** si $F_X(x)$ es una función continua de x .

Una variable aleatoria X es **discreta** si $F_X(x)$ es una función escalonada (o en escalera / step function).

Definición 1.5.8

Las variables aleatorias X e Y son **idénticamente distribuidas** si, por cada conjunto $A \in \mathcal{B}$, $P(X \in A) = P(Y \in A)$

Teorema 1.5.10

Las siguientes declaraciones son equivalentes:

- a) Las variables aleatorias X e Y son idénticamente distribuidas.
- b) $F_X(x) = F_Y(x), \forall x$.

Definición 1.6.1

La **función de probabilidad puntual (fpp)** de una variable aleatoria discreta X es dada por

$$f_X(x) = P(X = x)$$

Ecuación 1.6.1

Relación entre fpp y fda (variable discreta)

$$F_X(x) = \sum_{i=1}^x f_X(i)$$

Ecuación 1.6.2

Relación entre fdp y fda (variable continua).

$$\frac{d}{dx} F_X(x) = f_X(x)$$

Definición 1.6.3

La **función de densidad de probabilidad (fdp)**, $f_X(x)$, de una variable aleatoria continua X es la función que satisface

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad \forall x$$

Teorema 1.6.5

Una función $f_X(x)$ es fdp o fpp, de una variable aleatoria X si y solo si

- a) $f_X(x) \geq 0 \quad \forall x$.
- b) $\sum_x f_X(x) = 1$ (fpp) o $\int_{-\infty}^{\infty} f_X(x) dx = 1$ (fdp)

Valor esperado**Definición 2.2.1**

El **valor esperado (esperanza)** de una variable aleatoria $g(X)$, denotado por $E[g(X)]$, es

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx & X \text{ continua} \\ \sum_{x \in \mathcal{X}} g(x) f_X(x) = \sum_{x \in \mathcal{X}} g(x) P(X = x) & X \text{ discreta} \end{cases}$$

dado que la integral o suma exista. Si $E[g(X)] = \infty$, decimos que $E[g(X)]$ no existe.

Es el resultado promedio teórico que esperarías obtener si repetirías un experimento aleatorio un número infinito de veces. Representa el punto de equilibrio de la distribución de probabilidad.

Valor esperado de la variable: **valor medio**.

$$g(X) = X$$

Es el promedio aritmético calculado a partir de un conjunto de datos observados (una muestra o una población real). Por la Ley de los Grandes Números, a medida que aumentas el tamaño de la muestra, el valor medio se acerca a la esperanza.

Valor esperado de las distancias cuadráticas con respecto al valor medio: **varianza**.

$$\text{Var}(X) = E[(X - E(X))^2]$$

Es una medida de la dispersión o variabilidad de los datos respecto a su media o esperanza. A menudo se calcula su raíz cuadrada, conocida como **desviación estándar**, para devolver la medida a la unidad original.

Teorema 2.2.5

Sea X una variable aleatoria y sean a, b y c constantes. Entonces para funciones cualesquiera $g_1(x)$ y $g_2(x)$ donde sus esperanzas existen, se cumple que

- a) $E[ag_1(X) + bg_2(X) + c] = aE[g_1(X)] + bE[g_2(X)] + c$
- b) Si $g_1(x) \geq 0$ para todo x , entonces $E[g_1(X)] \geq 0$.
- c) Si $g_1(x) \geq g_2(x)$ para todo x , entonces $E[g_1(X)] \geq E[g_2(X)]$.
- d) Si $a \leq g_1(x) \leq b$ para todo x , entonces $a \leq E[g_1(X)] \leq b$.

Teorema 2.3.4

Si X es una variable aleatoria con varianza finita, entonces para cualesquiera constantes a y b ,

$$\text{Var}(aX + b) = a^2 \text{Var}X$$

Clase 4. Distribuciones discretas y continuas.

(referencias a Casella Berger 2024 y al resumen de distribuciones de la práctica)

Familias comunes de distribuciones discretas

Ecuación 3.2.1

Distribución uniforme discreta.

$X \sim U(1, N)$ si $P(X = x | N) = \frac{1}{N}$ ($x = 1, 2, \dots, N$)

$$E[X] = \sum_{x=1}^N xP(X = x | N) = \frac{N+1}{2}$$

$$\text{Var}(X) = \frac{(N+1)(N-1)}{12}$$

Ecuación 3.2.3

Distribución de Bernoulli (ensayo de Bernoulli).

$X \sim \text{Bernoulli}(p)$ si $x = \begin{cases} 1 & \text{con probabilidad } p \\ 0 & \text{con probabilidad } (1-p) \end{cases}$ ($0 \leq p \leq 1$)

$$E[X] = p$$

$$\text{Var}(X) = p(1-p)$$

Teorema 3.2.2

Distribución binomial. Supongamos n ensayos de Bernoulli independientes e $Y =$ número de éxitos en n ensayos. Modela el número de éxitos en n ensayos independientes, cada uno con probabilidad de éxito p .

$Y \sim \text{Bin}(n, p)$ si $P(Y = y | n, p) = \binom{n}{y} p^y (1-p)^{n-y}$

$$E[Y] = np$$

$$\text{Var}(Y) = np(1-p)$$

Ecuación 3.2.5

Distribución de Poisson. Modela el número de eventos (raros e independientes) que ocurren en un intervalo fijo de tiempo o espacio.

$X \sim \text{Poisson}(\lambda)$ si $P(X = x | \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$, ($x = 0, 1, \dots$)

$$E[X] = \lambda$$

$$\text{Var}(X) = \lambda$$

Ecuaciones 3.2.6 3.2.7

Relaciones de recursión (binomial y Poisson)

$X \sim \text{Poisson}(\lambda) \Rightarrow P(X = x) = \frac{\lambda}{x} P(X = x-1)$, ($x = 1, 2, \dots$)

$Y \sim \text{Bin}(n, p) \Rightarrow P(Y = y) = \frac{(n-y+1)p}{y(1-p)} P(Y = y-1)$

Ecuación 3.2.11

Distribución geométrica.

$X =$ número de ensayos de Bernoulli hasta el primer éxito.

$X \sim \text{Geom}(p)$ si $P(X = x | p) = (1-p)^{x-1}$, ($x = 1, 2, \dots$)

$$E[X] = \frac{1}{p}$$

$$\text{Var}(X) = \frac{1-p}{p^2}$$

Propiedad “sin memoria”.

$$P(X > s | X > t) = P(X > s-t), \quad (s > t)$$

La probabilidad de obtener una secuencia de fracasos no depende de la posición en la tira, solo del largo de la secuencia.

Ecuación 3.2.9

Distribución binomial negativa. Modela el número de ensayos necesarios hasta obtener el r -ésimo éxito.

$$p_X(k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad (k = r, r+1, \dots), \quad (0 < p < 1)$$

$$E[X] = \frac{r}{p}$$

$$\text{Var}(Y) = \frac{r(1-p)}{p^2}$$

Ecuación 3.2.2

Distribución hipergeométrica. Modela el número de elementos “buenos” al extraer una muestra de tamaño m sin reposición de una población finita de tamaño N con r buenos.

$$p_X(k) = \frac{\binom{r}{k} \binom{N-r}{m-k}}{\binom{N}{m}}, \quad \max(r+m-N, 0) \leq k \leq \min(r, m)$$

$$E[X] = m \frac{r}{N}$$

$$\text{Var}(X) = m \frac{r}{N} \frac{N-r}{N} \frac{N-m}{N-1}$$

Familias comunes de distribuciones continuas

Ecuación 3.3.1

Distribución uniforme continua.

$$X \sim U[a, b]$$

$$f(x) = \frac{1}{(b-a)} \mathbb{1}_{[a,b]}(x)$$

$$E[X] = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

$$U[0, 1] = \beta(1, 1)$$

Ecuación 3.3.13

Distribución normal.

$$X \sim N(\mu, \sigma^2)$$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}, \quad \sigma > 0$$

$$E[X] = \mu$$

$$\text{Var}(X) = \sigma^2$$

Normal estándar: $N(0, 1)$

Ecuación 3.3.6

Distribución gamma.

$$X \sim \Gamma(\alpha, \lambda)$$

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda, \alpha > 0$$

$$E[X] = \frac{\alpha}{\lambda}$$

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}$$

$$\Gamma(1) = 1, \quad \Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1), \quad \Gamma(n) = (n-1)!, \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Ecuación 3.3.16 3.3.17

Distribución Beta.

$$X \sim \beta(a, b)$$

$$f_X(x) =$$

$$\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} \mathbb{1}_{(0,1)}(x), \quad a, b > 0$$

$$E[X] = \frac{a}{a+b}$$

$$\text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

Relación con la función gamma

$$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

Ecuación 3.3.11

Distribución exponencial.

$$X \sim \text{Exp}(\lambda)$$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda > 0$$

$$E[X] = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Parametrización alternativa.

$$\text{Exp}(\lambda) = \Gamma(1, \lambda)$$

Ecuación 3.3.19

Distribución de Cauchy.

$$X \sim C(0, \lambda)$$

$$f_X(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + x^2}, \quad \lambda > 0$$

No tiene esperanza definida. $C(0, 1) = t_1$

Otras

T de Student

$$X \sim t_n$$

$$f_X(x) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{\pi n}} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}$$

$$E(X) = 0$$

$$\text{Var}(X) = 2n$$

Chi cuadrado

$$X \sim \chi_n^2$$

$$\chi_n^2 = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right), n \in \mathbb{N}$$

$$E[X] = n$$

$$\text{Var}(X) = 2n$$

F de Snedecor

$$X \sim F_{n,m}$$

$$f_X(x) =$$

$$\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \left(\frac{n}{m}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} \left(1 + \frac{n}{m}x\right)^{-\frac{m+n}{2}} \mathbb{1}((0, \infty))(x)$$

Propiedades más usadas

- $X \sim \text{Bi}(n, p), Y \sim \text{Bi}(m, p)$ independientes
 $\Rightarrow X + Y \sim \text{Bi}(n + m, p)$.
- $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ independientes $\Rightarrow$
 $X + Y \sim P(\lambda_1 + \lambda_2)$.
- $\text{Bi}(n, p) \approx P(\lambda)$ con $\lambda = np$ cuando $p \ll 1$.
- $H(N, r, m) \approx \text{Bi}(m, \frac{r}{N})$ cuando N es grande
y $m \ll N$.
- $X \sim N(\mu, \sigma^2) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0, 1)$
(estandarización).
- $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
independientes $\Rightarrow aX + bY + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$.
- $X \sim \Gamma(\alpha, \lambda) \Rightarrow cX \sim \Gamma(\alpha, \frac{\lambda}{c})$.
- $Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi_1^2$.

Clase 5. Transformación de variables aleatorias.

(referencias a Casella Berger 2024)

Transformaciones de variables aleatorias

Ecuación 2.1.1

Función de una variable aleatoria. Si X es una variable aleatoria con fda $F_X(x)$, entonces cualquier función de X , digamos $g(X)$ también es una variable aleatoria.

$$P(Y \in A) = P(g(X) \in A)$$

$g(X)$ define un mapa desde el espacio muestral original (X) al transformado (Y).

$\mathcal{X}$ soporte de X

$\mathcal{Y}$ soporte de Y

(**soporte** es el conjunto de puntos x donde la función de probabilidad puntual (fpp) es estrictamente mayor que cero.)

$$g(x) : \mathcal{X} \rightarrow \mathcal{Y}$$

Lo definimos por la inversa:

$$g^{-1}(\{y\}) = \{x \in \mathcal{X} : g(x) = y\}$$

$$Y = g(X)$$

Podemos escribir entonces para cualquier conjunto $A \subset \mathcal{Y}$:

$$\begin{aligned} P(Y \in A) &= P(g(X) \in A) \\ &= P(\{x \in \mathcal{X} : g(x) \in A\}) \\ &= P(X \in g^{-1}(A)). \end{aligned}$$

Ecuación 2.1.4, 2.1.8, 2.1.9

Función de distribución acumulada de una variable transformada. X e Y variables aleatorias continuas, calculemos la fda de $Y = g(X)$:

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\ &= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x) dx. \end{aligned}$$

Región de integración de la probabilidad de una transformación.

Si g es creciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \leq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \leq g^{-1}(y)\}. \end{aligned}$$

Si g es decreciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \geq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \geq g^{-1}(y)\}. \end{aligned}$$

Con esto podemos escribir que, si es creciente $g(x)$:

$$F_Y(y) = \int_{\{x \in \mathcal{X} : x \leq g^{-1}(y)\}} f_X(x) dx = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx = F_X(g^{-1}(y)).$$

Si $g(x)$ es decreciente, tenemos

$$F_Y(y) = \int_{g^{-1}(y)}^{\infty} f_X(x) dx = 1 - F_X(g^{-1}(y)).$$

Teorema 2.1.3

Función de distribución acumulada de una transformación.

Sea X una variable aleatoria con fda $F_X(x)$, sea $Y = g(X)$, y sean $\mathcal{X}$ e $\mathcal{Y}$ definidos como $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x) \text{ para algún } x \in \mathcal{X}\}$.

- Si g es una función creciente en $\mathcal{X}$, $F_Y(y) = F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.
- Si g es una función decreciente en $\mathcal{X}$ y X es una variable aleatoria continua, $F_Y(y) = 1 - F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.

Teorema 2.1.5

Función de densidad de probabilidad de una transformación.

Sea X una variable aleatoria con fdp $f_X(x)$ y sea $Y = g(X)$, donde g es una función monótona (función que no cambia de sentido de variación (siempre crece o siempre decrece) a lo largo de todo el conjunto $\mathcal{X}$ donde la variable aleatoria X toma valores). Sean $\mathcal{X}$ y $\mathcal{Y}$ definidos como en el teorema

2.1.3. Supongamos que $f_X(x)$ es continua en $\mathcal{X}$ y que $g^{-1}(y)$ tiene derivada continua en $\mathcal{Y}$. Entonces la fdp de Y está dada por:

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| & y \in \mathcal{Y}, \\ 0 & \text{si no} \end{cases}$$

Teorema 2.1.10

Transformación integral de probabilidad.

Tenga X una fda continua $F_X(x)$ y definimos la variable aleatoria Y como $Y = F_X(X)$. Entonces Y esta uniformemente distribuida en $(0, 1)$, o sea, $P(Y \leq y) = y$, $0 < y < 1$.

Demo:

Para $Y = F_X(X)$ tenemos que, para $0 < y < 1$,

$$\begin{aligned} P(Y \leq y) &= P(F_X(X) \leq y) \\ &= P(F_X^{-1}[F_X(X)] \leq F_X^{-1}(y)) \quad (F_X^{-1} \text{ es creciente}) \\ &= P(X \leq F_X^{-1}(y)) \quad (\text{propiedad de } F_X^{-1}) \\ &= F_X(F_X^{-1}(y)) \quad (\text{definición de } F_X) \\ &= y. \quad (\text{continuidad de } F_X) \end{aligned}$$

Clase 6. Distribuciones conjuntas.

(referencias a Casella Berger 2024)

Teorema 3.6.1

Desigualdad de Markov / Chebychev.

Sea X una variable aleatoria y $g(X) \geq 0$. Entonces, para cualquier $r > 0$:

$$P(g(X) \geq r) \leq \frac{E[g(X)]}{r}$$

Demo:

$$\begin{aligned} E[g(X)] &= \int_{-\infty}^{\infty} g(x) f_X(x) dx \\ &\geq \int_{\{x: g(x) \geq r\}} g(x) f_X(x) dx \quad (g \text{ es no negativa}) \\ &\geq r \int_{\{x: g(x) \geq r\}} f_X(x) dx \\ &= r P(g(X) \geq r). \quad (\text{definición}) \end{aligned}$$

Reacomodando ahora da la inecuación deseada.

Distribuciones conjuntas

Definición 4.1.1

Un **vector aleatorio n-dimensional** es una función de un espacio muestral S en $\mathbb{R}^2$, un espacio Euclidiano n-dimensional.

Definición 4.1.3

Sea (X, Y) un vector aleatorio bivariado discreto. Entonces la función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ definida

por $f(x, y) = P(X = x, Y = y)$ se la llama la **función de probabilidad puntual conjunta / fpp conjunta** de (X, Y) . Si es necesario reafirmar que f es la fpp conjunta del vector (X, Y) en vez de ser de otro vector, la notación que se usa es $f_{X,Y}(x, y)$

La fpp conjunta puede ser usada para computar la probabilidad de cualquier evento definido en términos de (X, Y) . Sea A un subconjunto de $\mathbb{R}^2$. Entonces,

$$P((X, Y) \in A) = \sum_{(x,y) \in A} f(x, y).$$

El valor esperado es,

$$E[g(X, Y)] = \sum_{(x,y) \in \mathbb{R}^2} g(x, y) f(x, y).$$

Propiedades:

Sean $g_1(x, y)$ y $g_2(x, y)$ funciones y a, b y c constantes:

- $E[ag_1(x, y) + bg_2(x, y) + c] = aE[g_1(x, y)] + bE[g_2(x, y)] + c$
- $f(x, y) \geq 0$ para todo x, y
- $\sum_{(x,y) \in \mathbb{R}^2} f(x, y) = 1$

Teorema 4.1.6

Sea (X, Y) un vector aleatorio bivariado discreto con fpp conjunta $f_{X,Y}(x, y)$. Entonces, la **función de probabilidad puntual marginal / fpp marginal** de X e Y , $f_X(x) = P(X = x)$ y $f_Y(y) = P(Y = y)$, son dadas por,

$$f_X(x) = \sum_{y \in \mathbb{R}} f_{X,Y}(x, y) \quad \text{y} \quad f_Y(y) = \sum_{x \in \mathbb{R}} f_{X,Y}(x, y).$$

Nota: Marginal es por como se ve en una tabla los resultados de $f_X(x)$ y $f_Y(y)$, o sea, en los márgenes de una tabla.

Definición 4.1.10

Una función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ se la llama **función de densidad de probabilidad conjunta / fdp conjunta** para un vector bidimensional continuo (X, Y) si, por cada $A \subset \mathbb{R}^2$,

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy.$$

Ecuación 4.1.1

Valor esperado de una función de dos variables continuas.

Sea $g(X, Y) \in \mathbb{R}$

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy.$$

Ecuación 4.1.2

Funciones de densidad de probabilidad marginales / fdp marginal para variables continuas.

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad -\infty < x < \infty,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx, \quad -\infty < y < \infty.$$

Ecuación 4.1.3

Función de distribución acumulada conjunta / fda conjunta para variables continuas.

$$F(x, y) = P(X \leq x, Y \leq y)$$

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds.$$

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y),$$

Definición 4.2.1

Función de distribución condicional para variables multidimensionales discretas.

Sea (X, Y) un vector aleatorio bivariado discreto con una fpp conjunta $f(x, y)$ y fpps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $P(X = x) = f_X(x) > 0$, la fpp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ definida por

$$f(y|x) = P(Y = y | X = x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $P(Y = y) = f_Y(y) > 0$, la fpp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ definida por

$$f(x|y) = P(X = x | Y = y) = \frac{f(x, y)}{f_Y(y)}.$$

Son distribuciones de probabilidad:

- $f(y|x) \geq 0$
- $\sum_y f(y|x) = \frac{\sum_y f(x, y)}{f_X(x)} = \frac{f_X(x)}{f_X(x)} = 1.$

Definición 4.2.3

Función de distribución condicional para variables multidimensionales continuas.

Sea (X, Y) un vector aleatorio bivariado continuo con fdp conjunta $f(x, y)$ y fdps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $f_X(x) > 0$, la fdp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ y definida por

$$f(y|x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $f_Y(y) > 0$, la fdp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ y definida por

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}.$$

Valor esperado condicional:

- Caso discreto: $E[g(Y) | x] = \sum_y g(y) f(y|x)$
- Caso continuo: $E[g(Y) | x] = \int_{-\infty}^{\infty} g(y) f(y|x) dy$

Definición 4.2.5

Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$, y fdps o fpps marginales $f_X(x)$ y $f_Y(y)$. Entonces X e Y se denominan **variables aleatorias independientes** si, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = f_X(x)f_Y(y).$$

Si X y Y son independientes, la fdp condicional de Y dado $X = x$ es

$$\begin{aligned} f(y|x) &= \frac{f(x, y)}{f_X(x)} && \text{(definición)} \\ &= \frac{f_X(x)f_Y(y)}{f_X(x)} && \text{(de (4.2.1))} \\ &= f_Y(y), \end{aligned}$$

no depende de x .

Lema 4.2.7

Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$. Entonces X y Y son **variables aleatorias independientes** si y solo si existen funciones $g(x)$ y $h(y)$ tales que, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = g(x)h(y).$$

Nota: O sea, si se puede separar en un producto donde uno dependa solo de x y el otro solo de y , entonces son independientes. Esto es un atajo.

Teorema 4.2.10**Eventos independientes.**

Valor esperado de un producto de funciones de variables independientes.

Sean X y Y variables aleatorias independientes.

- Para cualesquiera $A \subset \mathbb{R}$ y $B \subset \mathbb{R}$, $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$, es decir, los eventos $\{X \in A\}$ y $\{Y \in B\}$ son eventos independientes.
- Sea $g(x)$ una función que depende solo de x y $h(y)$ una función que depende solo de y . Entonces

$$E(g(X)h(Y)) = (E[g(X)])(E[h(Y)]).$$

Nota:

- Si dos variables X e Y son independientes, cualquier pregunta o condición que le hagas a X será totalmente independiente de cualquier pregunta o condición que le hagas a Y .
- La esperanza del producto de dos funciones aplicadas a variables independientes es igual al producto de sus esperanzas individuales.

Demo

$$\begin{aligned}
E(g(X)h(Y)) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f(x,y)dxdy \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f_X(x)f_Y(y)dxdy \\
&= \int_{-\infty}^{\infty} h(y)f_Y(y) \int_{-\infty}^{\infty} g(x)f_X(x)dxdy \\
&= \left(\int_{-\infty}^{\infty} g(x)f_X(x)dx \right) \left(\int_{-\infty}^{\infty} h(y)f_Y(y)dy \right) \\
&= (Eg(X))(Eh(Y)).
\end{aligned}$$

Teorema 4.2.14

La suma de dos variables normales independientes es también una variable normal (sus medias y varianzas se suman).

Sean $X \sim N(\mu, \sigma^2)$ y $Y \sim N(\gamma, \tau^2)$ variables aleatorias normales independientes. Entonces la variable aleatoria $Z = X + Y$ tiene una distribución $N(\mu + \gamma, \sigma^2 + \tau^2)$.

Clase 7. Muestras aleatorias.

(referencias a Casella Berger 2024)

Definición 4.5.1 y 4.5.2

La **covarianza** de X e Y es el número definido por

$$\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y))$$

La **correlación** de X e Y es el número definido por

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Nota:

- **Covarianza:** Mide la variación conjunta de dos variables respecto a sus respectivas medias (μ_X y μ_Y). Responde a la pregunta: “Cuando X está por encima de su promedio, ¿ Y tiende a estar por encima o por debajo del suyo?”.
- **Correlación:** Es la covarianza estandarizada (o adimensional). Se obtiene dividiendo la covarianza por el producto de las desviaciones estándar ($\sigma_X \sigma_Y$).

Teorema 4.5.3

Descomposición de la covarianza.

Para cualesquiera variables aleatorias X e Y .

$$\text{Cov}(X, Y) = E[XY] - \mu_X \mu_Y.$$

Demo:

$$\begin{aligned}
\text{Cov}(X, Y) &= E((X - \mu_X)(Y - \mu_Y)) \\
&= E((XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y)) \quad (\text{expandiendo el producto}) \\
&= E[XY] - \mu_X E[Y] - \mu_Y E[X] + \mu_X \mu_Y \quad (\mu_X \text{ y } \mu_Y \text{ son constantes}) \\
&= E[XY] - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y \\
&= E[XY] - \mu_X \mu_Y.
\end{aligned}$$

Teorema 4.5.5

Covarianza y correlación de variables independientes.

Sean X e Y variables aleatorias independientes entonces $\text{Cov}(X, Y) = 0$ y $\rho_{XY} = 0$.

Teorema 4.5.6

Varianza de una suma de variables aleatorias.

Si X e Y son dos variables aleatorias cualesquiera, y a y b son dos constantes cualesquiera, entonces

$$\text{Var}(aX + bY) = a^2 \text{Var } X + b^2 \text{Var } Y + 2ab \text{Cov}(X, Y).$$

Si X e Y son variables aleatorias independientes, entonces

$$\text{Var}(aX + bY) = a^2 \text{Var } X + b^2 \text{Var } Y.$$

Teorema 4.5.7

Correlación y relación lineal.

Para cualesquiera variables aleatorias X e Y ,

- a) $-1 \leq \rho_{XY} \leq 1$.
- b) $|\rho_{XY}| = 1$ si y solo si existen números $a \neq 0$ y b tales que $P(Y = aX + b) = 1$. Si $\rho_{XY} = 1$ entonces $a > 0$, y si $\rho_{XY} = -1$ entonces $a < 0$.

Nota: Si $\rho_{XY} = 1$ entonces si X aumenta, Y también y si $\rho_{XY} = -1$ entonces si X aumenta, Y decrece.

Definición 5.1.1

Las variables aleatorias $X_1, \dots, X_n$ se denominan una **muestra aleatoria** de tamaño n de la población $f(x)$ si $X_1, \dots, X_n$ son variables aleatorias mutuamente independientes y la fdp o fpp marginal de cada X_i es la misma función $f(x)$.

Alternativamente, $X_1, \dots, X_n$ se denominan **variables aleatorias independientes e idénticamente distribuidas** con fdp o fpp $f(x)$. Esto se abrevia comúnmente como **variables aleatorias i.i.d.**

Nota: Es la incertidumbre de lo que se obtiene la muestra aleatoria, y después de medir se convierte en un conjunto de números fijos o datos observados.

Definición 5.2.1, 5.2.2, 5.2.3

Sean $X_1, \dots, X_n$ una muestra aleatoria de tamaño n de una población y sea $T(x_1, \dots, x_n)$ una función de valor real o vectorial cuyo dominio incluye el espacio muestral de $(X_1, \dots, X_n)$. Entonces, la variable aleatoria o vector aleatorio $Y = T(X_1, \dots, X_n)$ se denomina **estadístico**. La distribución de probabilidad de un estadístico Y se denomina distribución muestral de Y .

La **media muestral** es el promedio aritmético de los valores en una muestra aleatoria. Generalmente se denota por

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

La **varianza muestral** es el estadístico definido por

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Nota: El estadístico entonces es una regla para resumir toda tu muestra en un número o vector calculable.

La media muestral es un estimador insesgado (en promedio, acierta exactamente al valor real del parámetro poblacional que intenta medir, no tiene una desviación o sesgo hacia arriba o abajo) de la media poblacional (μ).

Teorema 5.2.4

Sean $x_1, \dots, x_n$ números cualesquiera y $\bar{x} = \frac{x_1 + \dots + x_n}{n}$. Entonces **Promedio minimiza la varianza; descomposición de la varianza.**

- a) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$
- b) $(n-1)s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$

Nota:

- a) Si buscas un número a que represente a un conjunto de datos minimizando el error cuadrático total (la suma de las distancias al cuadrado de cada dato a ese valor a), el mejor valor posible a es la media aritmética $\bar{x}$.
- b) Esta igualdad proporciona una fórmula computacional rápida (conocida como el teorema de la suma de cuadrados). Permite calcular la suma de desviaciones cuadráticas sin necesidad de restar la media $\bar{x}$ a cada dato individualmente uno por uno.

Lema 5.2.5

Esperanza y varianza de una función de una muestra aleatoria.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una población y sea $g(x)$ una función tal que $E[g(X_1)]$ y $\text{Var}(g(X_1))$ existen. Entonces

$$E\left(\sum_{i=1}^n g(X_i)\right) = n(E[g(X_1)])$$

y

$$\text{Var}\left(\sum_{i=1}^n g(X_i)\right) = n(\text{Var}(g(X_1))).$$

Teorema 5.2.6

Valor esperado y varianza de las medias muestrales. Valor esperado de la varianza muestral.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una población con media μ y varianza $\sigma^2 < \infty$. Entonces

- a) $E[\bar{X}] = \mu,$
- b) $\text{Var}(\bar{X}) = \frac{\sigma^2}{n},$
- c) $E[S^2] = \sigma^2.$

Clase 8. Teorema Central del limite. Estimación puntual.

(referencias a Casella Berger 2024)

Teorema Central del Límite

Teorema 5.3.1

Propiedades de media y varianza de una normal.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una distribución $N(\mu, \sigma^2)$, y sean $\bar{X} = (\frac{1}{n}) \sum_{i=1}^n X_i$ y $S^2 = [\frac{1}{n-1}] \sum_{i=1}^n (X_i - \bar{X})^2$. Entonces

- $\bar{X}$ y S^2 son variables aleatorias independientes,
- $\bar{X}$ tiene una distribución $N(\mu, \frac{\sigma^2}{n})$,
- $(n-1) \frac{S^2}{\sigma^2}$ tiene una distribución chi-cuadrada (χ^2) con $n-1$ grados de libertad.

Distribución chi-cuadrada (χ^2): $X \sim \chi^2$ si $f(x|p) = \frac{1}{\Gamma(\frac{p}{2})2^{\frac{p}{2}}} x^{\frac{p}{2}-1} e^{-\frac{x}{2}}$ con $0 < x < \infty$ $p =$ “grados de libertad”.

Definición 5.5.1

Una secuencia de variables aleatorias, $X_1, X_2, \dots$, **converge en probabilidad** a una variable aleatoria X si, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0, \text{ o, equivalentemente, } \lim_{n \rightarrow \infty} P(|X_n - X| < \varepsilon) = 1.$$

Las $X_1, X_2, \dots$ en la Definición 5.5.1 (y las otras definiciones en esta sección) típicamente no son variables aleatorias independientes e idénticamente distribuidas, como en una muestra aleatoria. La distribución de X_n cambia a medida que cambia el subíndice, y los conceptos de convergencia discutidos en esta sección describen diferentes formas en las que la distribución de X_n converge a alguna distribución límite a medida que el subíndice se vuelve grande.

Teorema 5.5.2

Ley Débil de los Grandes Números.

Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $E[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = (\frac{1}{n}) \sum_{i=1}^n X_i$. Entonces, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \varepsilon) = 1,$$

es decir, $\bar{X}_n$ converge en probabilidad a μ .

Definición 5.5.10

Una secuencia de variables aleatorias, $X_1, X_2, \dots$, **converge en distribución** a una variable aleatoria X si

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x),$$

en todos los puntos x donde $F_X(x)$ es continua.

Teorema 5.5.15

Forma más Fuerte del Teorema del Límite Central.

Sean $X_1, X_2, \dots$ una secuencia de variables aleatorias i.i.d. (idénticamente distribuidas) con $E[X_i] = \mu$ y $0 < \text{Var}(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = (\frac{1}{n}) \sum_{i=1}^n X_i$. Sea $G_n(x)$ la fda de $\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$. Entonces, para todo x , $-\infty < x < \infty$,

$$\lim_{n \rightarrow \infty} G_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy,$$

es decir, $\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$ tiene una distribución normal estándar límite.

Nota: Te dice que sin importar qué distribución tengan tus datos originales (pueden ser continuos, discretos, simétricos, sesgados, exponenciales, de Poisson, etc.), la suma o el promedio de un número grande de variables aleatorias independientes e idénticamente distribuidas siempre se aproximará a una distribución Normal (Campana de Gauss). Es para hacer estadística sin saber la población.

Estimación puntual

Definición 7.1.1

Un **estimador puntual** es cualquier función $W(X_1, \dots, X_n)$ de una muestra. O sea, cualquier estadística es un punto estimador.

Sección 7.2.1

Método de los momentos para la normal / encontrar estimadores.

Supóngase que $X_1, \dots, X_n$ son i.i.d. $N(\theta, \sigma^2)$. En la notación precedente, $\theta_1 = \theta$ y $\theta_2 = \sigma^2$. Tenemos $m_1 = \bar{X}$, $m_2 = (\frac{1}{n}) \sum X_i^2$, $\mu'_1 = \theta$, $\mu'_2 = \theta^2 + \sigma^2$, y por lo tanto debemos resolver

$$\begin{aligned}\bar{X} &= \theta, \\ \frac{1}{n} \sum X_i^2 &= \theta^2 + \sigma^2.\end{aligned}$$

Resolver para θ y σ^2 produce los estimadores del método de los momentos

$$\tilde{\theta} = \bar{X}, \text{ y } \tilde{\sigma}^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2.$$

En este ejemplo simple, la solución del método de los momentos coincide con nuestra intuición, y tal vez le otorga cierta credibilidad a ambas. El método es algo más útil, sin embargo, cuando no se sugiere un estimador obvio.

Nota: El Método de los Momentos (MM) es una técnica para encontrar estimadores de los parámetros desconocidos de una población. Su idea central es muy directa: igualar los momentos teóricos (poblacionales) con los momentos muestrales (calculados con los datos) y resolver el sistema de ecuaciones resultante.

Sección 7.2.2

Método de máxima verosimilitud para encontrar estimadores.

Sea $X_1, \dots, X_n$ una muestra aleatoria con fdp / fpp $f(X(\Theta_1, \dots, \Theta_k))$. Definimos la **función de verosimilitud** como

$$L(\Theta_1, \dots, \Theta_k \mid X_1, \dots, X_n) = \prod_{i=1}^n f(X_i \mid \Theta_1, \dots, \Theta_k)$$

Nota: La L es de likelihood. El Método de Máxima Verosimilitud busca encontrar los valores de los parámetros desconocidos que hacen que los datos que ya observaste en tu muestra sean lo más probables posible de haber ocurrido.

Definición 7.2.4

Estimador de máxima verosimilitud.

Dada la muestra busco los $\Theta_1, \dots, \Theta_k$ tal que $L(\Theta_1, \dots, \Theta_k \mid X_1, \dots, X_n)$ es máxima. Busco $\hat{\Theta}(X_i)$ tal que $L(\Theta, X_1, \dots, X_n)$ es máxima.

Definición 7.3.1

Error cuadrático medio de un estimador.

El error cuadrático medio (MSE) de un estimador W de un parámetro θ es la función de θ definida por $E_\theta(W - \theta)^2$.

$$E_{\theta}[(W - \theta)^2] = \text{Var}_{\theta}(W) + (E_{\theta}[W] - \theta)^2 = \text{Var}_{\theta}(W) + (\text{Sesgo}_{\theta}(W))^2,$$

Nota: Métrica principal en estadística para evaluar la calidad o precisión general de un estimador. Responde a la pregunta: “En promedio, ¿qué tan lejos cae mi estimación respecto al verdadero valor del parámetro θ ?”. El sesgo mide qué tan desviado está el valor esperado del estimador respecto al parámetro objetivo θ .

Definición 7.3.2

El **sesgo de un estimador** puntual W , de un parámetro θ , es la diferencia entre el valor esperado de W y θ . Es decir, $\text{Sesgo}_{\theta}(W) = E_{\theta}[W] - \theta$. Un estimador cuyo sesgo es idénticamente (en θ) igual a cero se llama insesgado y satisface $E_{\theta}[W] = \theta$ para todo θ .

Para un estimador insesgado tenemos

$$E_{\theta}[(W - \theta)^2] = \text{Var}_{\theta}(W),$$

y por lo tanto, si un estimador es insesgado, su MSE es igual a su varianza.