

Clase 1. Teoría de conjuntos, espacio muestral, eventos, probabilidad.

(referencias a Casella Berger 2024)

Definición 1.1.1

El conjunto S de todos los posibles resultados de un experimento se llama **espacio muestral**.

Definición 1.1.2

Un **evento** es una colección de posibles resultados de un experimento, o sea, un subconjunto de S (incluyendolo a S). Relaciones de inclusión e igualdad.

Teorema 1.1.4

Para cualesquiera tres eventos, A , B y C , definidos en un espacio muestral S ,

a) Commutativity

$$\begin{aligned}A \cup B &= B \cup A, \\A \cap B &= B \cap A;\end{aligned}$$

b) Associativity

$$\begin{aligned}A \cup (B \cap C) &= (A \cup B) \cap C, \\A \cap (B \cup C) &= (A \cap B) \cup C;\end{aligned}$$

c) Distributive Laws

$$\begin{aligned}A \cap (B \cup C) &= (A \cap B) \cup (A \cap C), \\A \cup (B \cap C) &= (A \cup B) \cap (A \cup C);\end{aligned}$$

d) DeMorgan's Laws

$$(A \cup B)^c = A^c \cap B^c, (A \cap B)^c = A^c \cup B^c.$$

Definición 1.1.5

Dos eventos A y B son **disjuntos (o mutuamente exclusivos)** si $A \cap B = \emptyset$. Estos eventos $A_1, A_2, \dots$ son **disjuntos de a pares (o mutuamente exclusivos)** si $A_i \cap A_j = \emptyset \forall i \neq j$.

Definición 1.1.6

Si $A_1, A_2, \dots$ son disjuntos de a pares, $A_i \neq \emptyset$ y $\bigcup_{i=1}^{\infty} A_i = S$, entonces la colección $A_1, A_2, \dots$ forman una **partición** de S .

Definición 1.2.1

Una colección de subconjuntos de S se lo llama **sigma-algebra (campo de Borel o álgebra de Borel)**, denotada $\mathcal{B}$, si satisface las siguientes propiedades:

- a) $\emptyset \in \mathcal{B}$ (el conjunto vacío es un elemento de $\mathcal{B}$).
- b) Si $A \in \mathcal{B}$, entonces $A^c \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para complemento).
- c) Si $A_1, A_2, \dots \in \mathcal{B}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para uniones numerables).

Definición 1.2.4

Dado un espacio muestral S y un campo de Borel asociado $\mathcal{B}$, una **función de probabilidad** es una función P con dominio $\mathcal{B}$ que satisface los **axiomas de probabilidad**:

1. $P(A) \geq 0 \forall A \in \mathcal{B}$.
2. $P(S) = 1$.

3. Si $A_1, A_2, \dots \in \mathcal{B}$ son mutuamente exclusivos, entonces $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$.

Teorema 1.2.6

Sea $S = \{s_1, \dots, s_n\}$ un conjunto finito. Sea $\mathcal{B}$ un campo de Borel de subconjuntos de S . Sean $p_1, \dots, p_n$ numeros no-negativos que sumen uno. Para cualquier $A \in \mathcal{B}$, se define $P(A)$ como

$$P(A) = \sum_{\{i: s_i \in A\}} p_i$$

Teorema 1.2.8

Si P es una función de probabilidad y A es algun conjunto en $\mathcal{B}$, entonces

- a) $P(\emptyset) = 0$.
- b) $P(A) \leq 1$.
- c) $P(A^c) = 1 - P(A)$.

Teorema 1.2.9

Si P es una función de probabilidad y A y B son conjuntos en $\mathcal{B}$, entonces

- a) $P(B \cap A^c) = P(B) - P(A \cap B)$.
- b) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- c) Si $A \subset B$ entonces $P(A) \leq P(B)$.

Clase 2. Bonferroni, conteo, probabilidad condicional e independencia.

(referencias a Casella Berger 2024)

Teorema 1.2.11

Si P es una función de probabilidad, entonces

- a) $P(A) = \sum_{i=1}^{\infty} P(A \cap C_i)$ para cualquier partición $C_1, C_2, \dots$ **probabilidad total**
- b) $P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$ para cualesquiera conjuntos $A_1, A_2, \dots$ **probabilidad de Boole / desigualdad de Boole**

Ecuación 1.2.10

La **desigualdad de Bonferroni**:

$$P(A \cap B) \geq P(A) + P(B) - 1$$

La **generalización de Bonferroni** es:

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n-1)$$

Teorema 1.2.14

Si un trabajo consiste en k tareas separadas, de las cuales la i -ésima puede resolverse de n_i maneras, $i = 1, \dots, k$, entonces el trabajo completo puede hacerse en $n_1 \times n_2 \times \dots \times n_k$ formas.

Definición 1.2.17

Para numeros no negativos n y r , $n \geq r$, definiamos el **número combinatorio** $\binom{n}{r}$, leído como elegir r de n , como

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}$$

Tabla 1.2.1

Resumen de los cuatro casos básicos de conteo.

	Sin reemplazo	Con reemplazo
Con orden	$\frac{n!}{(n-r)!}$	n^r
Sin orden	$\binom{n}{r}$	$\binom{n+r-1}{r}$

Definición 1.3.2

Si A y B son eventos en S , y $P(B) > 0$, entonces la **probabilidad condicional** de un A dado B , escrito como $P(A|B)$, es

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Ecuación 1.3.3

$$P(A \cap B) = P(A|B)P(B)$$

Ecuación 1.3.4

$$P(A \cap B) = P(B|A)P(A)$$

Ecuación 1.3.5

Regla de Bayes para dos eventos.

$$P(A|B) = P(B|A) \frac{P(A)}{P(B)}$$

Teorema 1.3.5

Regla de Bayes generalizada. Sea $A_1, A_2, \dots$ una partición del espacio muestral, y sea B cualquier conjunto, para cada $i = 1, 2, \dots$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{\infty} P(B|A_j)P(A_j)}$$

Definición 1.3.7

Dos eventos, A y B , son **estadísticamente independientes** si

$$P(A \cap B) = P(A)P(B)$$

Esto implica que:

$$P(A|B) = P(A)$$

Teorema 1.3.9

Si A y B son eventos independientes, entonces los siguientes pares también:

a) A y B^c

b) A^c y B

c) A^c y B^c

Definición 1.3.12

Una colección de eventos $A_1, \dots, A_n$ son **mutuamente independientes** si para cualquier subcolección $A_{i_1}, \dots, A_{i_k}$, se cumple que la probabilidad de la intersección es igual a la factorización de las probabilidades:

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$$

Clase 3. Variables aleatorias.

(referencias a Casella Berger 2024)

Variables aleatorias

Definición 1.4.1

Una **variable aleatoria** es una función de un espacio muestral S a los números reales.

Ecuación 1.4.1

P_X es una función de probabilidad inducida en $\mathcal{X} = \{x_1, \dots, x_m\}$. Definida en los términos de la función original P .

$$P_X(X = x_i) = P(\{s_j \in S : X(s_j) = x_i\})$$

Definición 1.5.1

La **función de distribución acumulada, o fda**, de una variable aleatoria X , denotada como $F_{X(x)}$, es definida por

$$F_X(x) = P_X(X \leq x), \forall x$$

Teorema 1.5.3

La función $F(x)$ es una fda si y solo si las siguientes condiciones se cumplen:

- a) $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow \infty} F(x) = 1$.
- b) $F(x)$ es una función no decreciente de x .
- c) $F(x)$ es continua a la derecha. O sea, para todo número x_0 , $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$.

Definición 1.5.7

Una variable aleatoria X es **continua** si $F_X(x)$ es una función continua de x .

Una variable aleatoria X es **discreta** si $F_X(x)$ es una función escalonada (o en escalera / step function).

Definición 1.5.8

Las variables aleatorias X e Y son **idénticamente distribuidas** si, por cada conjunto $A \in \mathcal{B}$, $P(X \in A) = P(Y \in A)$

Teorema 1.5.10

Las siguientes declaraciones son equivalentes:

- a) Las variables aleatorias X e Y son idénticamente distribuidas.
- b) $F_X(x) = F_Y(x), \forall x$.

Definición 1.6.1

La **función de probabilidad puntual (fpp)** de una variable aleatoria discreta X es dada por

$$f_X(x) = P(X = x)$$

Ecuación 1.6.1

Relación entre fpp y fda (variable discreta)

$$F_X(x) = \sum_{i=1}^x f_X(i)$$

Ecuación 1.6.2

Relación entre fdp y fda (variable continua).

$$\frac{d}{dx} F_X(x) = f_X(x)$$

Definición 1.6.3

La **función de densidad de probabilidad (fdp)**, $f_X(x)$, de una variable aleatoria continua X es la función que satisface

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad \forall x$$

Teorema 1.6.5

Una función $f_X(x)$ es fdp o fpp, de una variable aleatoria X si y solo si

- a) $f_X(x) \geq 0 \quad \forall x$.
- b) $\sum_x f_X(x) = 1$ (fpp) o $\int_{-\infty}^{\infty} f_X(x) dx = 1$ (fdp)

Valor esperado**Definición 2.2.1**

El **valor esperado (esperanza)** de una variable aleatoria $g(X)$, denotado por $E[g(X)]$, es

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx & X \text{ continua} \\ \sum_{x \in \mathcal{X}} g(x) f_X(x) = \sum_{x \in \mathcal{X}} g(x) P(X = x) & X \text{ discreta} \end{cases}$$

dado que la integral o suma exista. Si $E[g(X)] = \infty$, decimos que $E[g(X)]$ no existe.

Es el resultado promedio teórico que esperarías obtener si repetirías un experimento aleatorio un número infinito de veces. Representa el punto de equilibrio de la distribución de probabilidad.

Valor esperado de la variable: **valor medio**.

$$g(X) = X$$

Es el promedio aritmético calculado a partir de un conjunto de datos observados (una muestra o una población real). Por la Ley de los Grandes Números, a medida que aumentas el tamaño de la muestra, el valor medio se acerca a la esperanza.

Valor esperado de las distancias cuadráticas con respecto al valor medio: **varianza**.

$$\text{Var}(X) = E[(X - E(X))^2]$$

Es una medida de la dispersión o variabilidad de los datos respecto a su media o esperanza. A menudo se calcula su raíz cuadrada, conocida como **desviación estándar**, para devolver la medida a la unidad original.

Teorema 2.2.5

Sea X una variable aleatoria y sean a, b y c constantes. Entonces para funciones cualesquiera $g_1(x)$ y $g_2(x)$ donde sus esperanzas existen, se cumple que

- a) $E[ag_1(X) + bg_2(X) + c] = aE[g_1(X)] + bE[g_2(X)] + c$
- b) Si $g_1(x) \geq 0$ para todo x , entonces $E[g_1(X)] \geq 0$.
- c) Si $g_1(x) \geq g_2(x)$ para todo x , entonces $E[g_1(X)] \geq E[g_2(X)]$.
- d) Si $a \leq g_1(x) \leq b$ para todo x , entonces $a \leq E[g_1(X)] \leq b$.

Teorema 2.3.4

Si X es una variable aleatoria con varianza finita, entonces para cualesquiera constantes a y b ,

$$\text{Var}(aX + b) = a^2 \text{Var}X$$

Clase 4. Distribuciones discretas y continuas.

(referencias a Casella Berger 2024 y al resumen de distribuciones de la práctica)

Familias comunes de distribuciones discretas

Ecuación 3.2.1

Distribución uniforme discreta.

$X \sim U(1, N)$ si $P(X = x | N) = \frac{1}{N}$ ($x = 1, 2, \dots, N$)

$$E[X] = \sum_{x=1}^N xP(X = x | N) = \frac{N+1}{2}$$

$$\text{Var}(X) = \frac{(N+1)(N-1)}{12}$$

Ecuación 3.2.3

Distribución de Bernoulli (ensayo de Bernoulli).

$X \sim \text{Bernoulli}(p)$ si $x =$
 $\begin{cases} 1 \text{ con probabilidad } p \\ 0 \text{ con probabilidad } (1-p) \end{cases} \quad (0 \leq p \leq 1)$

$$E[X] = p$$

$$\text{Var}(X) = p(1-p)$$

Teorema 3.2.2

Distribución binomial. Supongamos n ensayos de Bernoulli independientes e $Y =$ número de éxitos en n ensayos. Modela el número de éxitos en n ensayos independientes, cada uno con probabilidad de éxito p .

$Y \sim \text{Bin}(n, p)$ si $P(Y = y | n, p) = \binom{n}{y} p^y (1-p)^{n-y}$

$$E[Y] = np$$

$$\text{Var}(Y) = np(1-p)$$

Ecuación 3.2.5

Distribución de Poisson. Modela el número de eventos (raros e independientes) que ocurren en un intervalo fijo de tiempo o espacio.

$X \sim \text{Poisson}(\lambda)$ si $P(X = x | \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$, ($x = 0, 1, \dots$)

$$E[X] = \lambda$$

$$\text{Var}(X) = \lambda$$

Ecuaciones 3.2.6 3.2.7

Relaciones de recursión (binomial y Poisson)

$X \sim \text{Poisson}(\lambda) \Rightarrow P(X = x) = \frac{\lambda}{x} P(X = x-1)$, ($x = 1, 2, \dots$)

$Y \sim \text{Bin}(n, p) \Rightarrow P(Y = y) = \frac{(n-y+1)p}{y(1-p)} P(Y = y-1)$

Ecuación 3.2.11

Distribución geométrica.

$X =$ número de ensayos de Bernoulli hasta el primer éxito.

$X \sim \text{Geom}(p)$ si $P(X = x | p) = (1-p)^{x-1}$, ($x = 1, 2, \dots$)

$$E[X] = \frac{1}{p}$$

$$\text{Var}(X) = \frac{1-p}{p^2}$$

Propiedad “sin memoria”.

$$P(X > s | X > t) = P(X > s-t), \quad (s > t)$$

La probabilidad de obtener una secuencia de fracasos no depende de la posición en la tira, solo del largo de la secuencia.

Ecuación 3.2.9

Distribución binomial negativa. Modela el número de ensayos necesarios hasta obtener el r -ésimo éxito.

$$p_X(k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, \quad (k = r, r+1, \dots), \quad (0 < p < 1)$$

$$E[X] = \frac{r}{p}$$

$$\text{Var}(Y) = \frac{r(1-p)}{p^2}$$

Ecuación 3.2.2

Distribución hipergeométrica. Modela el número de elementos “buenos” al extraer una muestra de tamaño m sin reposición de una población finita de tamaño N con r buenos.

$$p_X(k) = \frac{\binom{r}{k} \binom{N-r}{m-k}}{\binom{N}{m}}, \quad \max(r+m-N, 0) \leq k \leq \min(r, m)$$

$$E[X] = m \frac{r}{N}$$

$$\text{Var}(X) = m \frac{r}{N} \frac{N-r}{N} \frac{N-m}{N-1}$$

Familias comunes de distribuciones continuas

A partir de aca está mal hablar de $P(X=x)$ ya que es una distribución continua y se mide la probabilidad con el área de su curva, por lo que esto es lo mismo que decir 0.

Ecuación 3.3.1

Distribución uniforme continua.

$$X \sim U[a, b]$$

$$f(x) = \frac{1}{(b-a)} \mathbb{1}_{[a,b]}(x)$$

$$E[X] = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

$$U[0, 1] = \beta(1, 1)$$

Ecuación 3.3.13

Distribución normal.

$$X \sim N(\mu, \sigma^2)$$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}, \quad \sigma > 0$$

$$E[X] = \mu$$

$$\text{Var}(X) = \sigma^2$$

Normal estándar: $N(0, 1)$

Ecuación 3.3.6

Distribución gamma.

$$X \sim \Gamma(\alpha, \lambda)$$

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda, \alpha > 0$$

$$E[X] = \frac{\alpha}{\lambda}$$

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}$$

$$\Gamma(1) = 1, \quad \Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1), \quad \Gamma(n) = (n-1)!, \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Ecuación 3.3.16 3.3.17

Distribución Beta.

$$X \sim \beta(a, b)$$

$$f_X(x) =$$

$$\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} \mathbb{1}_{(0,1)}(x), \quad a, b > 0$$

$$E[X] = \frac{a}{a+b}$$

$$\text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

Relación con la función gamma

$$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

Ecuación 3.3.11

Distribución exponencial.

La distribución exponencial es una distribución de probabilidad continua que modela el tiempo que transcurre hasta que ocurre un determinado evento. λ es la tasa de ocurrencia de eventos en un intervalo de tiempo.

$$X \sim \text{Exp}(\lambda)$$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda > 0$$

$$E[X] = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Parametrización alternativa.

$$\text{Exp}(\lambda) = \Gamma(1, \lambda)$$

Ecuación 3.3.19

Distribución de Cauchy.

$$X \sim C(0, \lambda)$$

$$f_X(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + x^2}, \quad \lambda > 0$$

No tiene esperanza definida. $C(0, 1) = t_1$

Otras

T de Student

$$X \sim t_n$$

$$f_X(x) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{\pi n}} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}$$

$$E(X) = 0$$

$$\text{Var}(X) = 2n$$

Chi cuadrado

$$X \sim \mathcal{X}_n^2$$

$$\mathcal{X}_n^2 = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right), n \in \mathbb{N}$$

$$E[X] = n$$

$$\text{Var}(X) = 2n$$

F de Snedecor

$$X \sim F_{n,m}$$

$$f_X(x) =$$

$$\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \left(\frac{n}{m}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} \left(1 + \frac{n}{m}x\right)^{-\frac{m+n}{2}} \mathbb{1}((0, \infty))(x)$$

Propiedades más usadas

- $X \sim \text{Bi}(n, p), Y \sim \text{Bi}(m, p)$ independientes
 $\Rightarrow X + Y \sim \text{Bi}(n + m, p)$.
- $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ independientes $\Rightarrow$
 $X + Y \sim P(\lambda_1 + \lambda_2)$.
- $\text{Bi}(n, p) \approx P(\lambda)$ con $\lambda = np$ cuando $p \ll 1$.
- $H(N, r, m) \approx \text{Bi}(m, \frac{r}{N})$ cuando N es grande
y $m \ll N$.
- $X \sim N(\mu, \sigma^2) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0, 1)$
(estandarización).
- $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$
independientes $\Rightarrow aX + bY + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$.
- $X \sim \Gamma(\alpha, \lambda) \Rightarrow cX \sim \Gamma(\alpha, \frac{\lambda}{c})$.
- $Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi_1^2$.

Clase 5. Transformación de variables aleatorias.

(referencias a Casella Berger 2024)

Transformaciones de variables aleatorias

Ecuación 2.1.1

Función de una variable aleatoria. Si X es una variable aleatoria con fda $F_X(x)$, entonces cualquier función de X , digamos $g(X)$ también es una variable aleatoria.

$$P(Y \in A) = P(g(X) \in A)$$

$g(X)$ define un mapa desde el espacio muestral original (X) al transformado (Y).

$\mathcal{X}$ soporte de X

$\mathcal{Y}$ soporte de Y

(**soporte** es el conjunto de puntos x donde la función de probabilidad puntual (fpp) es estrictamente mayor que cero.)

$$g(x) : \mathcal{X} \rightarrow \mathcal{Y}$$

Lo definimos por la inversa:

$$g^{-1}(\{y\}) = \{x \in \mathcal{X} : g(x) = y\}$$

$$Y = g(X)$$

Podemos escribir entonces para cualquier conjunto $A \subset \mathcal{Y}$:

$$\begin{aligned} P(Y \in A) &= P(g(X) \in A) \\ &= P(\{x \in \mathcal{X} : g(x) \in A\}) \\ &= P(X \in g^{-1}(A)). \end{aligned}$$

Ecuación 2.1.4, 2.1.8, 2.1.9

Función de distribución acumulada de una variable transformada. X e Y variables aleatorias continuas, calculemos la fda de $Y = g(X)$:

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\ &= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x) dx. \end{aligned}$$

Región de integración de la probabilidad de una transformación.

Si g es creciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \leq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \leq g^{-1}(y)\}. \end{aligned}$$

Si g es decreciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \geq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \geq g^{-1}(y)\}. \end{aligned}$$

Con esto podemos escribir que, si es creciente $g(x)$:

$$F_Y(y) = \int_{\{x \in \mathcal{X} : x \leq g^{-1}(y)\}} f_X(x) dx = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx = F_X(g^{-1}(y)).$$

Si $g(x)$ es decreciente, tenemos

$$F_Y(y) = \int_{g^{-1}(y)}^{\infty} f_X(x) dx = 1 - F_X(g^{-1}(y)).$$

Teorema 2.1.3**Función de distribución acumulada de una transformación.**

Sea X una variable aleatoria con fda $F_X(x)$, sea $Y = g(X)$, y sean $\mathcal{X}$ e $\mathcal{Y}$ definidos como $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x) \text{ para algún } x \in \mathcal{X}\}$.

- a) Si g es una función creciente en $\mathcal{X}$, $F_Y(y) = F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.
- b) Si g es una función decreciente en $\mathcal{X}$ y X es una variable aleatoria continua, $F_Y(y) = 1 - F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.

Teorema 2.1.5**Función de densidad de probabilidad de una transformación.**

Sea X una variable aleatoria con fdp $f_X(x)$ y sea $Y = g(X)$, donde g es una función monótona (función que no cambia de sentido de variación (siempre crece o siempre decrece) a lo largo de todo el conjunto $\mathcal{X}$ donde la variable aleatoria X toma valores). Sean $\mathcal{X}$ y $\mathcal{Y}$ definidos como en el teorema 2.1.3. Supongamos que $f_X(x)$ es continua en $\mathcal{X}$ y que $g^{-1}(y)$ tiene derivada continua en $\mathcal{Y}$. Entonces la fdp de Y está dada por:

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| & y \in \mathcal{Y}, \\ 0 & \text{si no} \end{cases}$$

Teorema 2.1.10**Transformación integral de probabilidad.**

Tenga X una fda continua $F_X(x)$ y definimos la variable aleatoria Y como $Y = F_X(X)$. Entonces Y esta uniformemente distribuida en $(0, 1)$, o sea, $P(Y \leq y) = y$, $0 < y < 1$.

Demo:

Para $Y = F_X(X)$ tenemos que, para $0 < y < 1$,

$$\begin{aligned} P(Y \leq y) &= P(F_X(X) \leq y) \\ &= P(F_X^{-1}[F_X(X)] \leq F_X^{-1}(y)) \quad (F_X^{-1} \text{ es creciente}) \\ &= P(X \leq F_X^{-1}(y)) \quad (\text{propiedad de } F_X^{-1}) \\ &= F_X(F_X^{-1}(y)) \quad (\text{definición de } F_X) \\ &= y. \quad (\text{continuidad de } F_X) \end{aligned}$$

Clase 6. Distribuciones conjuntas.

(referencias a Casella Berger 2024)

Teorema 3.6.1**Desigualdad de Markov.**

Sea X una variable aleatoria y $g(X) \geq 0$. Entonces, para cualquier $r > 0$:

$$P(g(X) \geq r) \leq \frac{E[g(X)]}{r}$$

Desigualdad de Chevyshev

$$P(|Y - E[Y]| \geq k) \leq \frac{\text{Var}(Y)}{k^2}$$

Distribuciones conjuntas

Definición 4.1.1

Un **vector aleatorio n-dimensional** es una función de un espacio muestral S en $\mathbb{R}^2$, un espacio Euclidiano n-dimensional.

Definición 4.1.3

Sea (X, Y) un vector aleatorio bivariado discreto. Entonces la función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ definida por $f(x, y) = P(X = x, Y = y)$ se la llama la **función de probabilidad puntual conjunta / fpp conjunta** de (X, Y) . Si es necesario reafirmar que f es la fpp conjunta del vector (X, Y) en vez de ser de otro vector, la notación que se usa es $f_{X,Y}(x, y)$

La fpp conjunta puede ser usada para computar la probabilidad de cualquier evento definido en términos de (X, Y) . Sea A un subconjunto de $\mathbb{R}^2$. Entonces,

$$P((X, Y) \in A) = \sum_{(x,y) \in A} f(x, y).$$

El valor esperado es,

$$E[g(X, Y)] = \sum_{(x,y) \in \mathbb{R}^2} g(x, y) f(x, y).$$

Propiedades:

Sean $g_1(x, y)$ y $g_2(x, y)$ funciones y a, b y c constantes:

- $E[ag_1(x, y) + bg_2(x, y) + c] = aE[g_1(x, y)] + bE[g_2(x, y)] + c$
- $f(x, y) \geq 0$ para todo x, y
- $\sum_{(x,y) \in \mathbb{R}^2} f(x, y) = 1$

Teorema 4.1.6

Sea (X, Y) un vector aleatorio bivariado discreto con fpp conjunta $f_{X,Y}(x, y)$. Entonces, la **función de probabilidad puntual marginal / fpp marginal** de X e Y , $f_X(x) = P(X = x)$ y $f_Y(y) = P(Y = y)$, son dadas por,

$$f_X(x) = \sum_{y \in \mathbb{R}} f_{X,Y}(x, y) \quad \text{y} \quad f_Y(y) = \sum_{x \in \mathbb{R}} f_{X,Y}(x, y).$$

Nota: Marginal es por como se ve en una tabla los resultados de $f_X(x)$ y $f_Y(y)$, o sea, en los márgenes de una tabla.

Definición 4.1.10

Una función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ se la llama **función de densidad de probabilidad conjunta / fdp conjunta** para un vector bidimensional continuo (X, Y) si, por cada $A \subset \mathbb{R}^2$,

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy.$$

Ecuación 4.1.1

Valor esperado de una función de dos variables continuas.

Sea $g(X, Y) \in \mathbb{R}$

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy.$$

Ecuación 4.1.2

Funciones de densidad de probabilidad marginales / fdp marginal para variables continuas.

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad -\infty < x < \infty,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx, \quad -\infty < y < \infty.$$

Ecuación 4.1.3

Función de distribución acumulada conjunta / fda conjunta para variables continuas.

$$F(x, y) = P(X \leq x, Y \leq y)$$

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds.$$

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y),$$

Definición 4.2.1

Función de distribución condicional para variables multidimensionales discretas.

Sea (X, Y) un vector aleatorio bivariado discreto con una fpp conjunta $f(x, y)$ y fpps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $P(X = x) = f_X(x) > 0$, la fpp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ definida por

$$f(y|x) = P(Y = y | X = x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $P(Y = y) = f_Y(y) > 0$, la fpp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ definida por

$$f(x|y) = P(X = x | Y = y) = \frac{f(x, y)}{f_Y(y)}.$$

Son distribuciones de probabilidad:

- $f(y|x) \geq 0$
- $\sum_y f(y|x) = \frac{\sum_y f(x, y)}{f_X(x)} = \frac{f_X(x)}{f_X(x)} = 1.$

Definición 4.2.3

Función de distribución condicional para variables multidimensionales continuas.

Sea (X, Y) un vector aleatorio bivariado continuo con fdp conjunta $f(x, y)$ y fdps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $f_X(x) > 0$, la fdp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ y definida por

$$f(y|x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $f_Y(y) > 0$, la fdp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ y definida por

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}.$$

Valor esperado condicional:

- Caso discreto: $E[g(Y) | x] = \sum_y g(y)f(y|x)$
- Caso continuo: $E[g(Y) | x] = \int_{-\infty}^{\infty} g(y)f(y|x)dy$

Definición 4.2.5

Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$, y fdps o fpps marginales $f_X(x)$ y $f_Y(y)$. Entonces X e Y se denominan **variables aleatorias independientes** si, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = f_X(x)f_Y(y).$$

Si X y Y son independientes, la fdp condicional de Y dado $X = x$ es

$$\begin{aligned} f(y|x) &= \frac{f(x, y)}{f_X(x)} && \text{(definición)} \\ &= \frac{f_X(x)f_Y(y)}{f_X(x)} && \text{(de (4.2.1))} \\ &= f_Y(y), \end{aligned}$$

no depende de x .

Lema 4.2.7

Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$. Entonces X y Y son **variables aleatorias independientes** si y solo si existen funciones $g(x)$ y $h(y)$ tales que, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = g(x)h(y).$$

Nota: O sea, si se puede separar en un producto donde uno dependa solo de x y el otro solo de y , entonces son independientes. Esto es un atajo.

Teorema 4.2.10

Eventos independientes.

Valor esperado de un producto de funciones de variables independientes.

Sean X y Y variables aleatorias independientes.

- Para cualesquiera $A \subset \mathbb{R}$ y $B \subset \mathbb{R}$, $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$, es decir, los eventos $\{X \in A\}$ y $\{Y \in B\}$ son eventos independientes.
- Sea $g(x)$ una función que depende solo de x y $h(y)$ una función que depende solo de y . Entonces

$$E(g(X)h(Y)) = (E[g(X)])(E[h(Y)]).$$

Nota:

- Si dos variables X e Y son independientes, cualquier pregunta o condición que le hagas a X será totalmente independiente de cualquier pregunta o condición que le hagas a Y .
- La esperanza del producto de dos funciones aplicadas a variables independientes es igual al producto de sus esperanzas individuales.

Demo

$$\begin{aligned}
E(g(X)h(Y)) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f(x,y)dxdy \\
&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f_X(x)f_Y(y)dxdy \\
&= \int_{-\infty}^{\infty} h(y)f_Y(y) \int_{-\infty}^{\infty} g(x)f_X(x)dxdy \\
&= \left(\int_{-\infty}^{\infty} g(x)f_X(x)dx \right) \left(\int_{-\infty}^{\infty} h(y)f_Y(y)dy \right) \\
&= (Eg(X))(Eh(Y)).
\end{aligned}$$

Teorema 4.2.14

La suma de dos variables normales independientes es también una variable normal (sus medias y varianzas se suman).

Sean $X \sim N(\mu, \sigma^2)$ y $Y \sim N(\gamma, \tau^2)$ variables aleatorias normales independientes. Entonces la variable aleatoria $Z = X + Y$ tiene una distribución $N(\mu + \gamma, \sigma^2 + \tau^2)$.

Clase 7. Muestras aleatorias.

(referencias a Casella Berger 2024)

Definición 4.5.1 y 4.5.2

La **covarianza** de X e Y es el número definido por

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

La **correlación** de X e Y es el número definido por

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Posdata:

- μ_X y μ_Y son las $E[X]$ y $E[Y]$ respectivamente.
- $\sigma_X^2 = \sqrt{\text{Var}(X)} = \sqrt{E[X^2] - \mu_X^2}$ y $\sigma_Y^2 = \sqrt{\text{Var}(Y)} = \sqrt{E[Y^2] - \mu_Y^2}$.

Nota:

- **Covarianza:** Mide la variación conjunta de dos variables respecto a sus respectivas medias (μ_X y μ_Y). Responde a la pregunta: “Cuando X está por encima de su promedio, ¿ Y tiende a estar por encima o por debajo del suyo?”.
- **Correlación:** Es la covarianza estandarizada (o adimensional). Se obtiene dividiendo la covarianza por el producto de las **desviaciones estándar** ($\sigma_X \sigma_Y$).

Teorema 4.5.3

Descomposición de la covarianza.

Para cualesquiera variables aleatorias X e Y .

$$\text{Cov}(X, Y) = E[XY] - \mu_X \mu_Y.$$

Teorema 4.5.5**Covarianza y correlación de variables independientes.**

Sean X e Y variables aleatorias independientes entonces $\text{Cov}(X, Y) = 0$ y $\rho_{XY} = 0$.

Teorema 4.5.6**Varianza de una suma de variables aleatorias.**

Si X e Y son dos variables aleatorias cualesquiera, y a y b son dos constantes cualesquiera, entonces

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

Si X e Y son variables aleatorias independientes, entonces

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y).$$

Teorema 4.5.7**Correlación y relación lineal.**

Para cualesquiera variables aleatorias X e Y ,

- a) $-1 \leq \rho_{XY} \leq 1$.
- b) $|\rho_{XY}| = 1$ si y solo si existen números $a \neq 0$ y b tales que $P(Y = aX + b) = 1$. Si $\rho_{XY} = 1$ entonces $a > 0$, y si $\rho_{XY} = -1$ entonces $a < 0$.

Nota: Si $\rho_{XY} = 1$ entonces si X aumenta, Y también y si $\rho_{XY} = -1$ entonces si X aumenta, Y decrece.

Definición 5.1.1

Las variables aleatorias $X_1, \dots, X_n$ se denominan una **muestra aleatoria** de tamaño n de la población $f(x)$ si $X_1, \dots, X_n$ son variables aleatorias mutuamente independientes y la fdp o fpp marginal de cada X_i es la misma función $f(x)$.

Alternativamente, $X_1, \dots, X_n$ se denominan **variables aleatorias independientes e idénticamente distribuidas** con fdp o fpp $f(x)$. Esto se abrevia comúnmente como **variables aleatorias i.i.d.**

Nota: Es la incertidumbre de lo que se obtiene la muestra aleatoria, y después de medir se convierte en un conjunto de números fijos o datos observados.

Definición 5.2.1, 5.2.2, 5.2.3

Sean $X_1, \dots, X_n$ una muestra aleatoria de tamaño n de una población y sea $T(x_1, \dots, x_n)$ una función de valor real o vectorial cuyo dominio incluye el espacio muestral de $(X_1, \dots, X_n)$. Entonces, la variable aleatoria o vector aleatorio $Y = T(X_1, \dots, X_n)$ se denomina **estadístico**. La distribución de probabilidad de un estadístico Y se denomina distribución muestral de Y .

La **media muestral** es el promedio aritmético de los valores en una muestra aleatoria. Generalmente se denota por

$$\bar{X} = \frac{X_1 + \dots + X_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i.$$

La **varianza muestral** es el estadístico definido por

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

Nota: El estadístico entonces es una regla para resumir toda tu muestra en un número o vector calculable.

La media muestral es un estimador insesgado (en promedio, acierta exactamente al valor real del parámetro poblacional que intenta medir, no tiene una desviación o sesgo hacia arriba o abajo) de la media poblacional (μ).

Teorema 5.2.4

Sean $x_1, \dots, x_n$ números cualesquiera y $\bar{x} = \frac{x_1 + \dots + x_n}{n}$. Entonces **Promedio minimiza la varianza; descomposición de la varianza.**

- a) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$
- b) $(n-1)s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$

Nota:

- a) Si buscas un número a que represente a un conjunto de datos minimizando el error cuadrático total (la suma de las distancias al cuadrado de cada dato a ese valor a), el mejor valor posible a es la media aritmética $\bar{x}$.
- b) Esta igualdad proporciona una fórmula computacional rápida (conocida como el teorema de la suma de cuadrados). Permite calcular la suma de desviaciones cuadráticas sin necesidad de restar la media $\bar{x}$ a cada dato individualmente uno por uno.

Lema 5.2.5

Esperanza y varianza de una función de una muestra aleatoria.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una población y sea $g(x)$ una función tal que $E[g(X_1)]$ y $\text{Var}(g(X_1))$ existen. Entonces

$$E\left(\sum_{i=1}^n g(X_i)\right) = n(E[g(X_1)])$$

y

$$\text{Var}\left(\sum_{i=1}^n g(X_i)\right) = n(\text{Var}(g(X_1))).$$

Teorema 5.2.6

Valor esperado y varianza de las medias muestrales. Valor esperado de la varianza muestral.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una población con media μ y varianza $\sigma^2 < \infty$. Entonces

- a) $E[\bar{X}] = \mu$,
- b) $\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$,
- c) $E[S^2] = \sigma^2$.

Clase 8. Teorema Central del limite. Estimación puntual.

(referencias a Casella Berger 2024)

Teorema Central del Límite

Teorema 5.3.1

Propiedades de media y varianza de una normal.

Sean $X_1, \dots, X_n$ una muestra aleatoria de una distribución $N(\mu, \sigma^2)$, y sean $\bar{X} = \left(\frac{1}{n}\right) \sum_{i=1}^n X_i$ y $S^2 = \left[\frac{1}{n-1}\right] \sum_{i=1}^n (X_i - \bar{X})^2$. Entonces

- a) $\bar{X}$ y S^2 son variables aleatorias independientes,
- b) $\bar{X}$ tiene una distribución $N\left(\mu, \frac{\sigma^2}{n}\right)$,
- c) $(n-1)\frac{S^2}{\sigma^2}$ tiene una distribución chi-cuadrada (χ^2) con $n-1$ grados de libertad.

Distribución chi-cuadrada (χ^2):

$X \sim \chi^2$ si $f(x|p) = \frac{1}{\Gamma(\frac{p}{2})2^{\frac{p}{2}}} x^{\frac{p}{2}-1} e^{-\frac{x}{2}}$ con $0 < x < \infty$ $p =$ “grados de libertad”.

Definición 5.5.1

Una secuencia de variables aleatorias, $X_1, X_2, \dots$, **converge en probabilidad** a una variable aleatoria X si, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0, \text{ o, equivalentemente, } \lim_{n \rightarrow \infty} P(|X_n - X| < \varepsilon) = 1.$$

Las $X_1, X_2, \dots$ en la Definición 5.5.1 (y las otras definiciones en esta sección) típicamente no son variables aleatorias independientes e idénticamente distribuidas, como en una muestra aleatoria. La distribución de X_n cambia a medida que cambia el subíndice, y los conceptos de convergencia discutidos en esta sección describen diferentes formas en las que la distribución de X_n converge a alguna distribución límite a medida que el subíndice se vuelve grande.

Teorema 5.5.2

Ley Débil de los Grandes Números.

Sean $X_1, X_2, \dots$ variables aleatorias i.i.d. con $E[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = \left(\frac{1}{n}\right) \sum_{i=1}^n X_i$. Entonces, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \varepsilon) = 1,$$

es decir, $\bar{X}_n$ converge en probabilidad a μ .

Definición 5.5.10

Una secuencia de variables aleatorias, $X_1, X_2, \dots$, **converge en distribución** a una variable aleatoria X si

$$\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x),$$

en todos los puntos x donde $F_X(x)$ es continua.

Teorema 5.5.15

Forma más Fuerte del Teorema del Límite Central.

Sean $X_1, X_2, \dots$ una secuencia de variables aleatorias i.i.d. (idénticamente distribuidas) con $E[X_i] = \mu$ y $0 < \text{Var}(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = \left(\frac{1}{n}\right) \sum_{i=1}^n X_i$. Sea $G_n(x)$ la fda de $\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$. Entonces, para todo x , $-\infty < x < \infty$,

$$\lim_{n \rightarrow \infty} G_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy,$$

es decir, $\sqrt{n} \frac{\bar{X}_n - \mu}{\sigma}$ tiene una distribución normal estándar límite.

Nota: Te dice que sin importar qué distribución tengan tus datos originales (pueden ser continuos, discretos, simétricos, sesgados, exponenciales, de Poisson, etc.), la suma o el promedio de un número grande de variables aleatorias independientes e idénticamente distribuidas siempre se aproximará a una distribución Normal (Campana de Gauss). Es para hacer estadística sin saber la población.

Estimación puntual

Definición 7.1.1

Un **estimador puntual** es cualquier función $W(X_1, \dots, X_n)$ de una muestra. O sea, cualquier estadístico es un punto estimador.

Sección 7.2.1

Método de los momentos para la normal / encontrar estimadores.

Sean $X_1, \dots, X_n$ una muestra de una población con fdp o fpm $f(x \mid \theta_1, \dots, \theta_k)$. Los estimadores del método de los momentos se obtienen igualando los primeros k momentos muestrales a los correspondientes k momentos poblacionales, y resolviendo el sistema de ecuaciones simultáneas resultante. Más precisamente, se define:

$$\begin{aligned}m_1 &= \frac{1}{n} \sum_{i=1}^n X_i^1, \mu_{1'} = E[X^1] \\m_2 &= \frac{1}{n} \sum_{i=1}^n X_i^2, \mu_{2'} = E[X^2] \\&\vdots \\m_k &= \frac{1}{n} \sum_{i=1}^n X_i^k, \mu_{k'} = E[X^k].\end{aligned}$$

El momento poblacional μ_j' típicamente será una función de $\theta_1, \dots, \theta_k$, digamos $\mu_{j'(\theta_1, \dots, \theta_k)}'$. El **estimador del método de los momentos (EMM)** $(\tilde{\theta}_1, \dots, \tilde{\theta}_k)$ de $(\theta_1, \dots, \theta_k)$ se obtiene resolviendo el siguiente sistema de ecuaciones para $(\theta_1, \dots, \theta_k)$ en términos de $(m_1, \dots, m_k)$:

$$\begin{aligned}m_1 &= \mu_{1'(\theta_1, \dots, \theta_k)}', \\m_2 &= \mu_{2'(\theta_1, \dots, \theta_k)}', \\&\vdots \\m_k &= \mu_{k'(\theta_1, \dots, \theta_k)}' .\end{aligned}$$

Nota: El Método de los Momentos (MM) es una técnica para encontrar estimadores de los parámetros desconocidos de una población. Su idea central es muy directa: igualar los momentos teóricos (poblacionales) con los momentos muestrales (calculados con los datos) y resolver el sistema de ecuaciones resultante.

Sección 7.2.2

Método de máxima verosimilitud para encontrar estimadores.

Sea $X_1, \dots, X_n$ una muestra aleatoria con fdp / fpp $f(X(\Theta_1, \dots, \Theta_k))$. Definimos la **función de verosimilitud** como

$$L(\Theta_1, \dots, \Theta_k \mid X_1, \dots, X_n) = \prod_{i=1}^n f(X_i \mid \Theta_1, \dots, \Theta_k)$$

Nota: La L es de likelihood. El Método de Máxima Verosimilitud busca encontrar los valores de los parámetros desconocidos que hacen que los datos que ya observaste en tu muestra sean lo más probables posible de haber ocurrido.

Definición 7.2.4

Estimador de máxima verosimilitud.

Dada la muestra busco los $\Theta_1, \dots, \Theta_k$ tal que $L(\Theta_1, \dots, \Theta_k \mid X_1, \dots, X_n)$ es máxima. Busco $\hat{\Theta}(X_i)$ tal que $L(\Theta, X_1, \dots, X_n)$ es máxima.

Definición 7.3.1

Error cuadrático medio de un estimador.

El error cuadrático medio (MSE) de un estimador W de un parámetro θ es la función de θ definida por $E_{\theta}(W - \theta)^2$.

$$E_{\theta}[(W - \theta)^2] = \text{Var}_{\theta}(W) + (E_{\theta}[W] - \theta)^2 = \text{Var}_{\theta}(W) + (\text{Sesgo}_{\theta}(W))^2,$$

Nota: Métrica principal en estadística para evaluar la calidad o precisión general de un estimador. Responde a la pregunta: “En promedio, ¿qué tan lejos cae mi estimación respecto al verdadero valor del parámetro θ ?”. El sesgo mide qué tan desviado está el valor esperado del estimador respecto al parámetro objetivo θ .

Definición 7.3.2

El **sesgo de un estimador** puntual W , de un parámetro θ , es la diferencia entre el valor esperado de W y θ . Es decir, $\text{Sesgo}_{\theta}(W) = E_{\theta}[W] - \theta$. Un estimador cuyo sesgo es idénticamente (en θ) igual a cero se llama **insesgado** y satisface $E_{\theta}[W] = \theta$ para todo θ .

Para un estimador insesgado tenemos

$$E_{\theta}[(W - \theta)^2] = \text{Var}_{\theta}(W),$$

y por lo tanto, si un estimador es insesgado, su MSE es igual a su varianza.

Clase 9. Intervalos de confianza.

(referencias al pdf - varios puntos de bibliografía)

Nota: Un intervalo de confianza sirve para responder a una pregunta fundamental en estadística: ¿Cómo puedo estimar un valor real de toda una población si solo tengo una muestra de datos?

Distribuciones continuas fundamentales para la inferencia

Teniendo a $Z \sim N(0, 1)$ y construimos $X = \sum_{i=1}^k Z_i^2$, entonces $X = \chi^2$

Distribución Chi-Cuadrado (χ^2)

$$X \sim \chi_n^2$$

$$f(x) = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} x^{\frac{(k)}{2}-1} e^{-\frac{x}{2}} \text{ con } k \text{ “grados de libertad” y } \Gamma \text{ es la función gamma.}$$

$$E[X] = k$$

$$\text{Var}(X) = 2k$$

Distribución T de Student

$$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi\nu} \Gamma(\frac{\nu}{2})} \text{ con } \nu \text{ “grados de libertad” y } \Gamma \text{ es la función gamma.}$$

$$E[T] = 0 \text{ si } \nu > 1 \text{ (indefinido en otro caso pues Cauchy)} \quad \text{Var}(T) = \frac{\nu}{\nu-2} \text{ si } \nu > 2 \text{ (indefinida o infinita en otro caso)}$$

Nota: Los “grados de libertad” son:

En χ^2 : Representa cuántas normales Z^2 independientes se sumaron. En t de Student: Representa la precisión con la que se estimó la variabilidad muestral; a mayor número de grados de libertad, más se parece a la distribución Normal $N(0, 1)$.

Propiedades

A medida de que la ν de la distribución de Cauchy tiende al infinito, esta tiende a una distribución Normal.

Si $U \sim N(0, 1)$; $V \sim \chi_k^2$, construimos:

$$T = \frac{U}{\sqrt{\frac{V}{k}}} \text{ (} U \text{ y } V \text{ independientes), entonces}$$

$$T \sim \text{Student } (k)$$

Intervalos de confianza

Si $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ (muestra de distribución normal), entonces la media muestral $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ y construimos $U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$, entonces $U \sim N(0, 1)$ (normal estándar).

Similar a con una variable aleatoria puedo calcular la probabilidad de que U o $\bar{X}$ esté en un cierto intervalo:

$$P(-1,96 \leq U \leq 1,96) = 0,95$$

$$P\left(-1,96 \leq \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \leq 1,96\right) = 0,95$$

$$P\left(\mu - 1,96 \frac{\sigma}{\sqrt{n}} \leq \bar{X} \leq \mu + 1,96 \frac{\sigma}{\sqrt{n}}\right) = 0,95$$

Pero también se podría calcular la probabilidad:

$$P\left(\bar{X} - 1,96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1,96 \frac{\sigma}{\sqrt{n}}\right) = 0,95$$

O sea, el intervalo que tiene probabilidad 95% de incluir a μ en este.

Generalizado

Sea $X_1, \dots, X_n$ una muestra aleatoria de una distribución con parámetro θ . Dadas dos funciones de la muestra $a(X_1 \dots X_n)$ y $b(X_1 \dots X_n)$ tales que:

$$P(a(X_1 \dots X_n) \leq \theta \leq b(X_1 \dots X_n)) = 1 - \alpha$$

con α chico, entonces el intervalo $[a(X_1 \dots X_n); b(X_1 \dots X_n)]$ se denomina **intervalo de confianza de nivel $1 - \alpha$** para el parámetro θ .

Posibles interpretaciones:

- La probabilidad de que el intervalo de confianza contenga al valor de μ es 95% (en el mismo sentido de la probabilidad de cualquier variable aleatoria).
- Dados muchas realizaciones de la variable aleatoria “intervalo de confianza”, el 95% de ellas incluirá el valor de μ .

Desarrollo de los posibles casos para Población Normal

Dada una muestra aleatoria $X_1, \dots, X_n$ de una población $N(\mu, \sigma^2)$:

1. Parámetro μ con σ^2 conocida

- **Pivote:** $Z = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$
- **Fórmula del IC:**

$$IC_{1-\alpha}(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \right]$$

2. Parámetro μ con σ^2 desconocida

- **Pivote:** $T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$ donde $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$
- **Fórmula del IC:**

$$IC_{1-\alpha}(\mu) = \left[\bar{X} - t_{n-1, \frac{\alpha}{2}} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, \frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right]$$

3. Parámetro σ^2 con μ conocida

- **Pivote:** $V = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi_n^2$
- **Fórmula del IC:**

$$IC_{1-\alpha}(\sigma^2) = \left[\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{n, \frac{\alpha}{2}}^2}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{n, 1-\frac{\alpha}{2}}^2} \right]$$

4. Parámetro σ^2 con μ desconocida

- **Pivote:** $V = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$
- **Fórmula del IC:**

$$IC_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)S^2}{\chi_{n-1, \frac{\alpha}{2}}^2}, \frac{(n-1)S^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2} \right]$$

Resumen de Pivotes y Fórmulas de IC

Parámetro	Condición	Pivote	Distribución	Intervalo de Confianza (IC)
μ	σ^2 conocida	$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}$	$N(0, 1)$	$\bar{X} \pm z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}$
μ	σ^2 desconocida	$\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}$	t_{n-1}	$\bar{X} \pm t_{n-1, \frac{\alpha}{2}} \frac{S}{\sqrt{n}}$
σ^2	μ conocida	$\frac{\sum (X_i - \mu)^2}{\sigma^2}$	χ_n^2	$\left[\frac{\sum (X_i - \mu)^2}{\chi_{n, \frac{\alpha}{2}}^2}, \frac{\sum (X_i - \mu)^2}{\chi_{n, 1-\frac{\alpha}{2}}^2} \right]$
σ^2	μ desconocida	$\frac{(n-1)S^2}{\sigma^2}$	χ_{n-1}^2	$\left[\frac{(n-1)S^2}{\chi_{n-1, \frac{\alpha}{2}}^2}, \frac{(n-1)S^2}{\chi_{n-1, 1-\frac{\alpha}{2}}^2} \right]$

Método general para obtener el intervalo de confianza para un parámetro

Sea una muestra $X_1 \dots X_n$ de una distribución que depende de un parámetro θ . Supongamos que existe una función $T(X_1 \dots X_n, \theta)$ cuya distribución no depende de θ ni de ningún otro parámetro desconocido. Entonces dado α existen dos valores a y b tales que:

$$P(a \leq T(X_1 \dots X_n, \theta) \leq b) = 1 - \alpha$$

a partir de lo cual se puede obtener un intervalo de confianza de nivel $1 - \alpha$ para θ . La función $T(X_1 \dots X_n, \theta)$ se denomina “**pivote**”.

Intervalos de confianza asintóticos (Muestras Grandes)

Sea $X_1 \dots X_n$ una muestra aleatoria de una distribución desconocida con $E[X] = \mu$ y $\text{Var}(X) = \sigma^2$. Buscamos un intervalo de confianza para μ . Sabemos que la media muestral estima bien μ , pero no conocemos qué distribución tiene la media muestral. Sin embargo sabemos que:

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{d} N(0, 1)$$

Usemos S^2 para estimar σ^2 :

$$\sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{d} N(0, 1)$$

$$\frac{\sigma}{S} \xrightarrow{P} 1 \Rightarrow \sqrt{n} \frac{\bar{X} - \mu}{S} \xrightarrow{d} N(0, 1)$$

- **Fórmula del IC Asintótico:**

$$IC_{1-\alpha}(\mu) \approx \left[\bar{X} - z_{\frac{\alpha}{2}} \frac{S}{\sqrt{n}}, \bar{X} + z_{\frac{\alpha}{2}} \frac{S}{\sqrt{n}} \right]$$

Determinación del tamaño de una muestra

Tomemos una distribución normal con σ^2 conocida para ejemplificar. El semiancho (o margen de error E) del intervalo de confianza para el parámetro μ es:

$$E = z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}$$

Por lo tanto, la longitud total del intervalo es $L = 2E = 2z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}}$.

¿Qué tamaño de muestra necesito para asegurar un máximo largo L_0 del intervalo de confianza (o un margen de error máximo $E_0 = \frac{L_0}{2}$)?

$$L = 2z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}} \leq L_0 \Leftrightarrow \sqrt{n} \geq \frac{2z_{\alpha/2}\sigma_0}{L_0} \Leftrightarrow n \geq \left(\frac{2z_{\alpha/2}\sigma_0}{L_0} \right)^2$$

- **Fórmula resumida para el tamaño muestral n :**

$$n \geq \left(\frac{z_{\alpha/2}\sigma_0}{E_0} \right)^2$$

Clase 10. Contraste de Hipótesis

1. Conceptos Fundamentales

Hipótesis Nula (H_0): Es el “estado por defecto” o la idea de que todo funciona bien.

Hipótesis Alternativa (H_1): Es lo que querés probar o la sospecha de que algo anda mal.

Error estándar de un estimador La desviación estándar de la distribución muestral del estimador:

$$SE_{\hat{\theta}} = \sqrt{\text{Var}(\hat{\theta})}$$

Para la media muestral de $X \sim N(\mu, \sigma^2)$:

$$SE_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

Errores y Matriz de Confusión

Error Tipo I (α): Rechazar H_0 cuando H_0 es verdadera (falso positivo).

Error Tipo II (β): No rechazar H_0 cuando H_0 es falsa (falso negativo).

Potencia del Test ($1 - \beta$): Probabilidad de rechazar H_0 cuando esta es falsa (detectar el efecto real).

	H_0 es cierta	H_0 es falsa
--	-----------------	----------------

No se rechaza H_0	Decisión Correcta ($1 - \alpha$)	Error Tipo II (β)
Se rechaza H_0	Error Tipo I (α)	Decisión Correcta ($1 - \beta$)

2. Estructura de las Hipótesis

- **Unilateral derecha:** $H_0 : \theta \leq \theta_0$ vs $H_1 : \theta > \theta_0$
- **Unilateral izquierda:** $H_0 : \theta \geq \theta_0$ vs $H_1 : \theta < \theta_0$
- **Bilateral:** $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$

p-valor Es la probabilidad, asumiendo que la hipótesis nula H_0 es verdadera, de obtener un estadístico de prueba tan o más extremo que el valor observado t_{obs} :

p -valor = P_{H_0} (Estadístico tan o más extremo que t_{obs})

- **Test bilateral** (distribución simétrica, e.g., $Z \sim \mathcal{N}(0, 1)$): p -valor = $2c \cdot P(Z \geq |z_{\text{obs}}|) = 2c \cdot (1 - \Phi(|z_{\text{obs}}|))$
- **Test unilateral derecho:** p -valor = $P(Z \geq z_{\text{obs}}) = 1 - \Phi(z_{\text{obs}})$
- **Test unilateral izquierdo:** p -valor = $P(Z \leq z_{\text{obs}}) = \Phi(z_{\text{obs}})$
- **Regla de decisión universal:** Si p -valor $\leq \alpha \rightarrow$ Rechazo H_0 ; si p -valor $> \alpha \rightarrow$ No rechazo H_0 .

3. Tests Paramétricos para Distribución Normal $N(\mu, \sigma^2)$

Caso A: Test para μ con σ^2 conocida

Estadístico bajo H_0 :

$$Z = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0} \sim N(0, 1)$$

Región de Rechazo (Nivel α):

- $H_1 : \mu > \mu_0 \Rightarrow Z \geq z_\alpha$
- $H_1 : \mu < \mu_0 \Rightarrow Z \leq -z_\alpha$
- $H_1 : \mu \neq \mu_0 \Rightarrow |Z| \geq z_{\frac{\alpha}{2}}$

Caso B: Test para μ con σ^2 desconocida

Estadístico bajo H_0 :

$$T = \sqrt{n} \frac{\bar{X} - \mu_0}{S} \sim t_{n-1}$$

Región de Rechazo (Nivel α):

- $H_1 : \mu > \mu_0 \Rightarrow T \geq t_{n-1, \alpha}$
- $H_1 : \mu < \mu_0 \Rightarrow T \leq -t_{n-1, \alpha}$
- $H_1 : \mu \neq \mu_0 \Rightarrow |T| \geq t_{n-1, \frac{\alpha}{2}}$

Caso C: Test para σ^2 con μ desconocida

Estadístico bajo H_0 :

$$U = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2$$

Región de Rechazo (Nivel α):

- $H_1 : \sigma^2 > \sigma_0^2 \Rightarrow U \geq \chi_{n-1, \alpha}^2$
- $H_1 : \sigma^2 < \sigma_0^2 \Rightarrow U \leq \chi_{n-1, 1-\alpha}^2$

$$\bullet H_1 : \sigma^2 \neq \sigma_0^2 \Rightarrow U \geq \chi_{n-1, \frac{\alpha}{2}}^2 \text{ o } U \leq \chi_{n-1, 1-\frac{\alpha}{2}}^2$$

4. Relación con Intervalos de Confianza

Para un test bilateral $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$ de nivel α , se rechaza H_0 si y solo si θ_0 **no pertenece** al intervalo de confianza del $1 - \alpha$ para θ :

$$\theta_0 \notin \text{IC}^{1-\alpha} \iff \text{Se rechaza } H_0$$

5. Tamaño Muestral para Potencia Dada (Prueba Z Unilateral)

Para garantizar un nivel α y una probabilidad máxima de Error Tipo II de β ante un valor específico $\mu_1 \in H_1$:

$$n \geq \frac{((z_\alpha + z_\beta)\sigma_0)^2}{(\mu_1 - \mu_0)^2}$$

Nota: Cómo aumentar la potencia de un test ($1 - \beta$):

- Aumentar el tamaño de la muestra (n).
- Reducir la dispersión del estimador (σ).
- Aumentar el efecto/diferencia $|\mu_1 - \mu_0|$.
- Aumentar el nivel de significancia (α), asumiendo más falsos positivos.

6. Test para una Proporción Poblacional (1 Muestra)

Para n ensayos de Bernoulli con condición de validez asintótica ($np(1-p) \geq 5$):

Estadístico bajo $H_0 : p = p_0$:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \sim N(0, 1)$$

Región de Rechazo (Nivel α): Igual que en Caso A ($Z \geq z_\alpha$, $Z \leq -z_\alpha$, o $|Z| \geq z_{\frac{\alpha}{2}}$).

7. Comparación de Dos Poblaciones

Caso A: Muestras Apareadas / Dependientes (Mismos sujetos antes/después)

Se definen las diferencias individuales $D_i = X_{1,i} - X_{2,i}$. Se asume $D_i \sim N(\mu_D, \sigma_D^2)$.

Estadístico bajo $H_0 : \mu_D = 0$:

$$T = \sqrt{n} \frac{\bar{D}}{S_D} \sim t_{n-1}$$

donde $\bar{D}$ es la media de las diferencias y S_D es la desviación estándar muestral de D_i .

Caso B: Muestras Independientes para la Media ($\sigma_1^2 = \sigma_2^2$ desconocida)

Estadístico bajo $H_0 : \mu_1 - \mu_2 = 0$:

$$T = \frac{\bar{X}_1 - \bar{X}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}$$

donde la varianza amalgamada es $S_p^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}$.

Caso C: Test A/B de Proporciones (Muestras Independientes Grandes)

Estadístico bajo $H_0 : p_A = p_B$:

$$Z = \frac{\hat{p}_A - \hat{p}_B}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_A} + \frac{1}{n_B}\right)}} \sim N(0, 1)$$

donde la proporción combinada es $\hat{p} = \frac{x_A + x_B}{n_A + n_B}$.

8. Comparaciones Múltiples y Control de Errores

Al realizar N tests independientes de nivel α , la probabilidad de cometer al menos un Falso Positivo (FWER - **Family-Wise Error Rate**) aumenta:

$$P(\text{Al menos 1 FP}) = 1 - (1 - \alpha)^N$$

Corrección de Bonferroni (Controla FWER): Ajusta el nivel de significancia individual a $\alpha_i = \frac{\alpha}{N}$. Es un método muy conservador que reduce la potencia del test ($1 - \beta$).

Procedimiento de Benjamini-Hochberg (Controla FDR - False Discovery Rate): Ordena los N p-valores de menor a mayor: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(N)}$. Encuentra el mayor índice k tal que:

$$p_{(k)} \leq \left(\frac{k}{N}\right)q$$

y se rechazan las k hipótesis asociadas a los menores p-valores (donde q es la tasa de falsos descubrimientos deseada).

9. Interpretación: Significancia Estadística vs. Tamaño del Efecto

- **Efecto Trivial:** Una diferencia tan pequeña que no tiene relevancia práctica o de negocio (ej. mejorar 0.001 ms).
- **Efecto Relevante:** Un intervalo de confianza que cae fuera de la banda de trivialidad (ej. $(-10, 10)$).
- **Cuidado con el n gigante:** Un tamaño muestral $n \rightarrow \infty$ vuelve significativo (p -valor $< \alpha$) a cualquier efecto, incluso si es trivial. Siempre debe analizarse el **intervalo de confianza** junto al p-valor.

Clase 11. Otros contrastes comunes. Comparaciones múltiples.

Acá en las referencias del Cetinkaya-Rundel & Hardin 2024 tengan en cuenta que esos capítulos están organizados con una primera sección de Bootstrapping (que todavía no vimos) pero las secciones que siguen se entienden sin eso.

Capítulo 16 (Cetinkaya)

Comparación de una proporción con un valor de hipótesis nula

Capítulo 17 (Cetinkaya)

Comparar dos proporciones

Capítulo 19 (Cetinkaya)

Comparar la media con un valor de hipótesis nula

Capítulo 20 (Cetinkaya)

Comparar las medias de dos muestras independientes

Capítulo 21 (Cetinkaya)

Comparar las medias de dos muestras pareadas

Ejemplo 11.2.9 (Casella Berger 2024)

Comparaciones múltiples: corrección de Bonferroni.

Clase 12. Regresión lineal simple.

(referencias a Casella Berger 2024)

Sección 11.3

Regresión lineal simple

Sección 11.3.1

Cuadrados mínimos

Sección 11.3.3.1

Modelo normal condicional

Sección 11.3.4

Estimación por máxima verosimilitud, contrastes e intervalos de confianza

Sección 11.3.6

Estimaciones e intervalos de confianza simultáneos

Tabla de la Distribución Normal Estándar Acumulada $\Phi(z)$. p es el area acumulada debajo de la curva y Z_p es el punto del eje x hasta donde se acumula la curva.

Z_p	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Distribución t de Student

La tabla A.4 da distintos valores de la función de distribución en relación con el número de grados de libertad; concretamente, relaciona los valores p y $t_{n;p}$ que satisfacen: $P(t_n \leq t_{n;p}) = p$.

n	$t_{0,55}$	$t_{0,60}$	$t_{0,70}$	$t_{0,80}$	$t_{0,90}$	$t_{0,95}$	$t_{0,975}$	$t_{0,99}$	$t_{0,995}$
1	0,1584	0,3249	0,7265	1,3764	3,0777	6,3138	12,7062	31,8205	63,6567
2	0,1421	0,2887	0,6172	1,0607	1,8856	2,9200	4,3027	6,9646	9,9248
3	0,1366	0,2767	0,5844	0,9785	1,6377	2,3534	3,1824	4,5407	5,8409
4	0,1338	0,2707	0,5686	0,9410	1,5332	2,1318	2,7764	3,7469	4,6041
5	0,1322	0,2672	0,5594	0,9195	1,4759	2,0150	2,5706	3,3649	4,0321
6	0,1311	0,2648	0,5534	0,9057	1,4398	1,9432	2,4469	3,1427	3,7074
7	0,1303	0,2632	0,5491	0,8960	1,4149	1,8946	2,3646	2,9980	3,4995
8	0,1297	0,2619	0,5459	0,8889	1,3968	1,8595	2,3060	2,8965	3,3554
9	0,1293	0,2610	0,5435	0,8834	1,3830	1,8331	2,2622	2,8214	3,2498
10	0,1289	0,2602	0,5415	0,8791	1,3722	1,8125	2,2281	2,7638	3,1693
11	0,1286	0,2596	0,5399	0,8755	1,3634	1,7959	2,2010	2,7181	3,1058
12	0,1283	0,2590	0,5386	0,8726	1,3562	1,7823	2,1788	2,6810	3,0545
13	0,1281	0,2586	0,5375	0,8702	1,3502	1,7709	2,1604	2,6503	3,0123
14	0,1280	0,2582	0,5366	0,8681	1,3450	1,7613	2,1448	2,6245	2,9768
15	0,1278	0,2579	0,5357	0,8662	1,3406	1,7531	2,1314	2,6025	2,9467
16	0,1277	0,2576	0,5350	0,8647	1,3368	1,7459	2,1199	2,5835	2,9208
17	0,1276	0,2573	0,5344	0,8633	1,3334	1,7396	2,1098	2,5669	2,8982
18	0,1274	0,2571	0,5338	0,8620	1,3304	1,7341	2,1009	2,5524	2,8784
19	0,1274	0,2569	0,5333	0,8610	1,3277	1,7291	2,0930	2,5395	2,8609
20	0,1273	0,2567	0,5329	0,8600	1,3253	1,7247	2,0860	2,5280	2,8453
21	0,1272	0,2566	0,5325	0,8591	1,3232	1,7207	2,0796	2,5176	2,8314
22	0,1271	0,2564	0,5321	0,8583	1,3212	1,7171	2,0739	2,5083	2,8188
23	0,1271	0,2563	0,5317	0,8575	1,3195	1,7139	2,0687	2,4999	2,8073
24	0,1270	0,2562	0,5314	0,8569	1,3178	1,7109	2,0639	2,4922	2,7969
25	0,1269	0,2561	0,5312	0,8562	1,3163	1,7081	2,0595	2,4851	2,7874
26	0,1269	0,2560	0,5309	0,8557	1,3150	1,7056	2,0555	2,4786	2,7787
27	0,1268	0,2559	0,5306	0,8551	1,3137	1,7033	2,0518	2,4727	2,7707
28	0,1268	0,2558	0,5304	0,8546	1,3125	1,7011	2,0484	2,4671	2,7633
29	0,1268	0,2557	0,5302	0,8542	1,3114	1,6991	2,0452	2,4620	2,7564
30	0,1267	0,2556	0,5300	0,8538	1,3104	1,6973	2,0423	2,4573	2,7500
40	0,1265	0,2550	0,5286	0,8507	1,3031	1,6839	2,0211	2,4233	2,7045
50	0,1263	0,2547	0,5278	0,8489	1,2987	1,6759	2,0086	2,4033	2,6778
60	0,1262	0,2545	0,5272	0,8477	1,2958	1,6706	2,0003	2,3901	2,6603
80	0,1261	0,2542	0,5265	0,8461	1,2922	1,6641	1,9901	2,3739	2,6387
100	0,1260	0,2540	0,5261	0,8452	1,2901	1,6602	1,9840	2,3642	2,6259
120	0,1259	0,2539	0,5258	0,8446	1,2886	1,6577	1,9799	2,3578	2,6174
∞	0,126	0,253	0,524	0,842	1,282	1,645	1,960	2,327	2,576

Tabla A.4: Tabla de la distribución t de Student.

Tabla resumen de tests estadísticos

Estadística Computacional — 2C 2026

Qué se contrasta	Estadístico	Bajo H_0	Supuestos
Media, σ conocida $H_0 : \mu = \mu_0$	$\frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$	$\mathcal{N}(0, 1)$	Normalidad, o n grande por TCL
Media, σ desconocida $H_0 : \mu = \mu_0$	$\frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$	t_{n-1}	Normalidad; con n chico es un supuesto real, no una aproximación
Proporción $H_0 : p = p_0$	$\frac{\hat{p} - p_0}{\sqrt{p_0 \frac{1-p_0}{n}}}$	$\mathcal{N}(0, 1)$ aprox.	$np_0 \geq 10$ y $n(1 - p_0) \geq 10$; ensayos independientes
Varianza $H_0 : \sigma = \sigma_0$	$\frac{(n-1)S^2}{\sigma_0^2}$	χ_{n-1}^2	Normalidad, y acá es crítica : a diferencia del t , este test no es robusto
Dos medias, pareadas $H_0 : \mu_D = 0$	$\frac{\bar{D}}{\frac{S_D}{\sqrt{n}}}$	t_{n-1}	$D_i = X_i - Y_i$ sobre las mismas <i>unidades</i> ; normalidad de las <i>diferencias</i>
Dos medias, independientes $H_0 : \mu_X = \mu_Y$	$\frac{\bar{X} - \bar{Y}}{S_P \sqrt{\frac{1}{n} + \frac{1}{m}}}$	t_{n+m-2}	Normalidad, varianzas iguales , y grupos independientes entre sí
Dos proporciones $H_0 : p_1 = p_2$	$\frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$	$\mathcal{N}(0, 1)$ aprox.	Al menos 10 éxitos y 10 fracasos en cada grupo

$$S_P^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2} \quad \hat{p} = \frac{X_1 + X_2}{n_1 + n_2} \text{ (proporción combinada de los dos grupos)}$$