

Clase 1. Teoría de conjuntos, espacio muestral, eventos, probabilidad.

(referencias a Casella Berger 2024)

Definición 1.1.1

El conjunto S de todos los posibles resultados de un experimento se llama **espacio muestral**.

Definición 1.1.2

Un **evento** es una colección de posibles resultados de un experimento, o sea, un subconjunto de S (incluyendolo a S). Relaciones de inclusión e igualdad.

Teorema 1.1.4

Para cualesquiera tres eventos, A , B y C , definidos en un espacio muestral S ,

a) Commutativity

$$\begin{aligned}A \cup B &= B \cup A, \\A \cap B &= B \cap A;\end{aligned}$$

b) Associativity

$$\begin{aligned}A \cup (B \cap C) &= (A \cup B) \cap C, \\A \cap (B \cup C) &= (A \cap B) \cup C;\end{aligned}$$

c) Distributive Laws

$$\begin{aligned}A \cap (B \cup C) &= (A \cap B) \cup (A \cap C), \\A \cup (B \cap C) &= (A \cup B) \cap (A \cup C);\end{aligned}$$

d) DeMorgan's Laws

$$(A \cup B)^c = A^c \cap B^c, (A \cap B)^c = A^c \cup B^c.$$

Definición 1.1.5

Dos eventos A y B son **disjuntos (o mutuamente exclusivos)** si $A \cap B = \emptyset$. Estos eventos $A_1, A_2, \dots$ son **disjuntos de a pares (o mutuamente exclusivos)** si $A_i \cap A_j = \emptyset \forall i \neq j$.

Definición 1.1.6

Si $A_1, A_2, \dots$ son disjuntos de a pares, $A_i \neq \emptyset$ y $\bigcup_{i=1}^{\infty} A_i = S$, entonces la colección $A_1, A_2, \dots$ forman una **partición** de S .

Definición 1.2.1

Una colección de subconjuntos de S se lo llama **sigma-algebra (campo de Borel o álgebra de Borel)**, denotada $\mathcal{B}$, si satisface las siguientes propiedades:

- a) $\emptyset \in \mathcal{B}$ (el conjunto vacío es un elemento de $\mathcal{B}$).
- b) Si $A \in \mathcal{B}$, entonces $A^c \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para complemento).
- c) Si $A_1, A_2, \dots \in \mathcal{B}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para uniones numerables).

Definición 1.2.4

Dado un espacio muestral S y un campo de Borel asociado $\mathcal{B}$, una **función de probabilidad** es una función P con dominio $\mathcal{B}$ que satisface los **axiomas de probabilidad**:

1. $P(A) \geq 0 \forall A \in \mathcal{B}$.
2. $P(S) = 1$.

3. Si $A_1, A_2, \dots \in \mathcal{B}$ son mutuamente exclusivos, entonces $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$.

Teorema 1.2.6

Sea $S = \{s_1, \dots, s_n\}$ un conjunto finito. Sea $\mathcal{B}$ un campo de Borel de subconjuntos de S . Sean $p_1, \dots, p_n$ números no-negativos que sumen uno. Para cualquier $A \in \mathcal{B}$, se define $P(A)$ como

$$P(A) = \sum_{\{i: s_i \in A\}} p_i$$

Teorema 1.2.8

Si P es una función de probabilidad y A es algún conjunto en $\mathcal{B}$, entonces

- a) $P(\emptyset) = 0$.
- b) $P(A) \leq 1$.
- c) $P(A^c) = 1 - P(A)$.

Teorema 1.2.9

Si P es una función de probabilidad y A y B son conjuntos en $\mathcal{B}$, entonces

- a) $P(B \cap A^c) = P(B) - P(A \cap B)$.
- b) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.
- c) Si $A \subset B$ entonces $P(A) \leq P(B)$.

Clase 2. Bonferroni, conteo, probabilidad condicional e independencia.

(referencias a Casella Berger 2024)

Teorema 1.2.11

Si P es una función de probabilidad, entonces

- a) $P(A) = \sum_{i=1}^{\infty} P(A \cap C_i)$ para cualquier partición $C_1, C_2, \dots$ **probabilidad total**
- b) $P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$ para cualesquiera conjuntos $A_1, A_2, \dots$ **probabilidad de Boole / desigualdad de Boole**

Ecuación 1.2.10

La **desigualdad de Bonferroni**:

$$P(A \cap B) \geq P(A) + P(B) - 1$$

La **generalización de Bonferroni** es:

$$P\left(\bigcap_{i=1}^n A_i\right) \geq \sum_{i=1}^n P(A_i) - (n-1)$$

Teorema 1.2.14

Si un trabajo consiste en k tareas separadas, de las cuales la i -ésima puede resolverse de n_i maneras, $i = 1, \dots, k$, entonces el trabajo completo puede hacerse en $n_1 \times n_2 \times \dots \times n_k$ formas.

Definición 1.2.17

Para números no negativos n y r , $n \geq r$, definimos el **número combinatorio** $\binom{n}{r}$, leído como elegir r de n , como

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}$$

Tabla 1.2.1

Resumen de los cuatro casos básicos de conteo.

	Sin reemplazo	Con reemplazo
Con orden	$\frac{n!}{(n-r)!}$	n^r
Sin orden	$\binom{n}{r}$	$\binom{n+r-1}{r}$

Definición 1.3.2

Si A y B son eventos en S , y $P(B) > 0$, entonces la **probabilidad condicional** de un A dado B , escrito como $P(A|B)$, es

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Ecuación 1.3.3

$$P(A \cap B) = P(A|B)P(B)$$

Ecuación 1.3.4

$$P(A \cap B) = P(B|A)P(A)$$

Ecuación 1.3.5

Regla de Bayes para dos eventos.

$$P(A|B) = P(B|A) \frac{P(A)}{P(B)}$$

Teorema 1.3.5

Regla de Bayes generalizada. Sea $A_1, A_2, \dots$ una partición del espacio muestral, y sea B cualquier conjunto, para cada $i = 1, 2, \dots$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{\infty} P(B|A_j)P(A_j)}$$

Definición 1.3.7

Dos eventos, A y B , son **estadísticamente independientes** si

$$P(A \cap B) = P(A)P(B)$$

Esto implica que:

$$P(A|B) = P(A)$$

Teorema 1.3.9

Si A y B son eventos independientes, entonces los siguientes pares también:

a) A y B^c

b) A^c y B

c) A^c y B^c

Definición 1.3.12

Una colección de eventos $A_1, \dots, A_n$ son **mutuamente independientes** si para cualquier subcolección $A_{i_1}, \dots, A_{i_k}$, se cumple que la probabilidad de la intersección es igual a la factorización de las probabilidades:

$$P\left(\bigcap_{j=1}^k A_{i_j}\right) = \prod_{j=1}^k P(A_{i_j})$$

Clase 3. Variables aleatorias.

(referencias a Casella Berger 2024)

Variables aleatorias

Definición 1.4.1

Una **variable aleatoria** es una función de un espacio muestral S a los números reales.

Ecuación 1.4.1

P_X es una función de probabilidad inducida en $\mathcal{X} = \{x_1, \dots, x_m\}$. Definida en los términos de la función original P .

$$P_X(X = x_i) = P(\{s_j \in S : X(s_j) = x_i\})$$

Definición 1.5.1

La **función de distribución acumulada, o fda**, de una variable aleatoria X , donotada como $F_{X(x)}$, es definida por

$$F_X(x) = P_X(X \leq x), \forall x$$

Teorema 1.5.3

La función $F(x)$ es una fda si y solo si las siguientes condiciones se cumplen:

- a) $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow \infty} F(x) = 1$.
- b) $F(x)$ es una función no decreciente de x .
- c) $F(x)$ es continua a la derecha. O sea, para todo número x_0 , $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$.

Definición 1.5.7

Una variable aleatoria X es **continua** si $F_X(x)$ es una función continua de x .

Una variable aleatoria X es **discreta** si $F_X(x)$ es una función escalonada (o en escalera / step function).

Definición 1.5.8

Las variables aleatorias X e Y son **idénticamente distribuidas** si, por cada conjunto $A \in \mathcal{B}$, $P(X \in A) = P(Y \in A)$

Teorema 1.5.10

Las siguientes declaraciones son equivalentes:

- a) Las variables aleatorias X e Y son idénticamente distribuidas.
- b) $F_X(x) = F_Y(x), \forall x$.

Definición 1.6.1

La **función de probabilidad puntual (fpp)** de una variable aleatoria discreta X es dada por

$$f_X(x) = P(X = x)$$

Ecuación 1.6.1

Relación entre fdp y fda (variable discreta)

$$F_X(x) = \sum_{i=1}^x f_X(i)$$

Ecuación 1.6.2

Relación entre fdp y fda (variable continua).

$$\frac{d}{dx} F_X(x) = f_X(x)$$

Definición 1.6.3

La **función de densidad de probabilidad (fdp)**, $f_X(x)$, de una variable aleatoria continua X es la función que satisface

$$F_X(x) = \int_{-\infty}^x f_X(t) dt \quad \forall x$$

Teorema 1.6.5

Una función $f_X(x)$ es fdp o fpp, de una variable aleatoria X si y solo si

- a) $f_X(x) \geq 0 \quad \forall x$.
- b) $\sum_x f_X(x) = 1$ (fpp) o $\int_{-\infty}^{\infty} f_X(x) dx = 1$ (fdp)

Valor esperado**Definición 2.2.1**

El **valor esperado (esperanza)** de una variable aleatoria $g(X)$, denotado por $E[g(X)]$, es

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx & X \text{ continua} \\ \sum_{x \in \mathcal{X}} g(x) f_X(x) = \sum_{x \in \mathcal{X}} g(x) P(X = x) & X \text{ discreta} \end{cases}$$

dado que la integral o suma exista. Si $E[g(X)] = \infty$, decimos que $E[g(X)]$ no existe.

Valor esperado de la variable: **valor medio**.

$$g(X) = X$$

Valor esperado de las distancias cuadráticas con respecto al valor medio: **varianza**.

$$\text{Var}(X) = E[(X - E(X))^2]$$

Teorema 2.2.5

Sea X una variable aleatoria y sean a , b y c constantes. Entonces para funciones cualesquiera $g_1(x)$ y $g_2(x)$ donde sus esperanzas existen, se cumple que

- a) $E[ag_1(X) + bg_2(X) + c] = aE[g_1(X)] + bE[g_2(X)] + c$
- b) Si $g_1(x) \geq 0$ para todo x , entonces $E[g_1(X)] \geq 0$.
- c) Si $g_1(x) \geq g_2(x)$ para todo x , entonces $E[g_1(X)] \geq E[g_2(X)]$.

d) Si $a \leq g_1(x) \leq b$ para todo x , entonces $a \leq E[g_1(X)] \leq b$.

Teorema 2.3.4

Si X es una variable aleatoria con varianza finita, entonces para cualesquiera constantes a y b ,

$$\text{Var}(aX + b) = a^2 \text{Var}X$$

Clase 4. Distribuciones discretas y continuas.

(referencias a Casella Berger 2024 y al resumen de distribuciones de la práctica)

Familias comunes de distribuciones discretas

Ecuación 3.2.1

Distribución uniforme discreta.

$X \sim U(1, N)$ si $P(X = x | N) = \frac{1}{N}$ ($x = 1, 2, \dots, N$)

$$E[X] = \sum_{x=1}^N xP(X = x | N) = \frac{N+1}{2}$$

$$\text{Var}(X) = \frac{(N+1)(N-1)}{12}$$

Ecuación 3.2.3

Distribución de Bernoulli (ensayo de Bernoulli).

$X \sim \text{Bernoulli}(p)$ si $x = \begin{cases} 1 \text{ con probabilidad } p \\ 0 \text{ con probabilidad } (1-p) \end{cases}$ ($0 \leq p \leq 1$)

$$E[X] = p$$

$$\text{Var}(X) = p(1-p)$$

Teorema 3.2.2

Distribución binomial. Supongamos n ensayos de Bernoulli independientes e $Y =$ número de éxitos en n ensayos. Modela el número de éxitos en n ensayos independientes, cada uno con probabilidad de éxito p .

$Y \sim \text{Bin}(n, p)$ si $P(Y = y | n, p) = \binom{n}{y} p^y (1-p)^{n-y}$

$$E[Y] = np$$

$$\text{Var}(Y) = np(1-p)$$

Ecuación 3.2.5

Distribución de Poisson. Modela el número de eventos (raros e independientes) que ocurren en un intervalo fijo de tiempo o espacio.

$X \sim \text{Poisson}(\lambda)$ si $P(X = x | \lambda) = \frac{e^{-\lambda} \lambda^x}{x!}$, ($x = 0, 1, \dots$)

$$E[X] = \lambda$$

$$\text{Var}(X) = \lambda$$

Ecuaciones 3.2.6 3.2.7

Relaciones de recursión (binomial y Poisson)

$X \sim \text{Poisson}(\lambda) \Rightarrow P(X = x) = \frac{\lambda}{x} P(X = x - 1)$, ($x = 1, 2, \dots$)

$Y \sim \text{Bin}(n, p) \Rightarrow P(Y = y) = \frac{(n-y+1)p}{y(1-p)} P(Y = y - 1)$

Ecuación 3.2.11

Distribución geométrica.

$X =$ número de ensayos de Bernoulli hasta el primer éxito.

$X \sim \text{Geom}(p)$ si $P(X = x | p) = (1-p)^{x-1}$, ($x = 1, 2, \dots$)

$$E[X] = \frac{1}{p}$$

$$\text{Var}(X) = \frac{1-p}{p^2}$$

Propiedad “sin memoria”.

$$P(X > s | X > t) = P(X > s - t), \quad (s > t)$$

La probabilidad de obtener una secuencia de fracasos no depende de la posición en la tira, solo del largo de la secuencia.

Ecuación 3.2.9

Distribución binomial negativa. Modela el número de ensayos necesarios hasta obtener el r -ésimo éxito.

$p_X(k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}$, ($k = r, r + 1, \dots$), ($0 < p < 1$)

$$E[X] = \frac{r}{p}$$

$$\text{Var}(Y) = \frac{r(1-p)}{p^2}$$

Ecuación 3.2.2

Distribución hipergeométrica. Modela el número de elementos “buenos” al extraer una muestra de tamaño m sin reposición de una población finita de tamaño N con r buenos.

$$p_X(k) = \frac{\binom{r}{k} \binom{N-r}{m-k}}{\binom{N}{m}}, \quad \max(r+m-N, 0) \leq k \leq \min(r, m)$$

$$E[X] = m \frac{r}{N}$$

$$\text{Var}(X) = m \frac{r}{N} \frac{N-r}{N} \frac{N-m}{N-1}$$

Familias comunes de distribuciones continuas

Ecuación 3.3.1

Distribución uniforme continua.

$$X \sim U[a, b]$$

$$f(x) = \frac{1}{(b-a)} \mathbb{1}_{[a,b]}(x)$$

$$E[X] = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{(b-a)^2}{12}$$

$$U[0, 1] = \beta(1, 1)$$

Ecuación 3.3.13

Distribución normal.

$$X \sim N(\mu, \sigma^2)$$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/2\sigma^2}, \quad \sigma > 0$$

$$E[X] = \mu$$

$$\text{Var}(X) = \sigma^2$$

$$\text{Normal estándar: } N(0, 1)$$

Ecuación 3.3.6

Distribución gamma.

$$X \sim \Gamma(\alpha, \lambda)$$

$$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda, \alpha > 0$$

$$E[X] = \frac{\alpha}{\lambda}$$

$$\text{Var}(X) = \frac{\alpha}{\lambda^2}$$

$$\Gamma(1) = 1, \quad \Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1), \quad \Gamma(n) = (n-1)!, \quad \Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$$

Ecuación 3.3.16 3.3.17

Distribución Beta.

$$X \sim \beta(a, b)$$

$$f_X(x) =$$

$$\frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} \mathbb{1}_{(0,1)}(x), \quad a, b > 0$$

$$E[X] = \frac{a}{a+b}$$

$$\text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$$

Relación con la función gamma

$$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

Ecuación 3.3.11

Distribución exponencial.

$$X \sim \text{Exp}(\lambda)$$

$$f_X(x) = \lambda e^{-\lambda x} \mathbb{1}_{(0,\infty)}(x), \quad \lambda > 0$$

$$E[X] = \frac{1}{\lambda}$$

$$\text{Var}(X) = \frac{1}{\lambda^2}$$

Parametrización alternativa.

$$\text{Exp}(\lambda) = \Gamma(1, \lambda)$$

Ecuación 3.3.19

Distribución de Cauchy.

$$X \sim C(0, \lambda)$$

$$f_X(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + x^2}, \quad \lambda > 0$$

No tiene esperanza definida. $C(0, 1) = t_1$

Otras

T de Student

$$X \sim t_n$$

$$f_X(x) = \frac{\Gamma(\frac{n+1}{2})}{\Gamma(\frac{n}{2})\sqrt{\pi n}} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}$$

$$E(X) = 0$$

$$\text{Var}(X) = 2n$$

Chi cuadrado

$$X \sim \chi_n^2$$

$$\chi_n^2 = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right), n \in \mathbb{N}$$

$$E[X] = n$$

$$\text{Var}(X) = 2n$$

F de Snedecor

$$X \sim F_{n,m}$$

$$f_X(x) =$$

$$\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \left(\frac{n}{m}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} \left(1 + \frac{n}{m}x\right)^{-\frac{m+n}{2}} \mathbb{1}_{((0,\infty))}(x)$$

Propiedades más usadas

- $X \sim \text{Bi}(n, p), Y \sim \text{Bi}(m, p)$ independientes
 $\Rightarrow X + Y \sim \text{Bi}(n + m, p)$.
- $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ independientes
 $\Rightarrow X + Y \sim P(\lambda_1 + \lambda_2)$.
- $\text{Bi}(n, p) \approx P(\lambda)$ con $\lambda = np$ cuando $p \ll 1$.

- $H(N, r, m) \approx \text{Bi}(m, \frac{r}{N})$ cuando N es grande y $m \ll N$.
 - $X \sim N(\mu, \sigma^2) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0, 1)$ (estandarización).
 - $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ independientes $\Rightarrow aX + bY + c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$.
 - $X \sim \Gamma(\alpha, \lambda) \Rightarrow cX \sim \Gamma(\alpha, \frac{\lambda}{c})$.
 - $Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi_1^2$.
-

Clase 5. Transformación de variables aleatorias.

(referencias a Casella Berger 2024)

Transformaciones de variables aleatorias

Ecuación 2.1.1

Función de una variable aleatoria. Si X es una variable aleatoria con fda $F_X(x)$, entonces cualquier función de X , digamos $g(X)$ también es una variable aleatoria.

$$P(Y \in A) = P(g(X) \in A)$$

$g(X)$ define un mapa desde el espacio muestral original (X) al transformado (Y).

$\mathcal{X}$ soporte de X

$\mathcal{Y}$ soporte de Y

(**soporte** es el conjunto de puntos x donde la función de probabilidad puntual (fpp) es estrictamente mayor que cero.)

$$g(x) : \mathcal{X} \rightarrow \mathcal{Y}$$

Lo definimos por la inversa:

$$g^{-1}(\{y\}) = \{x \in \mathcal{X} : g(x) = y\}$$

$$Y = g(X)$$

Podemos escribir entonces para cualquier conjunto $A \subset \mathcal{Y}$:

$$\begin{aligned} P(Y \in A) &= P(g(X) \in A) \\ &= P(\{x \in \mathcal{X} : g(x) \in A\}) \\ &= P(X \in g^{-1}(A)). \end{aligned}$$

Ecuación 2.1.4, 2.1.8, 2.1.9

Función de distribución acumulada de una variable transformada. X e Y variables aleatorias continuas, calculemos la fda de $Y = g(X)$:

$$\begin{aligned}
F_Y(y) &= P(Y \leq y) \\
&= P(g(X) \leq y) \\
&= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\
&= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x) dx.
\end{aligned}$$

Región de integración de la probabilidad de una transformación.

Si g es creciente implica que:

$$\begin{aligned}
\{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \leq g^{-1}(y)\} \\
&= \{x \in \mathcal{X} : x \leq g^{-1}(y)\}.
\end{aligned}$$

Si g es decreciente implica que:

$$\begin{aligned}
\{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \geq g^{-1}(y)\} \\
&= \{x \in \mathcal{X} : x \geq g^{-1}(y)\}.
\end{aligned}$$

Con esto podemos escribir que, si es creciente $g(x)$:

$$F_Y(y) = \int_{\{x \in \mathcal{X} : x \leq g^{-1}(y)\}} f_X(x) dx = \int_{-\infty}^{g^{-1}(y)} f_X(x) dx = F_X(g^{-1}(y)).$$

Si $g(x)$ es decreciente, tenemos

$$F_Y(y) = \int_{g^{-1}(y)}^{\infty} f_X(x) dx = 1 - F_X(g^{-1}(y)).$$

Teorema 2.1.3

Función de distribución acumulada de una transformación. Sea X una variable aleatoria con fda $F_X(x)$, sea $Y = g(X)$, y sean $\mathcal{X}$ e $\mathcal{Y}$ definidos como $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x) \text{ para algún } x \in \mathcal{X}\}$.

- Si g es una función creciente en $\mathcal{X}$, $F_Y(y) = F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.
- Si g es una función decreciente en $\mathcal{X}$ y X es una variable aleatoria continua, $F_Y(y) = 1 - F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.

Teorema 2.1.5

Función de densidad de probabilidad de una transformación.

Sea X una variable aleatoria con fdp $f_X(x)$ y sea $Y = g(X)$, donde g es una función monótona. Sean $\mathcal{X}$ y $\mathcal{Y}$ definidos como en el Teorema 2.1.3. Supongamos que $f_X(x)$ es continua en $\mathcal{X}$ y que $g^{-1}(y)$ tiene derivada continua en $\mathcal{Y}$. Entonces la fdp de Y está dada por:

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| & y \in \mathcal{Y}, \\ 0 & \text{si no} \end{cases}$$

Teorema 2.1.10

Transformación integral de probabilidad.

Tenga X una fda continua $F_X(x)$ y definimos la variable aleatoria Y como $Y = F_X(X)$. Entonces Y esta uniformemente distribuida en $(0, 1)$, o sea, $P(Y \leq y) = y$, $0 < y < 1$.

Demo de Teorema 2.1.10: Para $Y = F_X(X)$ tenemos que, para $0 < y < 1$,

$$\begin{aligned}
 P(Y \leq y) &= P(F_X(X) \leq y) \\
 &= P(F_X^{-1}[F_X(X)] \leq F_X^{-1}(y)) \quad (F_X^{-1} \text{ es creciente}) \\
 &= P(X \leq F_X^{-1}(y)) \quad (\text{propiedad de } F_X^{-1}) \\
 &= F_X(F_X^{-1}(y)) \quad (\text{definición de } F_X) \\
 &= y. \quad (\text{continuidad de } F_X)
 \end{aligned}$$

Clase 6. Distribuciones conjuntas.

(referencias a Casella Berger 2024)

Teorema 3.6.1

Desigualdad de Markov / Chebychev. Sea X una variable aleatoria y $g(X) \geq 0$. Entonces, para cualquier $r > 0$:

$$P(g(X) \geq r) \leq \frac{E[g(X)]}{r}$$

Demo:

$$\begin{aligned}
 E[g(X)] &= \int_{-\infty}^{\infty} g(x) f_X(x) dx \\
 &\geq \int_{\{x: g(x) \geq r\}} g(x) f_X(x) dx \quad (g \text{ es no negativa}) \\
 &\geq r \int_{\{x: g(x) \geq r\}} f_X(x) dx \\
 &= r P(g(X) \geq r). \quad (\text{definición})
 \end{aligned}$$

Reacomodando ahora da la inecuación deseada.

Distribuciones conjuntas

Definición 4.1.1

Un **vector aleatorio n-dimensional** es una función de un espacio muestral S en $\mathbb{R}^2$, un espacio Euclidiano n-dimensional.

Definición 4.1.3

Sea (X, Y) un vector aleatorio bivariado discreto. Entonces la función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ definida por $f(x, y) = P(X = x, Y = y)$ se la llama la **función de probabilidad puntual conjunta / fpp conjunta** de (X, Y) . Si es necesario reafirmar que f es la fpp conjunta del vector (X, Y) en vez de ser de otro vector, la notación que se usa es $f_{X,Y}(x, y)$

La fpp conjunta puede ser usada para computar la probabilidad de cualquier evento definido en términos de (X, Y) . Sea A un subconjunto de $\mathbb{R}^2$. Entonces,

$$P((X, Y) \in A) = \sum_{(x,y) \in A} f(x, y).$$

El valor esperado es,

$$E[g(X, Y)] = \sum_{(x, y) \in \mathbb{R}^2} g(x, y) f(x, y).$$

Propiedades:

Sean $g_1(x, y)$ y $g_2(x, y)$ funciones y a, b y c constantes:

- $E[ag_1(x, y) + bg_2(x, y) + c] = aE[g_1(x, y)] + bE[g_2(x, y)] + c$
- $f(x, y) \geq 0$ para todo x, y
- $\sum_{(x, y) \in \mathbb{R}^2} f(x, y) = 1$

Teorema 4.1.6

Sea (X, Y) un vector aleatorio bivariado discreto con fpp conjunta $f_{X,Y}(x, y)$. Entonces, la **función de probabilidad puntual marginal/ fpp marginal** de X e Y , $f_X(x) = P(X = x)$ y $f_Y(y) = P(Y = y)$, son dadas por,

$$f_X(x) = \sum_{y \in \mathbb{R}} f_{X,Y}(x, y) \quad \text{y} \quad f_Y(y) = \sum_{x \in \mathbb{R}} f_{X,Y}(x, y).$$

Definición 4.1.10

Una función $f(x, y)$ de $\mathbb{R}^2 \rightarrow \mathbb{R}$ se la llama **función de densidad de probabilidad conjunta para un vector bidimensional continuo** (X, Y) si, por cada $A \subset \mathbb{R}^2$,

$$P((X, Y) \in A) = \iint_A f(x, y) dx dy.$$

Ecuación 4.1.1

Valor esperado de una función de dos variables continuas.

Sea $g(X, Y) \in \mathbb{R}$

$$E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy.$$

Ecuación 4.1.2

Funciones de densidad de probabilidad marginales para variables continuas.

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy, \quad -\infty < x < \infty,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx, \quad -\infty < y < \infty.$$

Ecuación 4.1.3

Función de distribución acumulada conjunta para variables continuas.

$$F(x, y) = P(X \leq x, Y \leq y)$$

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(s, t) dt ds.$$

$$\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y),$$

Definición 4.2.1

Función de distribución condicional para variables multidimensionales discretas. Sea

(X, Y) un vector aleatorio bivariado discreto con una fdp conjunta $f(x, y)$ y fpps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $P(X = x) = f_X(x) > 0$, la fpp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ definida por

$$f(y|x) = P(Y = y | X = x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $P(Y = y) = f_Y(y) > 0$, la fdp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ definida por

$$f(x|y) = P(X = x | Y = y) = \frac{f(x, y)}{f_Y(y)}.$$

Son distribuciones de probabilidad:

- $f(y|x) \geq 0$
- $\sum_y f(y|x) = \frac{\sum_y f(x, y)}{f_X(x)} = \frac{f_X(x)}{f_X(x)} = 1.$

Definición 4.2.3

Función de distribución condicional para variables multidimensionales continuas.

Sea (X, Y) un vector aleatorio bivariado continuo con fdp conjunta $f(x, y)$ y fdps marginales $f_X(x)$ y $f_Y(y)$. Para cualquier x tal que $f_X(x) > 0$, la fdp condicional de Y dado que $X = x$ es la función de y denotada por $f(y|x)$ y definida por

$$f(y|x) = \frac{f(x, y)}{f_X(x)}.$$

Para cualquier y tal que $f_Y(y) > 0$, la fdp condicional de X dado que $Y = y$ es la función de x denotada por $f(x|y)$ y definida por

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}.$$

Valor esperado condicional:

- Caso discreto: $E[g(Y) | x] = \sum_y g(y)f(y|x)$
- Caso continuo: $E[g(Y) | x] = \int_{-\infty}^{\infty} g(y)f(y|x)dy$

Definición 4.2.5

Sea (X, Y) un vector aleatorio bivariado con fdp o fpm conjunta $f(x, y)$, y fdps o fpms marginales $f_X(x)$ y $f_Y(y)$. Entonces X e Y se denominan **variables aleatorias independientes** si, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = f_X(x)f_Y(y).$$

Si X y Y son independientes, la fdp condicional de Y dado $X = x$ es

$$\begin{aligned} f(y|x) &= \frac{f(x, y)}{f_X(x)} && \text{(definición)} \\ &= \frac{f_X(x)f_Y(y)}{f_X(x)} && \text{(de (4.2.1))} \\ &= f_Y(y), \end{aligned}$$

no depende de x .

Lema 4.2.7

Sea (X, Y) un vector aleatorio bivariado con fdp o fpm conjunta $f(x, y)$. Entonces X y Y son variables aleatorias independientes si y solo si existen funciones $g(x)$ y $h(y)$ tales que, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = g(x)h(y).$$

Teorema 4.2.10

Eventos independientes. Valor esperado de un producto de funciones de variables independientes.

Sean X y Y variables aleatorias independientes.

- a) Para cualesquiera $A \subset \mathbb{R}$ y $B \subset \mathbb{R}$, $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$, es decir, los eventos $\{X \in A\}$ y $\{Y \in B\}$ son eventos independientes.
- b) Sea $g(x)$ una función que depende solo de x y $h(y)$ una función que depende solo de y . Entonces

$$E(g(X)h(Y)) = (E[g(X)])(E[h(Y)]).$$

Demo

$$\begin{aligned} E(g(X)h(Y)) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f(x, y)dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x)h(y)f_X(x)f_Y(y)dx dy \\ &= \int_{-\infty}^{\infty} h(y)f_Y(y) \int_{-\infty}^{\infty} g(x)f_X(x)dx dy \\ &= \left(\int_{-\infty}^{\infty} g(x)f_X(x)dx \right) \left(\int_{-\infty}^{\infty} h(y)f_Y(y)dy \right) \\ &= (Eg(X))(Eh(Y)). \end{aligned}$$

Teorema 4.2.14

La suma de dos variables normales independientes es también una variable normal (sus medias y varianzas se suman).

Sean $X \sim N(\mu, \sigma^2)$ y $Y \sim N(\gamma, \tau^2)$ variables aleatorias normales independientes. Entonces la variable aleatoria $Z = X + Y$ tiene una distribución $N(\mu + \gamma, \sigma^2 + \tau^2)$.