$$T = \frac{|x| - \text{valor nulo}}{\frac{s}{\sqrt{n}}}$$

- **Distribución:** Sigue una distribución t con $df = n - 1$ grados de libertad.

Contraste para dos medias independientes:
- **Objetivo:** Comparar las medias de dos grupos distintos (ej. dos versiones de un examen) asumiendo independencia entre observaciones.
- **Estadístico:**

$$T = \frac{|x|_1 - |x|_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- **Distribución:** Sigue una distribución t con $df = \min(n_1 - 1, n_2 - 1)$ grados de libertad.

Contraste para dos medias pareadas (Paired data):
- **Objetivo:** Comparar observaciones con una correspondencia directa uno a uno (ej. temperatura en el mismo grupo de personas antes y después de un tratamiento).
- **Método:** Se calcula la diferencia para cada par y el problema se reduce a un test de una sola muestra sobre esas diferencias ($|x|_{\text{diff}}$).
- **Estadístico:**

$$T = \frac{|x|_{\text{diff}} - 0}{\frac{s_{\text{diff}}}{\sqrt{n_{\text{diff}}}}}$$

3. El Problema de las Comparaciones Múltiples
- **Inflación del Error Tipo I:** Al realizar múltiples contrastes de hipótesis simultáneos sobre un mismo conjunto, por simple chance es probable obtener diferencias significativas falsas. La probabilidad de rechazar incorrectamente al menos una hipótesis nula verdadera (Family-wise error rate) escala rápidamente.
- **Ejemplo:** Con 100 pruebas independientes a un nivel de confianza del 95%, la probabilidad de obtener al menos un falso positivo sube al 99.4%.
- **Corrección de Bonferroni:** Para garantizar que la tasa máxima global de falsos positivos se mantenga acotada a un valor α, se debe exigir un nivel de significación más estricto a cada comparación individual.
- **Fórmula de corrección:**

$$\gamma = 1 - \frac{\alpha}{m}$$

  Donde m es el número total de contrastes y la tasa ajustada disminuye en proporción a la cantidad de comparaciones.

Clase 12. Regresión lineal simple.
(referencias a Casella Berger 2024)

1. Modelo Estadístico y Supuestos
La regresión lineal simple busca estimar la relación entre una variable de respuesta Y y una covariable o variable predictiva x.
- **Modelo poblacional:** La relación asume linealidad en los parámetros y se expresa como $E(Y_i \mid x_i) = \alpha + \beta x_i$.

- **Modelo Condicional Normal:** Desde el punto de vista estadístico, se asume que las observaciones Y_i son normales e independientes, con una varianza constante σ^2:

$$Y_i \sim N(\alpha + \beta x_i, \sigma^2) \qquad \text{o bien} \qquad Y_i = \alpha + \beta x_i + \varepsilon_i$$

  Donde los errores ε_i son independientes e idénticamente distribuidos (iid) según $N(0, \sigma^2)$.

2. Estimación de Parámetros

Método de Cuadrados Mínimos y Máxima Verosimilitud: Se busca minimizar la Suma de los Residuos Cuadrados (RSS), que representa la distancia vertical entre cada punto observado y la recta predictiva:

$$\text{RSS} = \sum_{i=1}^{n} (y_i - (a + bx_i))^2$$

Los estimadores obtenidos por cuadrados mínimos coinciden con los estimadores de Máxima Verosimilitud bajo el modelo normal:

- **Pendiente:** $\hat{\beta} = b = \frac{S_{\{xy\}}}{S_{\{xx\}}}$
- **Ordenada al origen:** $\hat{\alpha} = a = |y| - b|x|$

(Nota: La regresión es asimétrica; el modelo de regresar Y en X produce una pendiente distinta que el de regresar X en Y).

Estimación de la varianza del error (σ^2): El estimador de máxima verosimilitud para σ^2 es sesgado. Por ello, se utiliza el estimador insesgado basado en los residuos y los grados de libertad:

$$S^2 = \frac{1}{n-2} \sum_{i=1}^{n} \left(y_i - \hat{\alpha} - \hat{\beta} x_i\right)^2 = \frac{\text{RSS}}{n-2}$$

3. Inferencia Estadística

Bajo el modelo condicional normal, los estimadores permiten realizar contrastes de hipótesis e intervalos de confianza.

- **Distribución de la pendiente estimada:** Sigue una distribución Normal, pero al utilizar la varianza muestral S^2, el estadístico pivote sigue una distribución t de Student:

$$\frac{\hat{\beta} - \beta}{\frac{S}{\sqrt{S_{\{xx\}}}}} \sim t_{\{n-2\}}$$

Contraste de hipótesis para la pendiente ($H_0 : \beta = 0$): Sirve para evaluar si existe evidencia significativa de una relación lineal.

- Se rechaza H_0 a nivel α si $|\frac{\hat{\beta}-0}{\frac{S}{\sqrt{S_{\{xx\}}}}}| > t_{\{n-2, \frac{\alpha}{2}\}}$.
- De forma equivalente, puede evaluarse mediante el estadístico F de Snedecor-Fisher ($F = \frac{\hat{\beta}^2}{S^2/S_{\{xx\}}}$).

4. Análisis de Varianza (ANOVA) y Bondad del Ajuste

Descomposición de la suma de cuadrados: La variación total de las observaciones se descompone en la parte explicada por el modelo de regresión y la variación residual (errores):

$$\text{Total SS} = \text{Regression SS} + \text{Residual SS}$$

Coeficiente de Determinación (r^2): Cuantifica qué tan bien se ajusta la recta a los datos. Representa la proporción de la variación total en Y que logra ser explicada por la covariable x.

$$r^2 = \frac{\text{Regression SS}}{\text{Total SS}} = \frac{S_{\{xy\}}^2}{S_{\{xx\}} S_{\{yy\}}}$$

- Se cumple que $0 \leq r^2 \leq 1$. Si $r^2 = 1$, todos los puntos caen exactamente sobre la recta trazada.

5. Bandas de Confianza para la Regresión

Se pueden construir intervalos de confianza simultáneos para la recta de regresión a lo largo de todo el espectro de valores de x.

- Con una confianza de al menos $1 - \alpha$, el valor medio esperado $\alpha + \beta x$ cae simultáneamente en el intervalo:

$$\hat{\alpha} + \hat{\beta} x \pm M_\alpha S \sqrt{\frac{1}{n} + \frac{(x - |x|)^2}{S_{\{xx\}}}}$$

  Donde el factor de amplitud es $M_\alpha = \sqrt{2F_{\{2,n-2,\alpha\}}}$ (esto deriva de aplicar métodos de corrección como Bonferroni o Scheffé para comparaciones múltiples).

Clase 13. Análisis de Varianza (ANOVA de un factor).

1. Concepto y Modelo Estadístico

El Análisis de Varianza (ANOVA) se utiliza para comparar simultáneamente las medias de tres o más grupos o tratamientos poblacionales.

Modelo poblacional: Cada observación se modela como la suma de la media de su grupo y un error aleatorio:

$$Y_{\{ij\}} = \theta_i + \varepsilon_{\{ij\}} \qquad \text{o equivalentemente} \qquad Y_{\{ij\}} = \mu + \alpha_i + \varepsilon_{\{ij\}}$$

Donde $Y_{\{ij\}}$ es la observación j del grupo i, θ_i es la media del grupo i (o μ la media global y α_i el efecto del tratamiento), y $\varepsilon_{\{ij\}}$ es el error aleatorio.

Supuestos del modelo (Oneway ANOVA):

a) **Esperanza nula:** $E\left(\varepsilon_{\{ij\}}\right) = 0$.
b) **Normalidad e Independencia:** Los errores $\varepsilon_{\{ij\}}$ son variables aleatorias independientes y siguen una distribución Normal.
c) **Homocedasticidad:** Todos los grupos tienen la misma varianza poblacional ($\sigma_i^2 = \sigma^2$ para todo i).

2. Contraste de Hipótesis

- **Hipótesis Nula (H_0):** No hay diferencia entre las medias de los grupos.

$$H_0 : \theta_1 = \theta_2 = \ldots = \theta_k$$

- **Hipótesis Alternativa (H_1):** Al menos una de las medias poblacionales difiere del resto.

$$H_1 : \theta_i \neq \theta_j \qquad \text{para algún par } i, j$$

Lógica del contraste: El método consiste en comparar dos fuentes de variabilidad:

- **Varianza Intergrupo (Between):** La dispersión que hay **entre** las medias de los distintos grupos y la media global.
- **Varianza Intragrupo (Within):** La dispersión que hay **dentro** de cada grupo respecto a su propia media.

Si la varianza intergrupo es significativamente mayor que la intragrupo, se concluye que los grupos son distinguibles (se rechaza H_0).

3. Estadístico de Prueba

El estadístico para este contraste es el estadístico F de Fisher-Snedecor, que es el cociente de dos variables independientes con distribución χ^2.

1. Cuadrado Medio Intragrupo (MSW / Pooled Variance S_p^2): Estima la varianza común σ^2 promediando las varianzas muestrales de cada grupo.

$$\text{MSW} = S_p^2 = \frac{1}{N-k} \sum_{i=1}^{k} \sum_{j=1}^{n_i} \left(Y_{\{ij\}} - |Y|_i \right)^2$$

2. Cuadrado Medio Intergrupo (MSB): Mide la dispersión de las medias muestrales de los grupos ($|Y|_i$) respecto a la media global ($||Y||$).

$$\text{MSB} = \frac{1}{k-1} \sum_{i=1}^{k} n_i (|Y|_i - ||Y||)^2$$

3. Estadístico F:

$$F = \frac{\text{MSB}}{\text{MSW}}$$

Bajo H_0, este estadístico sigue una distribución F con $k-1$ grados de libertad en el numerador y $N-k$ grados de libertad en el denominador (donde k es la cantidad de grupos y N la cantidad total de observaciones).

- **Región de rechazo:** Se rechaza H_0 si $F > F_{\{k-1, N-k, \alpha\}}$.

4. Tabla ANOVA

Los resultados suelen resumirse en una tabla estándar que descompone la Suma de Cuadrados Total (SST = SSB + SSW):

Fuente de variación	Grados de libertad	Suma de cuadrados	Cuadrados Medios	Estadístico F
Entre grupos (Inter)	$k-1$	SSB	MSB = SSB / $(k-1)$	$F = \frac{\text{MSB}}{\text{MSW}}$
Dentro de grupos (Intra)	$N-k$	SSW	MSW = SSW / $(N-k)$	
Total	$N-1$	SST		

Clase 14. Regresión Logística.

1. Concepto y Modelo Estadístico

La regresión logística es un caso particular de los Modelos Lineales Generalizados (GLM) utilizado cuando la variable de respuesta Y es binaria (ej. Falló/No falló, Éxito/Fracaso).

- **Componente Aleatoria:** Las respuestas $Y_1, ..., Y_n$ son independientes y siguen una distribución de Bernoulli: $Y_i \sim \text{Bernoulli}(\pi_i)$, donde $E(Y_i) = \pi_i = P(Y_i = 1)$.
- **Función de Enlace (Link Logit):** Se relaciona la probabilidad de éxito π_i con la covariable x_i a través del logaritmo de los "odds" (chances):

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = \alpha + \beta x_i$$

- **Probabilidad Estimada:** Despejando π_i, la probabilidad en función de x adopta una forma sigmoidea (curva logística):

$$\pi(x) = \frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}$$

2. Interpretación de los Parámetros

- **Ordenada al origen (α):** Es el log-odds (logaritmo de las chances) de éxito cuando la covariable es cero ($x = 0$).
- **Pendiente (β):** Representa el cambio en el log-odds de éxito ante un incremento de exactamente 1 unidad en la variable x:

$$\log\left(\frac{\pi(x+1)}{1-\pi(x+1)}\right) - \log\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta$$

  (A diferencia de la regresión lineal, donde β era el cambio absoluto en el valor medio de Y, aquí mide el cambio en la relación logarítmica de las probabilidades).

3. Inferencia Estadística y Contraste de Hipótesis

El contraste más importante evalúa si existe una relación significativa entre la variable predictora x y la respuesta binaria, planteando:

$$H_0 : \beta = 0 \qquad \text{vs} \qquad H_1 : \beta \neq 0$$

Existen dos pruebas principales para evaluar esta hipótesis (ambas válidas para muestras grandes):

1. Test de Wald (Basado en el estimador normalizado): Utiliza el estimador de máxima verosimilitud $\hat{\beta}$ y su error estándar.

$$Z = \frac{\hat{\beta}}{\text{se}\left(\hat{\beta}\right)}$$

- Bajo H_0 y con n grande, Z sigue aproximadamente una distribución Normal estándar $N(0,1)$.
- Se rechaza H_0 si $|Z| \geq z_{\frac{\alpha}{2}}$.

2. Test de Razón de Verosimilitud (Likelihood Ratio Test - LRT): Compara la verosimilitud del modelo completo (con β) frente al modelo nulo (donde $\beta = 0$ y $\hat{\alpha}_0$ depende solo de la proporción de éxitos muestrales).

$$-2\log\lambda(y^*) = 2\left[\log L\left(\hat{\alpha}, \hat{\beta} \mid y^*\right) - \log L(\hat{\alpha}_0, 0 \mid y^*)\right]$$

- Bajo H_0, el estadístico $-2\log\lambda$ sigue aproximadamente una distribución chi-cuadrado con 1 grado de libertad (χ^2_1).
- Se rechaza H_0 a nivel α si $-2\log\lambda \geq \chi^2_{1,\alpha}$.

Clase 15a. Modelos Lineales Generalizados (GLM).

1. Concepto General

Los Modelos Lineales Generalizados (GLM) proponen una abstracción que permite modelar la relación entre una variable dependiente (aleatoria) Y y una variable independiente x, cuando Y no sigue necesariamente una distribución Normal.

En lugar de modelar la esperanza directamente como una combinación lineal, se aplica una transformación general a la esperanza matemática de Y_i:

$$g[E(Y_i)] = \alpha + \beta x_i$$

Donde Y_i pertenece a una familia de distribuciones de tipo exponencial.

2. Las Tres Componentes de un GLM

Todo Modelo Lineal Generalizado está definido estrictamente por tres elementos estructurales:

a) **La componente aleatoria:** Las variables de respuesta $Y_1, ..., Y_n$ son independientes (aunque no idénticamente distribuidas), y provienen todas de la misma familia de distribuciones de tipo exponencial (por ejemplo: Normal, Bernoulli, Binomial, Poisson, Laplace, Exponencial, Gamma, etc.).
b) **La componente sistemática:** Es la parte estructural que involucra a la variable independiente. Su característica fundamental es que debe ser **lineal en los parámetros** (ejemplos válidos: $\alpha + \beta x_i$, $\alpha + \beta x_i^2$, $\alpha + \frac{\beta}{x_i}$).
c) **La función de enlace (Link $g(\mu)$):** Es la función matemática que relaciona o "enlaza" la componente aleatoria con la sistemática. Dicta cómo la esperanza de la variable dependiente se vincula con la combinación lineal de los parámetros:

$$g(E(Y_i)) = \alpha + \beta x_i$$

3. Casos Particulares Comunes

Dependiendo de la distribución elegida para la variable aleatoria y de la función de enlace asociada, se obtienen distintos modelos estadísticos clásicos:

Distribución (Y_i)	Función de Enlace (Link)	Ecuación del Modelo	Nombre Clásico
Normal	Identidad	$E(Y_i) = \alpha + \beta x_i$	Regresión Lineal Simple
Bernoulli	Logit	$\ln\left(\frac{E(Y_i)}{1-E(Y_i)}\right) = \alpha + \beta x_i$	Regresión Logística
Poisson	Logarítmica (Log)	$\ln(E(Y_i)) = \alpha + \beta x_i$	Regresión Poissoniana

---

Clase 15b. Bootstrapping (Remuestreo).

1. Concepto Fundamental

El **bootstrapping** es un método computacional utilizado para estimar la variabilidad de un estadístico y construir intervalos de confianza cuando no se conoce su varianza ni su distribución teórica subyacente.

Idea central: Se utiliza la muestra original empírica como si fuera la población. La distribución de los valores de una muestra (incluso si es relativamente chica) aproxima la distribución de los valores de la población subyacente.

2. El Problema de las Alternativas Clásicas

Para construir un intervalo de confianza (por ejemplo, para una proporción p), tradicionalmente se recurre a:

- **Aproximación Normal:** Basada en el Teorema del Límite Central ($Z \sim N(0,1)$). Exige que el tamaño muestral sea lo suficientemente grande.
- **Intervalo Exacto (ej. Clopper-Pearson):** Utiliza la distribución exacta del estimador (como relacionar la Binomial con la distribución Beta para hallar el parámetro p). Suele ser matemáticamente complejo y requiere conocer de antemano la familia de la distribución.

Cuando no se quiere o no se puede depender de aproximaciones asintóticas, ni se conoce la distribución exacta para derivar el intervalo analíticamente, se utiliza bootstrapping.

3. El Método: Remuestreo con Reposición

El motor del bootstrapping es el **remuestreo con reposición**.

- Dada una muestra original de tamaño N, se generan "nuevas muestras" extrayendo al azar exactamente N valores de la muestra original **con reposición**.
- En estas nuevas muestras (muestras bootstrap) habrá valores repetidos y valores omitidos. Si la muestra original representa bien a la población, la frecuencia de repetición emulará la probabilidad real de cada valor.

4. Receta del Algoritmo de Bootstrap

Para calcular el intervalo de confianza de nivel $1 - \alpha$ para un parámetro θ:

a) **Partir de la muestra:** Se tiene una muestra original $X_1, ..., X_n$.
b) **Elegir el estadístico:** Definir el estadístico θ de interés (media, proporción, varianza, etc.).
c) **Generar la distribución empírica (Bucle):**
   - a) Remuestrear con reposición n elementos de la muestra original para crear una muestra bootstrap: $X_1^*, ..., X_n^*$.
   - b) Calcular el valor del estadístico para esa muestra específica: θ^*.
   - c) Repetir los pasos (a) y (b) una gran cantidad de veces (ej. 1000 o 10000 veces).
d) **Hallar percentiles:** Sobre la distribución de todos los θ^* calculados, buscar los percentiles correspondientes a las colas para el nivel de significación deseado: $\theta_{\frac{\alpha}{2}}$ (límite inferior) y $\theta_{1-\frac{\alpha}{2}}$ (límite

---

Tabla de la Distribución Normal Estándar Acumulada $\Phi(z)$. p es el area acumulada debajo de la curva y Z_p es el punto del eje x hasta donde se acumula la curva.

Z_p	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

!" #$% &'(*t*()*(+!$)*'!

! "# $%& ' '()!(*!+) , #+-.) '. # /0*1(2* '. '()!-("01(2* .* -.# 1(2* 1+* .# *34.-+ '. 5- '+) '. #(".-! '6 1+*1-.! 4.*!.7-.# 1(+* #+) , #+-.) p 8 $t_{n;p}$ 90.) !()/ 1.*:$P(t_n \le t_{n;p}) = p$.

n	$t_{0,55}$	$t_{0,60}$	$t_{0,70}$	$t_{0,80}$	$t_{0,90}$	$t_{0,95}$	$t_{0,975}$	$t_{0,99}$	$t_{0,995}$
;	<7;=>&	<7?@&A	<7B@C=	;7?BC&	?7<BBB	C7?;?>	;@7B<C@	?;7>@<=	C?7C=CB
@	<7;&@;	<7@>>B	<7C;B@	;7<C<B	;7>>=C	@7A@<<	&7?<@B	C7AC&C	A7A@&>
?	<7;?CC	<7@BCB	<7=>&&	<7AB>=	;7C?BB	@7?=?&	?7;>@&	&7=&<B	=7>&<A
&	<7;??>	<7@B<B	<7=C>C	<7A&;<	;7=??@	@7;?;>	@7BBC&	?7B&CA	&7C<&;
=	<7;?@@	<7@CB@	<7==A&	<7A;A=	;7&B=A	@7<;=<	@7=B<C	?7?C&A	&7<?@;
C	<7;?;;	<7@C&>	<7==?&	<7A<=B	;7&?A>	;7A&?@	@7&&CA	?7;&@B	?7B<B&
B	<7;?<?	<7@C?@	<7=&A;	<7>AC<	;7&;&A	;7>A&C	@7?C&C	@7AA><	?7&AA=
>	<7;@AB	<7@C;A	<7=&=A	<7>>>A	;7?AC>	;7>=A=	@7?<C<	@7>AC=	?7?==&
A	<7;@A?	<7@C;<	<7=&?=	<7>>?&	;7?>?<	;7>??;	@7@C@@	@7>@;&	?7@&A>
;<	<7;@>A	<7@C<@	<7=&;=	<7>BA;	;7?B@@	;7>;@=	@7@@>;	@7BC?>	?7;CA?
;;	<7;@>C	<7@=AC	<7=?AA	<7>B==	;7?C?&	;7BA=A	@7@<;<	@7B;>;	?7;<=>
;@	<7;@>?	<7@=A<	<7=?>C	<7>B@C	;7?=C@	;7B>@?	@7;B>>	@7C>;<	?7<=&=
;?	<7;@>;	<7@=>C	<7=?B=	<7>B<@	;7?=<@	;7BB<A	@7;C<&	@7C=<?	?7<;@?
;&	<7;@><	<7@=>@	<7=?CC	<7>C>;	;7?&=<	;7BC;?	@7;&&>	@7C@&=	@7ABC>
;=	<7;@B>	<7@=BA	<7=?=B	<7>CC@	;7?&<C	;7B=?;	@7;?;&	@7C<@=	@7A&CB
;C	<7;@BB	<7@=BC	<7=?=<	<7>C&B	;7??C>	;7B&=A	@7;;AA	@7=>?=	@7A@<>
;B	<7;@BC	<7@=B?	<7=?&&	<7>C??	;7???&	;7B?AC	@7;<A>	@7=CCA	@7>A>@
;>	<7;@B&	<7@=B;	<7=??>	<7>C@<	;7??<&	;7B?&;	@7;<<A	@7==@&	@7>B>&
;A	<7;@B&	<7@=CA	<7=???	<7>C;<	;7?@BB	;7B@A;	@7<A?<	@7=?A=	@7>C<A
@<	<7;@B?	<7@=CB	<7=?@A	<7>C<<	;7?@=?	;7B@&B	@7<>C<	@7=@><	@7>&=?
@;	<7;@B@	<7@=CC	<7=?@=	<7>=A;	;7?@?@	;7B@<B	@7<BAC	@7=;BC	@7>?;&
@@	<7;@B;	<7@=C&	<7=?@;	<7>=>?	;7?@;@	;7B;B;	@7<B?A	@7=<>?	@7>;>>
@?	<7;@B;	<7@=C?	<7=?;B	<7>=B=	;7?;A=	;7B;?A	@7<C>B	@7&AAA	@7><B?
@&	<7;@B<	<7@=C@	<7=?;&	<7>=CA	;7?;B>	;7B;<A	@7<C?A	@7&A@@	@7BACA
@=	<7;@CA	<7@=C;	<7=?;@	<7>=C@	;7?;C?	;7B<>;	@7<=A=	@7&>=;	@7B>B&
@C	<7;@CA	<7@=C<	<7=?<A	<7>==B	;7?;=<	;7B<=C	@7<===	@7&B>C	@7BB>B
@B	<7;@C>	<7@==A	<7=?<C	<7>==;	;7?;?B	;7B<??	@7<=;>	@7&B@B	@7BB<B
@>	<7;@C>	<7@==>	<7=?<&	<7>=&C	;7?;@=	;7B<;;	@7<&>&	@7&CB;	@7BC??
@A	<7;@C>	<7@==B	<7=?<@	<7>=&@	;7?;;&	;7CAA;	@7<&=@	@7&C@<	@7B=C&
?<	<7;@CB	<7@==C	<7=?<<	<7>=?>	;7?;<&	;7CAB?	@7<&@?	@7&=B?	@7B=<<
&<	<7;@C=	<7@==<	<7=@>C	<7>=<B	;7?<?;	;7C>?A	@7<@;;	@7&@??	@7B<&=
=<	<7;@C?	<7@=&B	<7=@B>	<7>&>A	;7@A>B	;7CB=A	@7<<>C	@7&<??	@7CBB>
C<	<7;@C@	<7@=&=	<7=@B@	<7>&BB	;7@A=>	;7CB<C	@7<<<?	@7?A<;	@7CC<?
><	<7;@C;	<7@=&@	<7=@C=	<7>&C;	;7@A@@	;7CC&;	;7AA<;	@7?B?A	@7C?>B
;<<	<7;@C<	<7@=&<	<7=@C;	<7>&=@	;7@A<;	;7CC<@	;7A>&<	@7?C&@	@7C@=A
;@<	<7;@=A	<7@=?A	<7=@=>	<7>&&C	;7@>>C	;7C=BB	;7ABAA	@7?=B>	@7C;B&
∞	<7;@C	<7@=?	<7=@&	<7>&@	;7@>@	;7C&=	;7AC<	@7?@B	@7=BC

D "# $%&: D "# '. # '()!-("01(2* t '. E!0'.*!%

D "# -.)04.* '.!.)!) .)! 'F)!(1+)

G)! 'F)!(1 H+4 I0! 1(+* # J @H @<@C

, $-(*(%.'!"/ !/	0 !/)1!%.	2/3.(H_0	+4* !.
K.'(7 σ 1+*+1(' $H_0 : \mu = \mu_0$	$\frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$	$\mathcal{N}(0,1)$	L+-4 #(' '7 + n 5- *'. I+- DH
K.'(7 σ '.)1+*+1(' $H_0 : \mu = \mu_0$	$\frac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$	t_{n-1}	L+-4 #(' '6 1+* n 1M(1+ .) $'(4* !.("*/57 '. 0* I-+N(4 1(2*
6".4."% &' $H_0 : p = p_0$	$\frac{\hat{p} - p_0}{\sqrt{p_0 \frac{1-p_0}{n}}}$	$\mathcal{N}(0,1)$ I-+N%	$np_0 \geq 10$ 8 $n(1-p_0) \geq 10$