Clase 1. Teoría de conjuntos, espacio muestral, eventos, probabilidad.

(referencias a Casella Berger 2024)

Definición 1.1.1
El conjunto S de todos los posibles resultados de un experimento se llama **espacio muestral**.

Definición 1.1.2
Un **evento** es una colección de posibles resultados de un experimento, o sea, un subconjunto de S (incluyendolo a S). Relaciones de inclusión e igualdad.

Teorema 1.1.4
Para cualesquiera tres eventos, A, B y C, definidos en un espacio muestral S,

a) Commutativity

$$A \cup B = B \cup A,$$
$$A \cap B = B \cap A;$$

b) Associativity

$$A \cup (B \cup C) = (A \cup B) \cup C,$$
$$A \cap (B \cap C) = (A \cap B) \cap C;$$

c) Distributive Laws

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C),$$
$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C);$$

d) DeMorgan's Laws

$$(A \cup B)^c = A^c \cap B^c, (A \cap B)^c = A^c \cup B^c.$$

Definición 1.1.5
Dos eventos A y B son **disjuntos (o mutuamente exclusivos)** si $A \cap B = \varnothing$. Estos eventos $A_1, A_2, \ldots$ son **disjuntos de a pares (o mutuamente exclusivos)** si $A_i \cap A_j = \varnothing \; \forall i \neq j$.

Definición 1.1.6
Si $A_1, A_2, \ldots$ son disjuntos de a pares, $A_i \neq \varnothing$ y $\bigcup_{i=1}^{\infty} A_i = S$, entonces la colección $A_1, A_2, \ldots$ forman una **partición** de S.

Definición 1.2.1
Una colección de subconjuntos de S se lo llama **sigma-algebra (campo de Borel o álgebra de Borel)**, denotada $\mathcal{B}$, si satisface las siguientes propiedades:

a) $\varnothing \in \mathcal{B}$ (el conjunto vacio es un elemento de $\mathcal{B}$).

b) Si $A \in \mathcal{B}$, entonces $A^c \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para complemento).

c) Si $A_1, A_2, \ldots \in \mathcal{B}$, entonces $\bigcup_{i=1}^{\infty} A_i \in \mathcal{B}$ ($\mathcal{B}$ es cerrado para uniones numerables).

Definición 1.2.4
Dado un espacio muestral S y un campo de Borel aociado $\mathcal{B}$, una **función de probabilidad** es una función P con dominio $\mathcal{B}$ que satisface los **axiomas de probabilidad**:

1. $P(A) \geq 0 \; \forall A \in \mathcal{B}$.
2. $P(S) = 1$.

3. Si $A_1, A_2, ... \in \mathcal{B}$ son mutuamente exclusivos, entonces $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$.

Teorema 1.2.6
Sea $S = \{s_1, ..., s_n\}$ un conjunto finito. Sea $\mathcal{B}$ un campo de Borel de subconjuntos de S. Sean $p_1, ..., p_n$ numeros no-negativos que sumen uno. Para cualquier $A \in \mathcal{B}$, se define $P(A)$ como

$$P(A) = \sum_{\{i: s_i \in A\}} p_i$$

Teorema 1.2.8
Si P es una función de probabilidad y A es algun conjunto en $\mathcal{B}$, entonces

a) $P(\varnothing) = 0$.

b) $P(A) \leq 1$.

c) $P(A^c) = 1 - P(A)$.

Teorema 1.2.9
Si P es una función de probabilidad y A y B son conjuntos en $\mathcal{B}$, entonces

a) $P(B \cap A^c) = P(B) - P(A \cap B)$.

b) $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

c) Si $A \subset B$ entonces $P(A) \leq P(B)$.

Clase 2. Bonferroni, conteo, probabilidad condicional e independencia.

(referencias a Casella Berger 2024)

Teorema 1.2.11
Si P es una función de probabilidad, entonces

a) $P(A) = \sum_{i=1}^{\infty} P(A \cap C_i)$ para cualquier partición $C_1, C_2, ...$ **probabilidad total**

b) $P\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} P(A_i)$ para cualesquiera conjuntos $A_1, A_2, ...$ **probabilidad de Boole / desigualdad de Boole**

Ecuación 1.2.10
La **desigualdad de Bonferroni**:

$$P(A \cap B) \geq P(A) + P(B) - 1$$

La **generalización de Bonferroni** es:

$$P\left(\bigcap_{i=1}^{n} A_i\right) \geq \sum_{i=1}^{n} P(A_i) - (n-1)$$

Teorema 1.2.14
Si un trabajo consiste en k tareas separadas, de las cuales la i-ésima puede resolverse de n_i materas, $i = 1, ..., k$, entonces el trabajo completo puede hacerse en $n_1 \times n_2 \times ... \times n_k$ formas.

Definición 1.2.17
Para numeros no negativos n y r, $n \geq r$, definiumos el **número combinatorio** $\binom{n}{r}$, leído como elegir r de n, como

$$\binom{n}{r} = \frac{n!}{r!(n-r)!}$$

Tabla 1.2.1
Resumen de los cuatro casos básicos de conteo.

	Sin reemplazo	**Con reemplazo**
Con orden	$\frac{n!}{(n-r)!}$	n^r
Sin orden	$\binom{n}{r}$	$\binom{n+r-1}{r}$

Definición 1.3.2
Si A y B son eventos en S, y $P(B) > 0$, entonces la **probabilidad condicional** de un A dado B, escrito como $P(A|B)$, es

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Ecuación 1.3.3

$$P(A \cap B) = P(A|B)P(B)$$

Ecuación 1.3.4

$$P(A \cap B) = P(B|A)P(A)$$

Ecuación 1.3.5
Regla de Bayes para dos eventos.

$$P(A|B) = P(B|A)\frac{P(A)}{P(B)}$$

Teorema 1.3.5
Regla de Bayes generalizada. Sea $A_1, A_2, \ldots$ una partición del espacio muestral, y sea B cualquier conjunto, para cada $i = 1, 2\ldots$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^{\infty} P(B|A_j)P(A_j)}$$

Definición 1.3.7
Dos eventos, A y B, son **estadísticamente independientes** si

$$P(A \cap B) = P(A)P(B)$$

Esto implica que:

$$P(A|B) = P(A)$$

Teorema 1.3.9
Si A y B son eventos independientes, entonces los siguientes pares también:

a) A y B^c

b) A^c y B

c) A^c y B^c

Definición 1.3.12
Una colección de eventos $A_1, ..., A_n$ son **mutuamente independientes** si para cualquier subcolección $A_{i_1}, ..., A_{i_k}$, se cumple que la probabilidad de la intersección es igual a la factorización de las probabilidades:

$$P\left(\bigcap_{j=1}^{k} A_{ij}\right) = \prod_{j=1}^{k} P(A_{ij})$$

Clase 3. Variables aleatorias.

(referencias a Casella Berger 2024)

Variables aleatorias

Definición 1.4.1
Una **variable aleatoria** es una función de un espacio muestral S a los números reales.

Ecuación 1.4.1
P_X es una función de probabilidad inducida en $\mathcal{X} = \{x_1, ..., x_m\}$. Definida en los términos de la función original P.

$$P_X(X = x_i) = P\big(\{s_j \in S : X(s_j) = x_i\}\big)$$

Definición 1.5.1
La **función de distribución acumulada, o fda**, de una variable aleatoria X, donotada como $F_{X(x)}$, es definida por

$$F_X(x) = P_X(X \leq x), \forall x$$

Teorema 1.5.3
La función $F(x)$ es una fda si y solo si las siguientes condiciones se cumplen:

a) $\lim_{x\to-\infty} F(x) = 0$ y $\lim_{x\to\infty} F(x) = 1$.

b) $F(x)$ es una función no decreciente de x.

c) $F(x)$ es continua a la derecha. O sea, para todo número x_0, $\lim_{x\to x_0^+} F(x) = F(x_0)$.

Definición 1.5.7
Una variable aleatoria X es **continua** si $F_X(x)$ es una función continua de x.

Una variable aleatoria X es **discreta** si $F_X(x)$ es una función escalonada (o en escalera / step function).

Definición 1.5.8
Las variables aleatorias X e Y son **idénticamente distribuidas** si, por cada conjunto $A \in \mathcal{B}$, $P(X \in A) = P(Y \in A)$

Teorema 1.5.10
Las siguientes declaraciones son equivalentes:

a) Las variables aleatorias X e Y son idénticamente distribuidas.

b) $F_X(x) = F_Y(x), \forall x$.

Definición 1.6.1
La **función de probabilidad puntual (fpp)** de una variable aleatoria discreta X es dada por

$$f_X(x) = P(X = x)$$

Ecuación 1.6.1
Relación entre fpp y fda (variable discreta)

$$F_X(x) = \sum_{i=1}^{x} f_X(i)$$

Ecuación 1.6.2
Relación entre fdp y fda (variable continua).

$$\frac{d}{dx} F_X(x) = f_X(x)$$

Definición 1.6.3
La **función de densidad de probabilidad (fdp)**, $f_X(x)$, de una variable aleatoria continua X es la función que satisface

$$F_X(x) = \int_{-\infty}^{x} f_X(t)dt \quad \forall x$$

Teorema 1.6.5
Una función $f_X(x)$ es fdp o fpp, de una variable aleatoria X si y solo si

a) $f_X(x) \geq 0 \quad \forall x.$

b) $\sum_x f_X(x) = 1$ (fpp) o $\int_{-\infty}^{\infty} f_X(x)dx = 1$ (fdp)

Valor esperado

Definición 2.2.1
El **valor esperado (esperanza)** de una variable aleatoria $g(X)$, denotado por $E[g(X)]$, es

$$E[g(X)] = \begin{cases} \int_{-\infty}^{\infty} g(x) f_X(x) dx & X \text{ continua} \\ \sum_{x \in \mathcal{X}} g(x) f_X(x) = \sum_{x \in \mathcal{X}} g(x) P(X = x) & X \text{ discreta} \end{cases}$$

dado que la integral o suma exista. Si $E[g(X)] = \infty$, decimos que $E[g(X)]$ no existe.
Es el resultado promedio teórico que esperarías obtener si repitieras un experimento aleatorio un número infinito de veces. Representa el punto de equilibrio de la distribución de probabilidad.

Valor esperado de la variable: **valor medio**.

$$g(X) = X$$

Es el promedio aritmético calculado a partir de un conjunto de datos observados (una muestra o una población real). Por la Ley de los Grandes Números, a medida que aumentas el tamaño de la muestra, el valor medio se acerca a la esperanza.

Valor esperado de las distancias cuadráticas con respecto al valor medio: **varianza**.

$$\text{Var}(X) = E\left[(X - E(X))^2\right]$$

Es una medida de la dispersión o variabilidad de los datos respecto a su media o esperanza. A menudo se calcula su raíz cuadrada, conocida como **desviación estándar**, para devolver la medida a la unidad original.

Teorema 2.2.5
Sea X una variable aleatoria y sean a, b y c constantes. Entonces para funciones cualesquiera $g_1(x)$ y $g_2(x)$ donde sus esperanzas existen, se cumple que

a) $E[ag_1(X) + bg_2(X) + c] = aE[g_1(X)] + bE[g_2(X)] + c$

b) Si $g_1(x) \geq 0$ para todo x, entonces $E[g_1(X)] \geq 0$.

c) Si $g_1(x) \geq g_2(x)$ para todo x, entonces $E[g_1(X)] \geq E[g_2(X)]$.

d) Si $a \leq g_1(x) \leq b$ para todo x, entonces $a \leq E[g_1(X)] \leq b$.

Teorema 2.3.4
Si X es una variable aleatoria con varianza finita, entonces para cualesquiera constantes a y b,

$$\text{Var}(aX + b) = a^2 \text{ Var}X$$

Clase 4. Distribuciones discretas y continuas.

(referencias a Casella Berger 2024 y al resumen de distribuciones de la práctica)

Familias comunes de distribuciones discretas

Ecuación 3.2.1
Distribución uniforme discreta.

$X \sim U(1, N)$ si $P(X = x \mid N) = \frac{1}{N} \quad (x = 1, 2, ..., N)$

$E[X] = \sum_{x=1}^{N} xP(X = x \mid N) = \frac{N+1}{2}$

$\text{Var}(X) = \frac{(N+1)(N-1)}{12}$

Ecuación 3.2.3
Distribución de Bernoulli (ensayo de Bernoulli).

$X \sim \text{Bernoulli}(p)$ si $x = \begin{cases} 1 \text{ con probabilidad } p \\ 0 \text{ con probabilidad } (1-p) \end{cases} \quad (0 \leq p \leq 1)$

$E[X] = p$

$\text{Var}(X) = p(1 - p)$

Teorema 3.2.2
Distribución binomial. Supongamos n ensayos de Bernoulli independientes e $Y =$ número de éxitos en n ensayos. Modela el número de éxitos en n ensayos independientes, cada uno con probabilidad de éxito p.

$Y \sim \text{Bin}(n, p)$ si $P(Y = y|n, p) = \binom{n}{y} p^y (1 - p)^{n-y}$

$E[Y] = np$

$\text{Var}(Y) = np(1 - p)$

Ecuación 3.2.5
Distribución de Poisson. Modela el número de eventos (raros e independientes) que ocurren en un intervalo fijo de tiempo o espacio.

$X \sim \text{Poisson}(\lambda)$ si $P(X = x| \lambda) = \frac{e^{-\lambda}\lambda^x}{x!} , \quad (x = 0, 1, ...)$

$E[X] = \lambda$

$\text{Var}(X) = \lambda$

Ecuaciones 3.2.6 3.2.7
Relaciones de recursión (binomial y Poisson)

$X \sim \text{Poisson}(\lambda) \Rightarrow P(X = x) = \frac{\lambda}{x} P(X = x - 1) , \quad (x = 1, 2, ...)$

$Y \sim \text{Bin}(n, p) \Rightarrow P(Y = y) = \frac{(n-y+1)}{y} \frac{p}{1-p} P(Y = y - 1)$

Ecuación 3.2.11
Distribución geométrica.

$X =$ número de ensayos de Bernoulli hasta el primer éxito.

$X \sim \text{Geom}(p)$ si $P(X = x| p) = (1 - p)^{x-1} , \quad (x = 1, 2, ...)$

$E[X] = \frac{1}{p}$

$\text{Var}(X) = \frac{1-p}{p^2}$

Propiedad "sin memoria".

$P(X > s \mid X > t) = P(X > s - t) , \quad (s > t)$

La probabilidad de obtener una secuencia de fracasos no depende de la posición en la tira, solo del largo de la secuencia.

Ecuación 3.2.9
Distribución binomial negativa. Modela el número de ensayos necesarios hasta obtener el r-ésimo éxito.

$p_X(k) = \binom{k-1}{r-1}p^r(1-p)^{k-r}$, $(k = r, r+1, ...)$, $(0 < p < 1)$

$E[X] = \frac{r}{p}$

$\text{Var}(Y) = \frac{r(1-p)}{p^2}$

Ecuación 3.2.2
Distribución hipergeométrica. Modela el número de elementos "buenos" al extraer una muestra de tamaño m sin reposición de una población finita de tamaño N con r buenos.

$p_X(k) = \frac{\binom{r}{k}\binom{N-r}{m-k}}{\binom{N}{m}}$, $\max(r+m-N, 0) \leq k \leq \min(r, m)$

$E[X] = m\frac{r}{N}$

$\text{Var}(X) = m\frac{r}{N}\frac{N-r}{N}\frac{N-m}{N-1}$

Familias comunes de distribuciones continuas

A partir de aca está mal hablar de $P(X = x)$ ya que es una distribución continua y se mide la probabilidad con el área de su curva, por lo que esto es lo mismo que decir 0.

Ecuación 3.3.1
Distribución uniforme continua.

$X \sim U[a, b]$

$f(x) = \frac{1}{(b-a)}\mathbb{1}_{[a,b]}(x)$

$E[X] = \frac{a+b}{2}$

$\text{Var}(X) = \frac{(b-a)^2}{12}$

$U[0, 1] = \beta(1, 1)$

Ecuación 3.3.13
Distribución normal.

$X \sim N(\mu, \sigma^2)$

$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}}e^{-(x-\mu)^2/2\sigma^2}$, $\sigma > 0$

$E[X] = \mu$

$\text{Var}(X) = \sigma^2$

Normal estándar: $N(0, 1)$

Ecuación 3.3.6
Distribución gamma.

$X \sim \Gamma(\alpha, \lambda)$

$f_X(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)}x^{\alpha-1}e^{-\lambda x}\mathbb{1}_{(0,\infty)}(x)$, $\lambda, \alpha > 0$

$E[X] = \frac{\sigma}{\lambda}$

$\text{Var}(X) = \frac{\alpha}{\lambda^2}$

$\Gamma(1) = 1$, $\Gamma(\alpha) = (\alpha-1)\Gamma(\alpha-1)$, $\Gamma(n) = (n-1)!$, $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

Ecuación 3.3.16 3.3.17
Distribución Beta.

$X \sim \beta(a, b)$

$f_X(x) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)}x^{a-1}(1-x)^{b-1}\mathbb{1}_{(0,1)}(x)$, $a, b > 0$

$E[X] = \frac{a}{a+b}$

$\text{Var}(X) = \frac{ab}{(a+b)^2(a+b+1)}$

Relación con la función gamma

$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$

Ecuación 3.3.11
Distribución exponencial.
La distribución exponencial es una distribución de probabilidad continua que modela el tiempo que transcurre hasta que ocurre un determinado evento. λ es la tasa de ocurrencia de eventos en un intervalo de tiempo.

$X \sim \text{Exp}(\lambda)$

$f_X(x) = \lambda e^{-\lambda x}\mathbb{1}_{(0,\infty)}(x)$, $\lambda > 0$

$E[X] = \frac{1}{\lambda}$

$\text{Var}(X) = \frac{1}{\lambda^2}$

Parametrización alternativa.

$\text{Exp}(\lambda) = \Gamma(1, \lambda)$

Ecuación 3.3.19
Distribución de Cauchy.

$X \sim C(0, \lambda)$

$f_X(x) = \frac{1}{\pi}\frac{\lambda}{\lambda^2+x^2}$, $\lambda > 0$

No tiene esperanza definida. $C(0, 1) = t_1$

Otras

T de Student

$X \sim t_n$

$f_X(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{\pi n}}\left(1+\frac{x^2}{n}\right)^{-(n+1)/2}$

$E(X) = 0$

$\mathrm{Var}(X) = 2n$

Chi cuadrado

$X \sim \mathcal{X}^2_n$

$\mathcal{X}^2_n = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right), n \in \mathbb{N}$

$E[X] = n$

$\mathrm{Var}(X) = 2n$

F de Snedecor

$X \sim F_{n,m}$

$f_X(x) =$

$\frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\Gamma\left(\frac{m}{2}\right)}\left(\frac{n}{m}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1}\left(1+\frac{n}{m}x\right)^{-\frac{m+n}{2}} \mathbb{1}((0,\infty))(x)$

Propiedades más usadas

- $X \sim \mathrm{Bi}(n,p), Y \sim \mathrm{Bi}(m,p)$ independientes $\Rightarrow X+Y \sim \mathrm{Bi}(n+m,p)$.
- $X \sim P(\lambda_1), Y \sim P(\lambda_2)$ independientes $\Rightarrow X+Y \sim P(\lambda_1+\lambda_2)$.
- $\mathrm{Bi}(n,p) \approx P(\lambda)$ con $\lambda = np$ cuando $p \ll 1$.
- $H(N,r,m) \approx \mathrm{Bi}(m, \frac{r}{N})$ cuando N es grande y $m \ll N$.
- $X \sim N(\mu,\sigma^2) \Rightarrow \frac{X-\mu}{\sigma} \sim N(0,1)$ (estandarización).
- $X \sim N(\mu_1,\sigma_1^2), Y \sim N(\mu_2,\sigma_2^2)$ independientes $\Rightarrow aX+bY+c \sim N(a\mu_1 + b\mu_2 + c, a^2\sigma_1^2 + b^2\sigma_2^2)$.
- $X \sim \Gamma(\alpha,\lambda) \Rightarrow cX \sim \Gamma(\alpha, \frac{\lambda}{c})$.
- $Z \sim N(0,1) \Rightarrow Z^2 \sim \chi^2_1$.

Clase 5. Transformación de variables aleatorias.

(referencias a Casella Berger 2024)

Transformaciones de variables aleatorias

Ecuación 2.1.1

Función de una variable aleatoria. Si X es una variable aleatoria con fda $F_X(x)$, entonces cualquier función de X, digamos $g(X)$ también es una variable aleatoria.

$$P(Y \in A) = P(g(X) \in A)$$

$g(X)$ define un mapa desde el espacio muestral original (X) al transformado (Y).

$\mathcal{X}$ soporte de X
$\mathcal{Y}$ soporte de Y

(**soporte** es el conjunto de puntos x donde la función de probabilidad puntual (fpp) es estrictamente mayor que cero.)

$g(x) : \mathcal{X} \to \mathcal{Y}$

Lo definimos por la inversa:

$g^{-1}(\{y\}) = \{x \in \mathcal{X} : g(x) = y\}$

$Y = g(X)$

Podemos escribir entonces para cualquier conjunto $A \subset \mathcal{Y}$:

$$\begin{aligned} P(Y \in A) &= P(g(X) \in A) \\ &= P(\{x \in \mathcal{X} : g(x) \in A\}) \\ &= P(X \in g^{-1}(A)). \end{aligned}$$

Ecuación 2.1.4, 2.1.8, 2.1.9
Función de distribución acumulada de una variable transformada. X e Y variables aleatorias continuas, calculemos la fda de $Y = g(X)$:

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(g(X) \leq y) \\ &= P(\{x \in \mathcal{X} : g(x) \leq y\}) \\ &= \int_{\{x \in \mathcal{X} : g(x) \leq y\}} f_X(x)dx. \end{aligned}$$

Región de integración de la probabilidad de una transformación.

Si g es creciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \leq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \leq g^{-1}(y)\}. \end{aligned}$$

Si g es decreciente implica que:

$$\begin{aligned} \{x \in \mathcal{X} : g(x) \leq y\} &= \{x \in \mathcal{X} : g^{-1}(g(x)) \geq g^{-1}(y)\} \\ &= \{x \in \mathcal{X} : x \geq g^{-1}(y)\}. \end{aligned}$$

Con esto podemos escribir que, si es creciente $g(x)$:

$$F_Y(y) = \int_{\{x \in \mathcal{X} : x \leq g^{-1}(y)\}} f_X(x)dx = \int_{-\infty}^{g^{-1}(y)} f_X(x)dx = F_X(g^{-1}(y)).$$

Si $g(x)$ es decreciente, tenemos

$$F_Y(y) = \int_{g^{-1}(y)}^{\infty} f_X(x)dx = 1 - F_X(g^{-1}(y)).$$

Teorema 2.1.3
Función de distribución acumulada de una transformación.
Sea X una variable aleatoria con fda $F_X(x)$, sea $Y = g(X)$, y sean $\mathcal{X}$ e $\mathcal{Y}$ definidos como $\mathcal{X} = \{x : f_X(x) > 0\}$ e $\mathcal{Y} = \{y : y = g(x) \text{ para algún } x \in \mathcal{X}\}$..

a) Si g es una función creciente en $\mathcal{X}$, $F_Y(y) = F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.

b) Si g es una función decreciente en $\mathcal{X}$ y X es una variable aleatoria continua, $F_Y(y) = 1 - F_X(g^{-1}(y))$ para $y \in \mathcal{Y}$.

Teorema 2.1.5
Función de densidad de probabilidad de una transformación.
Sea X una variable aleatoria con fdp $f_X(x)$ y sea $Y = g(X)$, donde g es una función monótona (función que no cambia de sentido de variación (siempre crece o siempre decrece) a lo largo de todo el conjunto $\mathcal{X}$ donde la variable aleatoria X toma valores). Sean $\mathcal{X}$ y $\mathcal{Y}$ definidos como en el teorema 2.1.3. Supongamos que $f_X(x)$ es continua en $\mathcal{X}$ y que $g^{-1}(y)$ tiene derivada continua en $\mathcal{Y}$. Entonces la fdp de Y está dada por:

$$f_Y(y) = \begin{cases} f_X(g^{-1}(y)) \left|\frac{d}{dy} g^{-1}(y)\right| & y \in \mathcal{Y}, \\ 0 & \text{si no} \end{cases}$$

Teorema 2.1.10
Transformación integral de probabilidad.
Tenga X una fda continua $F_X(x)$ y definimos la variable aleatoria Y como $Y = F_X(X)$. Entonces Y esta uniformemente distribuida en $(0, 1)$, o sea, $P(Y \leq y) = y \ , \ \ 0 < y < 1$.

Demo:
Para $Y = F_X(X)$ tenemos que, para $0 < y < 1$,

$$\begin{aligned} P(Y \leq y) &= P(F_X(X) \leq y) \\ &= P(F_X^{-1}[F_X(X)] \leq F_X^{-1}(y)) && (F_X^{-1} \text{ es creciente}) \\ &= P(X \leq F_X^{-1}(y)) && (\text{propiedad de } \ F_X^{-1}) \\ &= F_X(F_X^{-1}(y)) && (\text{definición de } F_X) \\ &= y. && (\text{continuidad de } F_X) \end{aligned}$$

Clase 6. Distribuciones conjuntas.

(referencias a Casella Berger 2024)

Teorema 3.6.1
Desigualdad de Markov.
Sea X una variable aleatoria y $g(X) \geq 0$. Entonces, para cualquier $r > 0$:

$$P(g(X) \geq r) \leq \frac{E[g(X)]}{r}$$

Desigualdad de Chevyshev

$$P(|Y - E[Y]| \geq k) \leq \frac{\text{Var}(Y)}{k^2}$$

Distribuciones conjuntas

Definición 4.1.1

Un **vector aleatorio n-dimensional** es una función de un espacio muestral S en $\mathbb{R}^2$, un espacio Euclidiano n-dimensional.

Definición 4.1.3

Sea (X, Y) un vector aleatorio bivariado discreto. Entonces la función $f(x, y)$ de $\mathbb{R}^2 \to \mathbb{R}$ definida por $f(x, y) = P(X = x, Y = y)$ se la llama la **función de probabilidad puntual conjunta / fpp conjunta** de (X, Y). Si es necesario reafirmar que f es la fpp conjunta del vector (X, Y) en vez de ser de otro vector, la notación que se usa es $f_{X,Y}(x, y)$

La fpp conjunta puede ser usada para computar la probabilidad de cualquier evento definido en términos de (X, Y). Sea A un subconjunto de $\mathbb{R}^2$. Entonces,

$$P((X, Y) \in A) = \sum_{(x,y)\in A} f(x, y).$$

El valor esperado es,

$$E[g(X, Y)] = \sum_{(x,y)\in\mathbb{R}^2} g(x, y)f(x, y).$$

Propiedades:

Sean $g_1(x, y)$ y $g_2(x, y)$ funciones y a, b y c constantes:

- $E[ag_1(x, y) + bg_2(x, y) + c] = aE[g_1(x, y)] + bE[g_2(x, y)] + c$
- $f(x, y) \geq 0$ para todo x, y
- $\sum_{(x,y)\in\mathbb{R}^2} f(x, y) = 1$

Teorema 4.1.6

Sea (X, Y) un vector aleatorio bivariado discreto con fpp conjunta $f_{X,Y}(x, y)$. Entonces, la **función de probabilidad puntual marginal / fpp marginal** de X e Y, $f_X(x) = P(X = x)$ y $f_Y(y) = P(Y = y)$, son dadas por,

$$f_X(x) = \sum_{y\in\mathbb{R}} f_{X,Y}(x, y) \quad \text{y} \quad f_Y(y) = \sum_{x\in\mathbb{R}} f_{X,Y}(x, y).$$

Nota: Marginal es por como se ve en una tabla los resultados de $f_X(x)$ y $f_Y(y)$, o sea, en los márgenes de una tabla.

Definición 4.1.10

Una función $f(x, y)$ de $\mathbb{R}^2 \to \mathbb{R}$ se la llama **función de densidad de probabilidad conjunta / fdp conjunta** para un vector bidimensional continuo (X, Y) si, por cada $A \subset \mathbb{R}^2$,

$$P((X, Y) \in A) = \iint_A f(x, y)dxdy.$$

Ecuación 4.1.1

Valor esperado de una función de dos variables continuas.

Sea $g(X, Y) \in \mathbb{R}$

$$E[g(X, Y)] = \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x, y)f(x, y)dxdy.$$

Ecuación 4.1.2
Funciones de densidad de probabilidad marginales / fdp marginal para variables continuas.

$$f_X(x) = \int_{-\infty}^{\infty} f(x,y)dy, \quad -\infty < x < \infty,$$
$$f_Y(y) = \int_{-\infty}^{\infty} f(x,y)dx, \quad -\infty < y < \infty.$$

Ecuación 4.1.3
Función de distribución acumulada conjunta / fda conjunta para variables continuas.

$$F(x,y) = P(X \leq x, Y \leq y)$$
$$F(x,y) = \int_{-\infty}^{x}\int_{-\infty}^{y} f(s,t)dtds.$$
$$\frac{\partial^2 F(x,y)}{\partial x \partial y} = f(x,y),$$

Definición 4.2.1
Función de distribución condicional para variables multidimensionales discretas.
Sea (X,Y) un vector aleatorio bivariado discreto con una fpp conjunta $f(x,y)$ y fpps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $P(X=x) = f_X(x) > 0$, la fpp condicional de Y dado que $X=x$ es la función de y denotada por $f(y|x)$ definida por

$$f(y|x) = P(Y=y \mid X=x) = \frac{f(x,y)}{f_X(x)}.$$

Para cualquier y tal que $P(Y=y) = f_Y(y) > 0$, la fpp condicional de X dado que $Y=y$ es la función de x denotada por $f(x|y)$ definida por

$$f(x|y) = P(X=x \mid Y=y) = \frac{f(x,y)}{f_Y(y)}.$$

Son distribuciones de probabilidad:

- $f(y|x) \geq 0$
- $\sum_y f(y|x) = \frac{\sum_y f(x,y)}{f_X(x)} = \frac{f_X(x)}{f_X(x)} = 1.$

Definición 4.2.3
Función de distribución condicional para variables multidimensionales continuas.
Sea (X,Y) un vector aleatorio bivariado continuo con fdp conjunta $f(x,y)$ y fdps marginales $f_X(x)$ y $f_Y(y)$.

Para cualquier x tal que $f_X(x) > 0$, la fdp condicional de Y dado que $X=x$ es la función de y denotada por $f(y|x)$ y definida por

$$f(y|x) = \frac{f(x,y)}{f_X(x)}.$$

Para cualquier y tal que $f_Y(y) > 0$, la fdp condicional de X dado que $Y=y$ es la función de x denotada por $f(x|y)$ y definida por

$$f(x|y) = \frac{f(x,y)}{f_Y(y)}.$$

Valor esperado condicional:

- Caso discreto: $E[g(Y) \mid x] = \sum_y g(y)f(y|x)$
- Caso continuo: $E[g(Y) \mid x] = \int_{-\infty}^{\infty} g(y)f(y|x)dy$

Definición 4.2.5
Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$, y fdps o fpps marginales $f_X(x)$ y $f_Y(y)$. Entonces X e Y se denominan **variables aleatorias independientes** si, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = f_X(x)f_Y(y).$$

Si X y Y son independientes, la fdp condicional de Y dado $X = x$ es

$$\begin{aligned} f(y|x) &= \frac{f(x,y)}{f_X(x)} && \text{(definición)} \\ &= \frac{f_X(x)f_Y(y)}{f_X(x)} && \text{(de (4.2.1))} \\ &= f_Y(y), \end{aligned}$$

no depende de x.

Lema 4.2.7
Sea (X, Y) un vector aleatorio bivariado con fdp o fpp conjunta $f(x, y)$. Entonces X y Y son **variables aleatorias independientes** si y solo si existen funciones $g(x)$ y $h(y)$ tales que, para todo $x \in \mathbb{R}$ e $y \in \mathbb{R}$,

$$f(x, y) = g(x)h(y).$$

Nota: O sea, si se puede separar en un producto donde uno dependa solo de x y el otro solo de y, entonces son independientes. Esto es un atajo.

Teorema 4.2.10
Eventos independientes.
Valor esperado de un producto de funciones de variables independientes.

Sean X y Y variables aleatorias independientes.

a) Para cualesquiera $A \subset \mathbb{R}$ y $B \subset \mathbb{R}$, $P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$, es decir, los eventos $\{X \in A\}$ y $\{Y \in B\}$ son eventos independientes.

b) Sea $g(x)$ una función que depende solo de x y $h(y)$ una función que depende solo de y. Entonces

$$E(g(X)h(Y)) = (E[g(X)])(E[h(Y)]).$$

Nota:

a) Si dos variables X e Y son independientes, cualquier pregunta o condición que le hagas a X será totalmente independiente de cualquier pregunta o condición que le hagas a Y.

b) La esperanza del producto de dos funciones aplicadas a variables independientes es igual al producto de sus esperanzas individuales.

Demo

$$
\begin{aligned}
E(g(X)h(Y)) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x)h(y)f(x,y)dxdy \\
&= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x)h(y)f_X(x)f_Y(y)dxdy \\
&= \int_{-\infty}^{\infty} h(y)f_Y(y)\int_{-\infty}^{\infty} g(x)f_X(x)dxdy \\
&= \left(\int_{-\infty}^{\infty} g(x)f_X(x)dx\right)\left(\int_{-\infty}^{\infty} h(y)f_Y(y)dy\right) \\
&= (Eg(X))(Eh(Y)).
\end{aligned}
$$

Teorema 4.2.14
La suma de dos variables normales independientes es también una variable normal (sus medias y varianzas se suman).

Sean $X \sim N(\mu, \sigma^2)$ y $Y \sim N(\gamma, \tau^2)$ variables aleatorias normales independientes. Entonces la variable aleatoria $Z = X + Y$ tiene una distribución $N(\mu + \gamma, \sigma^2 + \tau^2)$.

Clase 7. Muestras aleatorias.

(referencias a Casella Berger 2024)

Definición 4.5.1 y 4.5.2
La **covarianza** de X e Y es el número definido por

$$\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$$

La **correlación** de X e Y es el número definido por

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

Posdata:

- μ_X y μ_Y son las $E[X]$ y $E[Y]$ respectivamente.
- $\sigma_X^2 = \sqrt{\text{Var}(X)} = \sqrt{E[X^2] - \mu_X^2}$ y $\sigma_Y^2 = \sqrt{\text{Var}(Y)} = \sqrt{E[Y^2] - \mu_Y^2}$.

Nota:

- **Covarianza:** Mide la variación conjunta de dos variables respecto a sus respectivas medias (μ_X y μ_Y). Responde a la pregunta: "Cuando X está por encima de su promedio, ¿Y tiende a estar por encima o por debajo del suyo?".
- **Correlación:** Es la covarianza estandarizada (o adimensional). Se obtiene dividiendo la covarianza por el producto de las **desviaciones estándar** ($\sigma_X \sigma_Y$).

Teorema 4.5.3
Descomposición de la covarianza.
Para cualesquiera variables aleatorias X e Y.

$$\text{Cov}(X, Y) = E[XY] - \mu_X \mu_Y.$$

Teorema 4.5.5
Covarianza y correlación de variables independientes.
Sean X e Y variables aleatorias independientes entonces $\text{Cov}(X,Y)=0$ y $\rho_{XY}=0$.

Teorema 4.5.6
Varianza de una suma de variables aleatorias.
Si X e Y son dos variables aleatorias cualesquiera, y a y b son dos constantes cualesquiera, entonces

$$\text{Var}(aX+bY)=a^2\ \text{Var}(X)+b^2\ \text{Var}(Y)+2ab\ \text{Cov}(X,Y).$$

Si X e Y son variables aleatorias independientes, entonces

$$\text{Var}(aX+bY)=a^2\ \text{Var}(X)+b^2\ \text{Var}(Y).$$

Teorema 4.5.7
Correlación y relación lineal.
Para cualesquiera variables aleatorias X e Y,

a) $-1\leq\rho_{XY}\leq 1$.

b) $|\rho_{XY}|=1$ si y solo si existen números $a\neq 0$ y b tales que $P(Y=aX+b)=1$. Si $\rho_{XY}=1$ entonces $a>0$, y si $\rho_{XY}=-1$ entonces $a<0$.

Nota: Si $\rho_{XY}=1$ entonces si X aumenta, Y también y si $\rho_{XY}=-1$ entonces si X aumenta, Y decrece.

Definición 5.1.1
Las variables aleatorias $X_1,\ldots,X_n$ se denominan una **muestra aleatoria** de tamaño n de la población $f(x)$ si $X_1,\ldots,X_n$ son variables aleatorias mutuamente independientes y la fdp o fpp marginal de cada X_i es la misma función $f(x)$.
Alternativamente, $X_1,\ldots,X_n$ se denominan **variables aleatorias independientes e idénticamente distribuidas** con fdp o fpp $f(x)$. Esto se abrevía comúnmente como **variables aleatorias i.i.d**.

Nota: Es la incertidumbre de lo que se obtiene la muestra aleatoria, y después de medir se convierte en un conjunto de números fijos o datos observados.

Definición 5.2.1, 5.2.2, 5.2.3
Sean $X_1,\ldots,X_n$ una muestra aleatoria de tamaño n de una población y sea $T(x_1,\ldots,x_n)$ una función de valor real o vectorial cuyo dominio incluye el espacio muestral de $(X_1,\ldots,X_n)$. Entonces, la variable aleatoria o vector aleatorio $Y=T(X_1,\ldots,X_n)$ se denomina **estadístico**. La distribución de probabilidad de un estadístico Y se denomina distribución muestral de Y.

La **media muestral** es el promedio aritmético de los valores en una muestra aleatoria. Generalmente se denota por

$$\bar{X}=\frac{X_1+\ldots+X_n}{n}=\frac{1}{n}\sum_{i=1}^{n}X_i.$$

La **varianza muestral** es el estadístico definido por

$$S^2=\frac{1}{n-1}\sum_{i=1}^{n}\left(X_i-\bar{X}\right)^2.$$

Nota: El estadístico entonces es una regla para resumir toda tu muestra en un número o vector calculable.

La media muestral es un estimador insesgado (en promedio, acierta exactamente al valor real del parámetro poblacional que intenta medir, no tiene una desviación o sesgo hacia arriba o abajo) de la media poblacional (μ).

Teorema 5.2.4
Sean $x_1, ..., x_n$ números cualesquiera y $\bar{x} = \frac{x_1+...+x_n}{n}$. Entonces **Promedio minimiza la varianza; descomposición de la varianza.**

a) $\min_a \sum_{i=1}^n (x_i - a)^2 = \sum_{i=1}^n (x_i - \bar{x})^2$

b) $(n-1)s^2 = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$

Nota:

a) Si buscas un número a que represente a un conjunto de datos minimizando el error cuadrático total (la suma de las distancias al cuadrado de cada dato a ese valor a), el mejor valor posible a es la media aritmética $\bar{x}$.

b) Esta igualdad proporciona una fórmula computacional rápida (conocida como el teorema de la suma de cuadrados). Permite calcular la suma de desviaciones cuadráticas sin necesidad de restar la media $\bar{x}$ a cada dato individualmente uno por uno.

Lema 5.2.5
Esperanza y varianza de una función de una muestra aleatoria.
Sean $X_1, ..., X_n$ una muestra aleatoria de una población y sea $g(x)$ una función tal que $E[g(X_1)]$ y $\text{Var}(g(X_1))$ existen. Entonces

$$E\left(\sum_{i=1}^n g(X_i)\right) = n(E[g(X_1)])$$

y

$$\text{Var}\left(\sum_{i=1}^n g(X_i)\right) = n(\text{Var}(g(X_1))).$$

Teorema 5.2.6
Valor esperado y varianza de las medias muestrales. Valor esperado de la varianza muestral.
Sean $X_1, ..., X_n$ una muestra aleatoria de una población con media μ y varianza $\sigma^2 < \infty$. Entonces

a) $E[\bar{X}] = \mu$,

b) $\text{Var}\,(\bar{X}) = \frac{\sigma^2}{n}$,

c) $E[S^2] = \sigma^2$.

Clase 8. Teorema Central del limite. Estimación puntual.

(referencias a Casella Berger 2024)

Teorema Central del Límite

Teorema 5.3.1
Propiedades de media y varianza de una normal.
Sean $X_1, ..., X_n$ una muestra aleatoria de una distribución $N(\mu, \sigma^2)$, y sean $\bar{X} = \left(\frac{1}{n}\right)\sum_{i=1}^n X_i$ y $S^2 = \left[\frac{1}{n-1}\right]\sum_{i=1}^n \left(X_i - \bar{X}\right)^2$. Entonces

a) $\bar{X}$ y S^2 son variables aleatorias independientes,

b) $\bar{X}$ tiene una distribución $N\left(\mu, \frac{\sigma^2}{n}\right)$,

c) $(n-1)\frac{S^2}{\sigma^2}$ tiene una distribución chi-cuadrada ($\mathcal{X}^2$) con $n-1$ grados de libertad.

Distribución chi-cuadrada ($\mathcal{X}^2$):
$X \sim \mathcal{X}^2$ si $f(x|p) = \frac{1}{\Gamma(\frac{p}{2})2^{\frac{p}{2}}} x^{\frac{p}{2}-1} e^{-\frac{x}{2}}$ con $0 < x < \infty$ $p =$ "grados de libertad".

Definición 5.5.1
Una secuencia de variables aleatorias, $X_1, X_2, \ldots$, **converge en probabilidad** a una variable aleatoria X si, para todo $\varepsilon > 0$,

$$\lim_{n\to\infty} P(|X_n - X| \geq \varepsilon) = 0, \text{o, equivalentemente, } \lim_{n\to\infty} P(|X_n - X| < \varepsilon) = 1.$$

Las $X_1, X_2, \ldots$ en la Definición 5.5.1 (y las otras definiciones en esta sección) típicamente no son variables aleatorias independientes e idénticamente distribuidas, como en una muestra aleatoria. La distribución de X_n cambia a medida que cambia el subíndice, y los conceptos de convergencia discutidos en esta sección describen diferentes formas en las que la distribución de X_n converge a alguna distribución límite a medida que el subíndice se vuelve grande.

Teorema 5.5.2
Ley Débil de los Grandes Números.
Sean $X_1, X_2, \ldots$ variables aleatorias i.i.d. con $E[X_i] = \mu$ y Var $(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = \left(\frac{1}{n}\right)\sum_{i=1}^n X_i$. Entonces, para todo $\varepsilon > 0$,

$$\lim_{n\to\infty} P\left(|\bar{X}_n - \mu| < \varepsilon\right) = 1,$$

es decir, $\bar{X}_n$ converge en probabilidad a μ.

Definición 5.5.10
Una secuencia de variables aleatorias, $X_1, X_2, \ldots$, **converge en distribución** a una variable aleatoria X si

$$\lim_{n\to\infty} F_{X_n}(x) = F_X(x),$$

en todos los puntos x donde $F_X(x)$ es continua.

Teorema 5.5.15
Forma más Fuerte del Teorema del Límite Central.
Sean $X_1, X_2, \ldots$ una secuencia de variables aleatorias i.i.d. (idénticamente distribuidas) con $E[X_i] = \mu$ y $0 <$ Var $(X_i) = \sigma^2 < \infty$. Defínase $\bar{X}_n = \left(\frac{1}{n}\right)\sum_{i=1}^n X_i$. Sea $G_n(x)$ la fda de $\sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}$. Entonces, para todo x, $-\infty < x < \infty$,

$$\lim_{n\to\infty} G_n(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dy,$$

es decir, $\sqrt{n}\frac{\bar{X}_n - \mu}{\sigma}$ tiene una distribución normal estándar límite.

Nota: Te dice que sin importar qué distribución tengan tus datos originales (pueden ser continuos, discretos, simétricos, sesgados, exponenciales, de Poisson, etc.), la suma o el promedio de un número grande de variables aleatorias independientes e idénticamente distribuidas siempre se aproximará a una distribución Normal (Campana de Gauss). Es para hacer estadística sin saber la población.

Estimación puntual

Definición 7.1.1

Un **estimador puntual** es cualquier función $W(X_1, ..., X_n)$ de una muestra. O sea, cualquier estadístico es un punto estimador.

Sección 7.2.1

Método de los momentos para la normal / encontrar estimadores.

Sean $X_1, ..., X_n$ una muestra de una población con fdp o fpm $f(x \mid \theta_1, ..., \theta_k)$. Los estimadores del método de los momentos se obtienen igualando los primeros k momentos muestrales a los correspondientes k momentos poblacionales, y resolviendo el sistema de ecuaciones simultáneas resultante. Más precisamente, se define:

$$\begin{aligned} m_1 &= \frac{1}{n}\sum_{i=1}^{n} X_i^1, \mu_{1'} = E[X^1] \\ m_2 &= \frac{1}{n}\sum_{i=1}^{n} X_i^2, \mu_{2'} = E[X^2] \\ &\vdots \\ m_k &= \frac{1}{n}\sum_{i=1}^{n} X_i^k, \mu_{k'} = E[X^k]. \end{aligned}$$

El momento poblacional μ_j' típicamente será una función de $\theta_1, ..., \theta_k$, digamos $\mu'_{j(\theta_1,...,\theta_k)}$. El **estimador del método de los momentos (EMM)** $\left(\tilde{\theta}_1, ..., \tilde{\theta}_k\right)$ de $(\theta_1, ..., \theta_k)$ se obtiene resolviendo el siguiente sistema de ecuaciones para $(\theta_1, ..., \theta_k)$ en términos de $(m_1, ..., m_k)$:

$$\begin{aligned} m_1 &= \mu_1'(\theta_1, ..., \theta_k), \\ m_2 &= \mu_2'(\theta_1, ..., \theta_k), \\ &\vdots \\ m_k &= \mu'_{k(\theta_1,...,\theta_k)}. \end{aligned}$$

Nota: El Método de los Momentos (MM) es una técnica para encontrar estimadores de los parámetros desconocidos de una población. Su idea central es muy directa: igualar los momentos teóricos (poblacionales) con los momentos muestrales (calculados con los datos) y resolver el sistema de ecuaciones resultante.

Sección 7.2.2

Método de máxima verosimilitud para encontrar estimadores.

Sea $X_1, ..., X_n$ una muestra aleatoria con fdp / fpp $f(X(\Theta_1, ..., \Theta_k))$. Definimos la **función de verosimilitud** como

$$L(\Theta_1, ..., \Theta_k \mid X_a, ..., X_n) = \prod_{i=1}^{n} f(X_i \mid \Theta_1, ..., \Theta_k)$$

Nota: La L es de likelihood. El Método de Máxima Verosimilitud busca encontrar los valores de los parámetros desconocidos que hacen que los datos que ya observaste en tu muestra sean lo más probables posible de haber ocurrido.

Definición 7.2.4

Estimador de máxima verosimilitud.

Dada la muestra busco los $\Theta_1, ..., \Theta_k$ tal que $L(\Theta_1, ..., \Theta_k \mid X_a, ..., X_n)$ es máxima. Busco $\hat{\Theta}(X_i)$ tal que $L(\Theta, X_1, ..., X_n)$ es máxima.

Definición 7.3.1
Error cuadrático medio de un estimador.
El error cuadrático medio (MSE) de un estimador W de un parámetro θ es la función de θ definida por $E_\theta(W-\theta)^2$.

$$E_\theta[(W-\theta)^2] = \mathrm{Var}_\theta(W) + (E_\theta[W]-\theta)^2 = \mathrm{Var}_\theta(W) + (\mathrm{Sesgo}_\theta(W))^2,$$

Nota: Métrica principal en estadística para evaluar la calidad o precisión general de un estimador. Responde a la pregunta: "En promedio, ¿qué tan lejos cae mi estimación respecto al verdadero valor del parámetro θ?". El sesgo mide qué tan desviado está el valor esperado del estimador respecto al parámetro objetivo θ.

Definición 7.3.2
El **sesgo de un estimador** puntual W, de un parámetro θ, es la diferencia entre el valor esperado de W y θ. Es decir, $\mathrm{Sesgo}_\theta(W) = E_\theta[W]-\theta$. Un estimador cuyo sesgo es idénticamente (en θ) igual a cero se llama **insesgado** y satisface $E_\theta[W]=\theta$ para todo θ.

Para un estimador insesgado tenemos

$$E_\theta[(W-\theta)^2] = \mathrm{Var}_\theta(W),$$

y por lo tanto, si un estimador es insesgado, su MSE es igual a su varianza.

Clase 9. Intervalos de confianza.

(referencias al pdf - varios puntos de bibliografía)

Nota: Un intervalo de confianza sirve para responder a una pregunta fundamental en estadística: ¿Cómo puedo estimar un valor real de toda una población si solo tengo una muestra de datos?

Distribuciones continuas fundamentales para la inferencia

Teniendo a $Z \sim N(0,1)$ y construimos $X = \sum_{i=1}^{k} Z_i^2$, entonces $X = \chi^2$

Distribución Chi-Cuadrado (χ^2)

$X \sim \chi^2_n$

$f(x) = \frac{1}{2^{\frac{k}{2}}\Gamma(\frac{k}{2})} x^{(\frac{k}{2})-1} e^{-\frac{x}{2}}$ con k "grados de libertad" y Γ es la función gamma.

$E[X] = k$

$\mathrm{Var}(X) = 2k$

Distribución T de Student

$f(t) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi\nu}\Gamma(\frac{\nu}{2})}$ con ν "grados de libertad" y Γ es la función gamma.

$E[T] = 0$ si $\nu > 1$ (indefinido en otro caso pues Cauchy) $\mathrm{Var}(T) = \frac{\nu}{\nu-2}$ si $\nu > 2$ (indefinida o infinita en otro caso)

Nota: Los "grados de libertad" son:
En χ^2: Representa cuántas normales Z^2 independientes se sumaron.En t de Student: Representa la precisión con la que se estimó la variabilidad muestral; a mayor número de grados de libertad, más se parece a la distribución Normal $N(0,1)$.

Propiedades

A medida de que la ν de la distribución de Cauchy tiende al infinito, esta tiende a una distribución Normal.

Si $U \sim N(0,1)$; $V \sim \mathcal{X}^2_k$, construimos:

$T = \frac{U}{\sqrt{\frac{V}{k}}}$ (U y V independientes), entonces

$T \sim \text{Student } (k)$

Intervalos de confianza

Si $X_1, ..., X_n \sim N(\mu, \sigma^2)$ (muestra de distribución normal), entonces la media muestral $\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$ y construimos $U = \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$, entonces $U \sim N(0,1)$ (normal estándar).

Similar a con una variable aleatoria puedo calcular la probabilidad de que U o $\bar{X}$ esté en un cierto intervalo:

$P(-1,96 \leq U \leq 1,96) = 0,95$

$P\left(-1,96 \leq \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \leq 1,96\right) = 0,95$

$P\left(\mu - 1,96\frac{\sigma}{\sqrt{n}} \leq \bar{X} \leq \mu + 1,96\frac{\sigma}{\sqrt{n}}\right) = 0,95$

Pero también se podría calcular la probabilidad:

$P\left(\bar{X} - 1,96\frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1,96\frac{\sigma}{\sqrt{n}}\right) = 0,95$

O sea, el intervalo que tiene probabilidad 95% de incluir a μ en este.

Generalizado

Sea $X_1, ..., X_n$ una muestra aleatoria de una distribución con parámetro θ. Dadas dos funciones de la muestra $a(X_1...X_n)$ y $b(X_1...X_n)$ tales que:

$$P(a(X_1...X_n) \leq \theta \leq b(X_1...X_n)) = 1 - \alpha$$

con α chico, entonces el intervalo $[a(X_1...X_n); b(X_1...X_n)]$ se denomina **intervalo de confianza de nivel $1 - \alpha$** para el parámetro θ.

Posibles interpretaciones:

- La probabilidad de que el intervalo de confianza contenga al valor de μ es 95% (en el mismo sentido de la probabilidad de cualquier variable aleatoria).
- Dados muchas realizaciones de la variable aleatoria "intervalo de confianza", el 95% de ellas incluirá el valor de μ.

Desarrollo de los posibles casos para Población Normal

Dada una muestra aleatoria $X_1, ..., X_n$ de una población $N(\mu, \sigma^2)$:

1. Parámetro μ con σ^2 conocida

- **Pivote:** $Z = \frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$
- **Fórmula del IC:**

$$\text{IC}_{1-\alpha}(\mu) = \left[\bar{X} - z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}},\ \bar{X} + z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}\right]$$

2. Parámetro μ con σ^2 desconocida

- **Pivote:** $T = \frac{\bar{X}-\mu}{\frac{S}{\sqrt{n}}} \sim t_{n-1}$ donde $S^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \bar{X}\right)^2$
- **Fórmula del IC:**

$$\mathrm{IC}_{1-\alpha}(\mu) = \left[\bar{X} - t_{n-1,\frac{\alpha}{2}}\frac{S}{\sqrt{n}},\ \bar{X} + t_{n-1,\frac{\alpha}{2}}\frac{S}{\sqrt{n}}\right]$$

3. Parámetro σ^2 con μ conocida

- **Pivote:** $V = \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} \sim \mathcal{X}^2_n$
- **Fórmula del IC:**

$$\mathrm{IC}_{1-\alpha}(\sigma^2) = \left[\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\mathcal{X}^2_{n,\frac{\alpha}{2}}},\ \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\mathcal{X}^2_{n,1-\frac{\alpha}{2}}}\right]$$

4. Parámetro σ^2 con μ desconocida

- **Pivote:** $V = \frac{(n-1)S^2}{\sigma^2} \sim \mathcal{X}^2_{n-1}$
- **Fórmula del IC:**

$$\mathrm{IC}_{1-\alpha}(\sigma^2) = \left[\frac{(n-1)S^2}{\mathcal{X}^2_{n-1,\frac{\alpha}{2}}},\ \frac{(n-1)S^2}{\mathcal{X}^2_{n-1,1-\frac{\alpha}{2}}}\right]$$

Resumen de Pivotes y Fórmulas de IC

Parámetro	Condición	Pivote	Distribución	Intervalo de Confianza (IC)
μ	σ^2 conocida	$\frac{\bar{X}-\mu}{\frac{\sigma}{\sqrt{n}}}$	$N(0,1)$	$\bar{X} \pm z_{\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}}$
μ	σ^2 desconocida	$\frac{\bar{X}-\mu}{\frac{S}{\sqrt{n}}}$	t_{n-1}	$\bar{X} \pm t_{n-1,\frac{\alpha}{2}}\frac{S}{\sqrt{n}}$
σ^2	μ conocida	$\frac{\sum(X_i-\mu)^2}{\sigma^2}$	$\mathcal{X}^2_n$	$\left[\frac{\sum(X_i-\mu)^2}{\mathcal{X}^2_{n,\frac{\alpha}{2}}}; \frac{\sum(X_i-\mu)^2}{\mathcal{X}^2_{n,1-\frac{\alpha}{2}}}\right]$
σ^2	μ desconocida	$\frac{(n-1)S^2}{\sigma^2}$	$\mathcal{X}^2_{n-1}$	$\left[\frac{(n-1)S^2}{\mathcal{X}^2_{n-1,\frac{\alpha}{2}}}; \frac{(n-1)S^2}{\mathcal{X}^2_{n-1,1-\frac{\alpha}{2}}}\right]$

Método general para obtener el intervalo de confianza para un parámetro

Sea una muestra $X_1 ... X_n$ de una distribución que depende de un parámetro θ. Supongamos que existe una función $T(X_1 ... X_n, \theta)$ cuya distribución no depende de θ ni de ningún otro parámetro desconocido. Entonces dado α existen dos valores a y b tales que:

$$P(a \leq T(X_1 ... X_n, \theta) \leq b) = 1 - \alpha$$

a partir de lo cual se puede obtener un intervalo de confianza de nivel $1-\alpha$ para θ. La función $T(X_1 ... X_n, \theta)$ se denomina **"pivote"**.

Intervalos de confianza asintóticos (Muestras Grandes)

Sea $X_1 ... X_n$ una muestra aleatoria de una distribución desconocida con $E[X] = \mu$ y $\mathrm{Var}(X) = \sigma^2$. Buscamos un intervalo de confianza para μ. Sabemos que la media muestral estima bien μ, pero no conocemos qué distribución tiene la media muestral. Sin embargo sabemos que:

$$\sqrt{n}\frac{\bar{X}-\mu}{\sigma} \xrightarrow{d} N(0,1)$$

Usemos S^2 para estimar σ^2:

$\sqrt{n}\frac{\bar{X}-\mu}{\sigma} \xrightarrow{d} N(0,1)$

$\frac{\sigma}{S} \xrightarrow{P} 1 \Rightarrow \sqrt{n}\frac{\bar{X}-\mu}{S} \xrightarrow{d} N(0,1)$

- **Fórmula del IC Asintótico:**

$$\text{IC}_{1-\alpha}(\mu) \approx \left[\bar{X} - z_{\frac{\alpha}{2}}\frac{S}{\sqrt{n}},\ \bar{X} + z_{\frac{\alpha}{2}}\frac{S}{\sqrt{n}}\right]$$

Determinación del tamaño de una muestra

Tomemos una distribución normal con σ^2 conocida para ejemplificar. El semiancho (o margen de error E) del intervalo de confianza para el parámetro μ es:

$$E = z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}$$

Por lo tanto, la longitud total del intervalo es $L = 2E = 2z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}}$.

¿Qué tamaño de muestra necesito para asegurar un máximo largo L_0 del intervalo de confianza (o un margen de error máximo $E_0 = \frac{L_0}{2}$)?

$$L = 2z_{\alpha/2}\frac{\sigma_0}{\sqrt{n}} \leq L_0 \Leftrightarrow \sqrt{n} \geq \frac{2z_{\alpha/2}\sigma_0}{L_0} \Leftrightarrow n \geq \left(\frac{2z_{\alpha/2}\sigma_0}{L_0}\right)^2$$

- **Fórmula resumida para el tamaño muestral n:**

$$n \geq \left(\frac{z_{\alpha/2}\sigma_0}{E_0}\right)^2$$

Clase 10. Contraste de hipótesis.

(referencias al pdf - varios puntos de bibliografía)

Error estándar de un estimador

Definición: El error estándar de un estimador es la desviación estándar de su distribución .

$$\text{SE}_{\hat{\theta}} = \sqrt{\text{Var}\left(\hat{\theta}\right)}$$

Medida de la "incerteza" o variabilidad que tenés en dicha estimación.

Nota: Muestra de tamaño n de una distribución subyacente $N(\mu, \sigma^2)$, estimamos $\hat{\mu} = \bar{X}$

Relación entre error estándar e intevalo de confianza

Sea una muestra $X_1 ... X_n$ de una distribución $N(\mu, \sigma^2)$. Calculemos el intervalo de confianza del $68\%(\alpha = 0.32)$ para μ suponiendo conocida σ^2:

$\text{IC}_{\mu}^{1-\alpha} = \left[\bar{X} - z_{\alpha/2}\frac{\alpha}{\sqrt{n}}; \bar{X} + z_{\alpha/2}\frac{\alpha}{\sqrt{n}}\right]$

$\text{IC}_{\mu}^{0.68} = \left[\bar{X} - z_{0.16}\frac{\alpha}{\sqrt{n}}; \bar{X} + z_{0.16}\frac{\alpha}{\sqrt{n}}\right]$

$\text{IC}_{\mu}^{0.68} = \left[\bar{X} - \frac{\alpha}{\sqrt{n}}; \bar{X} + \frac{\alpha}{\sqrt{n}}\right]$ Porque $z_{0.16} \sim 1$ (busco z normal estándar tal que $P(Z > z) = 0.16$)

$\text{IC}_{\mu}^{0.68} = \left[\bar{X} - \text{SE}_{\mu}; \bar{X} + \text{SE}_{\mu}\right]$ un error estándar para cada lado

Esto se reporta: $\hat{\mu} = \bar{X} \pm \text{SE}_{\mu}$

Regla mnemotécnica "68-95-99"

$\text{IC}_{\mu}^{68\%} \sim \bar{X} \pm 1\sigma_{\bar{X}}$

$\text{IC}_{\mu}^{95\%} \sim \bar{X} \pm 2\sigma_{\bar{X}}$

$\text{IC}_{\mu}^{99\%} \sim \bar{X} \pm 3\sigma_{\bar{X}}$

Nota: p-valor = probabilidad del valor observado del estadístico o uno más extremo asumiendo que la hipótesis nula es verdadera.

Clase 11. Otros contrastes comunes. Comparaciones múltiples.

Acá en las referencias del Cetinkaya-Rundel & Hardin 2024 tengan en cuenta que esos capítulos están organizados con una primera sección de Bootstrapping (que todavía no vimos) pero las secciones que siguen se entienden sin eso.

1. Contrastes para Proporciones (Estadístico Z)

Los contrastes de proporciones se basan en modelar los datos como ensayos de Bernoulli, donde la proporción de éxitos está bien modelada por el parámetro p de una Binomial. Por el Teorema del Límite Central, para muestras grandes la distribución se aproxima a una Normal estándar.

Contraste para una proporción:

- **Objetivo:** Comparar una proporción muestral $\hat{p}$ contra un valor de hipótesis nula p_0.
- **Estadístico:**

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

- **Condiciones:** Observaciones independientes y tamaño de muestra suficientemente grande ($np_0 \geq 10$ y $n(1-p_0) \geq 10$).
- **Regiones de rechazo:** Dependiendo de la hipótesis alternativa, se rechaza H_0 si $Z \leq -z_\alpha$, $Z \geq z_\alpha$, o $|Z| \geq z_{\alpha/2}$.

Contraste para dos proporciones:

- **Objetivo:** Comparar si dos proporciones muestrales ($\hat{p}_1$ y $\hat{p}_2$) difieren significativamente entre sí.
- **Proporción combinada (Pooled proportion):** Bajo $H_0 : p_1 - p_2 = 0$, se asume que ambas muestras provienen de la misma población, por lo que se estima una proporción conjunta para calcular el error estándar:

$$\hat{p}_{\text{pool}} = \frac{\hat{p}_1 n_1 + \hat{p}_2 n_2}{n_1 + n_2}$$

- **Estadístico:**

$$Z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}_{\text{pool}}(1 - \hat{p}_{\text{pool}})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

2. Contrastes para Medias (Estadístico T de Student)

Se utilizan cuando se trabaja con medias muestrales desconociendo la varianza poblacional (utilizando en su lugar la desviación estándar muestral s).

Contraste para una media:

- **Objetivo:** Comparar la media muestral $|x|$ con un valor nulo poblacional.
- **Estadístico:**

$$T = \frac{|x| - \text{valor nulo}}{\frac{s}{\sqrt{n}}}$$

- **Distribución:** Sigue una distribución t con $df = n - 1$ grados de libertad.

Contraste para dos medias independientes:
- **Objetivo:** Comparar las medias de dos grupos distintos (ej. dos versiones de un examen) asumiendo independencia entre observaciones.
- **Estadístico:**

$$T = \frac{|x|_1 - |x|_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

- **Distribución:** Sigue una distribución t con $df = \min(n_1 - 1, n_2 - 1)$ grados de libertad.

Contraste para dos medias pareadas (Paired data):
- **Objetivo:** Comparar observaciones con una correspondencia directa uno a uno (ej. temperatura en el mismo grupo de personas antes y después de un tratamiento).
- **Método:** Se calcula la diferencia para cada par y el problema se reduce a un test de una sola muestra sobre esas diferencias ($|x|_{\text{diff}}$).
- **Estadístico:**

$$T = \frac{|x|_{\text{diff}} - 0}{\frac{s_{\text{diff}}}{\sqrt{n_{\text{diff}}}}}$$

3. El Problema de las Comparaciones Múltiples
- **Inflación del Error Tipo I:** Al realizar múltiples contrastes de hipótesis simultáneos sobre un mismo conjunto, por simple chance es probable obtener diferencias significativas falsas. La probabilidad de rechazar incorrectamente al menos una hipótesis nula verdadera (Family-wise error rate) escala rápidamente.
- **Ejemplo:** Con 100 pruebas independientes a un nivel de confianza del 95%, la probabilidad de obtener al menos un falso positivo sube al 99.4%.
- **Corrección de Bonferroni:** Para garantizar que la tasa máxima global de falsos positivos se mantenga acotada a un valor α, se debe exigir un nivel de significación más estricto a cada comparación individual.
- **Fórmula de corrección:**

$$\gamma = 1 - \frac{\alpha}{m}$$

  Donde m es el número total de contrastes y la tasa ajustada disminuye en proporción a la cantidad de comparaciones.

Clase 12. Regresión lineal simple.
(referencias a Casella Berger 2024)

1. Modelo Estadístico y Supuestos
La regresión lineal simple busca estimar la relación entre una variable de respuesta Y y una covariable o variable predictiva x.
- **Modelo poblacional:** La relación asume linealidad en los parámetros y se expresa como $E(Y_i \mid x_i) = \alpha + \beta x_i$.

- **Modelo Condicional Normal:** Desde el punto de vista estadístico, se asume que las observaciones Y_i son normales e independientes, con una varianza constante σ^2:

$$Y_i \sim N(\alpha + \beta x_i, \sigma^2) \qquad \text{o bien} \qquad Y_i = \alpha + \beta x_i + \varepsilon_i$$

  Donde los errores ε_i son independientes e idénticamente distribuidos (iid) según $N(0, \sigma^2)$.

2. Estimación de Parámetros

Método de Cuadrados Mínimos y Máxima Verosimilitud: Se busca minimizar la Suma de los Residuos Cuadrados (RSS), que representa la distancia vertical entre cada punto observado y la recta predictiva:

$$\text{RSS} = \sum_{i=1}^{n} (y_i - (a + bx_i))^2$$

Los estimadores obtenidos por cuadrados mínimos coinciden con los estimadores de Máxima Verosimilitud bajo el modelo normal:

- **Pendiente:** $\hat{\beta} = b = \frac{S_{\{xy\}}}{S_{\{xx\}}}$
- **Ordenada al origen:** $\hat{\alpha} = a = |y| - b|x|$

(Nota: La regresión es asimétrica; el modelo de regresar Y en X produce una pendiente distinta que el de regresar X en Y).

Estimación de la varianza del error (σ^2): El estimador de máxima verosimilitud para σ^2 es sesgado. Por ello, se utiliza el estimador insesgado basado en los residuos y los grados de libertad:

$$S^2 = \frac{1}{n-2} \sum_{i=1}^{n} \left(y_i - \hat{\alpha} - \hat{\beta} x_i\right)^2 = \frac{\text{RSS}}{n-2}$$

3. Inferencia Estadística

Bajo el modelo condicional normal, los estimadores permiten realizar contrastes de hipótesis e intervalos de confianza.

- **Distribución de la pendiente estimada:** Sigue una distribución Normal, pero al utilizar la varianza muestral S^2, el estadístico pivote sigue una distribución t de Student:

$$\frac{\hat{\beta} - \beta}{\frac{S}{\sqrt{S_{\{xx\}}}}} \sim t_{\{n-2\}}$$

Contraste de hipótesis para la pendiente ($H_0 : \beta = 0$): Sirve para evaluar si existe evidencia significativa de una relación lineal.

- Se rechaza H_0 a nivel α si $|\frac{\hat{\beta}-0}{\frac{S}{\sqrt{S_{\{xx\}}}}}| > t_{\{n-2, \frac{\alpha}{2}\}}$.
- De forma equivalente, puede evaluarse mediante el estadístico F de Snedecor-Fisher ($F = \frac{\hat{\beta}^2}{S^2/S_{\{xx\}}}$).

4. Análisis de Varianza (ANOVA) y Bondad del Ajuste

Descomposición de la suma de cuadrados: La variación total de las observaciones se descompone en la parte explicada por el modelo de regresión y la variación residual (errores):

$$\text{Total SS} = \text{Regression SS} + \text{Residual SS}$$

Coeficiente de Determinación (r^2): Cuantifica qué tan bien se ajusta la recta a los datos. Representa la proporción de la variación total en Y que logra ser explicada por la covariable x.

$$r^2 = \frac{\text{Regression SS}}{\text{Total SS}} = \frac{S_{\{xy\}}^2}{S_{\{xx\}} S_{\{yy\}}}$$

- Se cumple que $0 \leq r^2 \leq 1$. Si $r^2 = 1$, todos los puntos caen exactamente sobre la recta trazada.

5. Bandas de Confianza para la Regresión

Se pueden construir intervalos de confianza simultáneos para la recta de regresión a lo largo de todo el espectro de valores de x.

- Con una confianza de al menos $1 - \alpha$, el valor medio esperado $\alpha + \beta x$ cae simultáneamente en el intervalo:

$$\hat{\alpha} + \hat{\beta} x \pm M_\alpha S \sqrt{\frac{1}{n} + \frac{(x - |x|)^2}{S_{\{xx\}}}}$$

  Donde el factor de amplitud es $M_\alpha = \sqrt{2F_{\{2,n-2,\alpha\}}}$ (esto deriva de aplicar métodos de corrección como Bonferroni o Scheffé para comparaciones múltiples).

Clase 13. Análisis de Varianza (ANOVA de un factor).

1. Concepto y Modelo Estadístico

El Análisis de Varianza (ANOVA) se utiliza para comparar simultáneamente las medias de tres o más grupos o tratamientos poblacionales.

Modelo poblacional: Cada observación se modela como la suma de la media de su grupo y un error aleatorio:

$$Y_{\{ij\}} = \theta_i + \varepsilon_{\{ij\}} \qquad \text{o equivalentemente} \qquad Y_{\{ij\}} = \mu + \alpha_i + \varepsilon_{\{ij\}}$$

Donde $Y_{\{ij\}}$ es la observación j del grupo i, θ_i es la media del grupo i (o μ la media global y α_i el efecto del tratamiento), y $\varepsilon_{\{ij\}}$ es el error aleatorio.

Supuestos del modelo (Oneway ANOVA):

a) **Esperanza nula:** $E\left(\varepsilon_{\{ij\}}\right) = 0$.
b) **Normalidad e Independencia:** Los errores $\varepsilon_{\{ij\}}$ son variables aleatorias independientes y siguen una distribución Normal.
c) **Homocedasticidad:** Todos los grupos tienen la misma varianza poblacional ($\sigma_i^2 = \sigma^2$ para todo i).

2. Contraste de Hipótesis

- **Hipótesis Nula (H_0):** No hay diferencia entre las medias de los grupos.

$$H_0 : \theta_1 = \theta_2 = \ldots = \theta_k$$

- **Hipótesis Alternativa (H_1):** Al menos una de las medias poblacionales difiere del resto.

$$H_1 : \theta_i \neq \theta_j \qquad \text{para algún par } i, j$$

Lógica del contraste: El método consiste en comparar dos fuentes de variabilidad:

- **Varianza Intergrupo (Between):** La dispersión que hay **entre** las medias de los distintos grupos y la media global.
- **Varianza Intragrupo (Within):** La dispersión que hay **dentro** de cada grupo respecto a su propia media.

Si la varianza intergrupo es significativamente mayor que la intragrupo, se concluye que los grupos son distinguibles (se rechaza H_0).

3. Estadístico de Prueba

El estadístico para este contraste es el estadístico F de Fisher-Snedecor, que es el cociente de dos variables independientes con distribución χ^2.

1. Cuadrado Medio Intragrupo (MSW / Pooled Variance S_p^2): Estima la varianza común σ^2 promediando las varianzas muestrales de cada grupo.

$$\text{MSW} = S_p^2 = \frac{1}{N-k} \sum_{i=1}^{k} \sum_{j=1}^{n_i} \left(Y_{\{ij\}} - |Y|_i \right)^2$$

2. Cuadrado Medio Intergrupo (MSB): Mide la dispersión de las medias muestrales de los grupos ($|Y|_i$) respecto a la media global ($||Y||$).

$$\text{MSB} = \frac{1}{k-1} \sum_{i=1}^{k} n_i (|Y|_i - ||Y||)^2$$

3. Estadístico F:

$$F = \frac{\text{MSB}}{\text{MSW}}$$

Bajo H_0, este estadístico sigue una distribución F con $k-1$ grados de libertad en el numerador y $N-k$ grados de libertad en el denominador (donde k es la cantidad de grupos y N la cantidad total de observaciones).

- **Región de rechazo:** Se rechaza H_0 si $F > F_{\{k-1, N-k, \alpha\}}$.

4. Tabla ANOVA

Los resultados suelen resumirse en una tabla estándar que descompone la Suma de Cuadrados Total (SST = SSB + SSW):

Fuente de variación	Grados de libertad	Suma de cuadrados	Cuadrados Medios	Estadístico F
Entre grupos (Inter)	$k-1$	SSB	MSB = SSB / $(k-1)$	$F = \frac{\text{MSB}}{\text{MSW}}$
Dentro de grupos (Intra)	$N-k$	SSW	MSW = SSW / $(N-k)$	
Total	$N-1$	SST		

Clase 14. Regresión Logística.

1. Concepto y Modelo Estadístico

La regresión logística es un caso particular de los Modelos Lineales Generalizados (GLM) utilizado cuando la variable de respuesta Y es binaria (ej. Falló/No falló, Éxito/Fracaso).

- **Componente Aleatoria:** Las respuestas $Y_1, ..., Y_n$ son independientes y siguen una distribución de Bernoulli: $Y_i \sim \text{Bernoulli}(\pi_i)$, donde $E(Y_i) = \pi_i = P(Y_i = 1)$.
- **Función de Enlace (Link Logit):** Se relaciona la probabilidad de éxito π_i con la covariable x_i a través del logaritmo de los "odds" (chances):

$$\log\left(\frac{\pi_i}{1-\pi_i}\right) = \alpha + \beta x_i$$

- **Probabilidad Estimada:** Despejando π_i, la probabilidad en función de x adopta una forma sigmoidea (curva logística):

$$\pi(x) = \frac{e^{\alpha+\beta x}}{1+e^{\alpha+\beta x}}$$

2. Interpretación de los Parámetros

- **Ordenada al origen (α):** Es el log-odds (logaritmo de las chances) de éxito cuando la covariable es cero ($x = 0$).
- **Pendiente (β):** Representa el cambio en el log-odds de éxito ante un incremento de exactamente 1 unidad en la variable x:

$$\log\left(\frac{\pi(x+1)}{1-\pi(x+1)}\right) - \log\left(\frac{\pi(x)}{1-\pi(x)}\right) = \beta$$

  (A diferencia de la regresión lineal, donde β era el cambio absoluto en el valor medio de Y, aquí mide el cambio en la relación logarítmica de las probabilidades).

3. Inferencia Estadística y Contraste de Hipótesis

El contraste más importante evalúa si existe una relación significativa entre la variable predictora x y la respuesta binaria, planteando:

$$H_0 : \beta = 0 \qquad \text{vs} \qquad H_1 : \beta \neq 0$$

Existen dos pruebas principales para evaluar esta hipótesis (ambas válidas para muestras grandes):

1. Test de Wald (Basado en el estimador normalizado): Utiliza el estimador de máxima verosimilitud $\hat{\beta}$ y su error estándar.

$$Z = \frac{\hat{\beta}}{\text{se}\left(\hat{\beta}\right)}$$

- Bajo H_0 y con n grande, Z sigue aproximadamente una distribución Normal estándar $N(0,1)$.
- Se rechaza H_0 si $|Z| \geq z_{\frac{\alpha}{2}}$.

2. Test de Razón de Verosimilitud (Likelihood Ratio Test - LRT): Compara la verosimilitud del modelo completo (con β) frente al modelo nulo (donde $\beta = 0$ y $\hat{\alpha}_0$ depende solo de la proporción de éxitos muestrales).

$$-2\log\lambda(y^*) = 2\Big[\log L\Big(\hat{\alpha}, \hat{\beta} \mid y^*\Big) - \log L(\hat{\alpha}_0, 0 \mid y^*)\Big]$$

- Bajo H_0, el estadístico $-2\log\lambda$ sigue aproximadamente una distribución chi-cuadrado con 1 grado de libertad (χ^2_1).
- Se rechaza H_0 a nivel α si $-2\log\lambda \geq \chi^2_{1,\alpha}$.

Clase 15a. Modelos Lineales Generalizados (GLM).

1. Concepto General

Los Modelos Lineales Generalizados (GLM) proponen una abstracción que permite modelar la relación entre una variable dependiente (aleatoria) Y y una variable independiente x, cuando Y no sigue necesariamente una distribución Normal.

En lugar de modelar la esperanza directamente como una combinación lineal, se aplica una transformación general a la esperanza matemática de Y_i:

$$g[E(Y_i)] = \alpha + \beta x_i$$

Donde Y_i pertenece a una familia de distribuciones de tipo exponencial.

2. Las Tres Componentes de un GLM

Todo Modelo Lineal Generalizado está definido estrictamente por tres elementos estructurales:

a) **La componente aleatoria:** Las variables de respuesta $Y_1, ..., Y_n$ son independientes (aunque no idénticamente distribuidas), y provienen todas de la misma familia de distribuciones de tipo exponencial (por ejemplo: Normal, Bernoulli, Binomial, Poisson, Laplace, Exponencial, Gamma, etc.).
b) **La componente sistemática:** Es la parte estructural que involucra a la variable independiente. Su característica fundamental es que debe ser **lineal en los parámetros** (ejemplos válidos: $\alpha + \beta x_i$, $\alpha + \beta x_i^2$, $\alpha + \frac{\beta}{x_i}$).
c) **La función de enlace (Link $g(\mu)$):** Es la función matemática que relaciona o "enlaza" la componente aleatoria con la sistemática. Dicta cómo la esperanza de la variable dependiente se vincula con la combinación lineal de los parámetros:

$$g(E(Y_i)) = \alpha + \beta x_i$$

3. Casos Particulares Comunes

Dependiendo de la distribución elegida para la variable aleatoria y de la función de enlace asociada, se obtienen distintos modelos estadísticos clásicos:

Distribución (Y_i)	Función de Enlace (Link)	Ecuación del Modelo	Nombre Clásico
Normal	Identidad	$E(Y_i) = \alpha + \beta x_i$	Regresión Lineal Simple
Bernoulli	Logit	$\ln\left(\frac{E(Y_i)}{1-E(Y_i)}\right) = \alpha + \beta x_i$	Regresión Logística
Poisson	Logarítmica (Log)	$\ln(E(Y_i)) = \alpha + \beta x_i$	Regresión Poissoniana

---

Clase 15b. Bootstrapping (Remuestreo).

1. Concepto Fundamental

El **bootstrapping** es un método computacional utilizado para estimar la variabilidad de un estadístico y construir intervalos de confianza cuando no se conoce su varianza ni su distribución teórica subyacente.

Idea central: Se utiliza la muestra original empírica como si fuera la población. La distribución de los valores de una muestra (incluso si es relativamente chica) aproxima la distribución de los valores de la población subyacente.

2. El Problema de las Alternativas Clásicas

Para construir un intervalo de confianza (por ejemplo, para una proporción p), tradicionalmente se recurre a:

- **Aproximación Normal:** Basada en el Teorema del Límite Central ($Z \sim N(0,1)$). Exige que el tamaño muestral sea lo suficientemente grande.
- **Intervalo Exacto (ej. Clopper-Pearson):** Utiliza la distribución exacta del estimador (como relacionar la Binomial con la distribución Beta para hallar el parámetro p). Suele ser matemáticamente complejo y requiere conocer de antemano la familia de la distribución.

Cuando no se quiere o no se puede depender de aproximaciones asintóticas, ni se conoce la distribución exacta para derivar el intervalo analíticamente, se utiliza bootstrapping.

3. El Método: Remuestreo con Reposición

El motor del bootstrapping es el **remuestreo con reposición**.

- Dada una muestra original de tamaño N, se generan "nuevas muestras" extrayendo al azar exactamente N valores de la muestra original **con reposición**.
- En estas nuevas muestras (muestras bootstrap) habrá valores repetidos y valores omitidos. Si la muestra original representa bien a la población, la frecuencia de repetición emulará la probabilidad real de cada valor.

4. Receta del Algoritmo de Bootstrap

Para calcular el intervalo de confianza de nivel $1 - \alpha$ para un parámetro θ:

a) **Partir de la muestra:** Se tiene una muestra original $X_1, ..., X_n$.
b) **Elegir el estadístico:** Definir el estadístico θ de interés (media, proporción, varianza, etc.).
c) **Generar la distribución empírica (Bucle):**
   - a) Remuestrear con reposición n elementos de la muestra original para crear una muestra bootstrap: $X_1^*, ..., X_n^*$.
   - b) Calcular el valor del estadístico para esa muestra específica: θ^*.
   - c) Repetir los pasos (a) y (b) una gran cantidad de veces (ej. 1000 o 10000 veces).
d) **Hallar percentiles:** Sobre la distribución de todos los θ^* calculados, buscar los percentiles correspondientes a las colas para el nivel de significación deseado: $\theta_{\frac{\alpha}{2}}$ (límite inferior) y $\theta_{1-\frac{\alpha}{2}}$ (límite

---

Tabla de la Distribución Normal Estándar Acumulada $\Phi(z)$. p es el area acumulada debajo de la curva y Z_p es el punto del eje x hasta donde se acumula la curva.

Z_p	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Distribución t de Student

La tabla A.4 da distintos valores de la función de distribución en relación con el número de grados de libertad; concretamente, relaciona los valores p y $t_{n;p}$ que satisfacen: $P(t_n \leq t_{n;p}) = p$.

n	$t_{0,55}$	$t_{0,60}$	$t_{0,70}$	$t_{0,80}$	$t_{0,90}$	$t_{0,95}$	$t_{0,975}$	$t_{0,99}$	$t_{0,995}$
1	0,1584	0,3249	0,7265	1,3764	3,0777	6,3138	12,7062	31,8205	63,6567
2	0,1421	0,2887	0,6172	1,0607	1,8856	2,9200	4,3027	6,9646	9,9248
3	0,1366	0,2767	0,5844	0,9785	1,6377	2,3534	3,1824	4,5407	5,8409
4	0,1338	0,2707	0,5686	0,9410	1,5332	2,1318	2,7764	3,7469	4,6041
5	0,1322	0,2672	0,5594	0,9195	1,4759	2,0150	2,5706	3,3649	4,0321
6	0,1311	0,2648	0,5534	0,9057	1,4398	1,9432	2,4469	3,1427	3,7074
7	0,1303	0,2632	0,5491	0,8960	1,4149	1,8946	2,3646	2,9980	3,4995
8	0,1297	0,2619	0,5459	0,8889	1,3968	1,8595	2,3060	2,8965	3,3554
9	0,1293	0,2610	0,5435	0,8834	1,3830	1,8331	2,2622	2,8214	3,2498
10	0,1289	0,2602	0,5415	0,8791	1,3722	1,8125	2,2281	2,7638	3,1693
11	0,1286	0,2596	0,5399	0,8755	1,3634	1,7959	2,2010	2,7181	3,1058
12	0,1283	0,2590	0,5386	0,8726	1,3562	1,7823	2,1788	2,6810	3,0545
13	0,1281	0,2586	0,5375	0,8702	1,3502	1,7709	2,1604	2,6503	3,0123
14	0,1280	0,2582	0,5366	0,8681	1,3450	1,7613	2,1448	2,6245	2,9768
15	0,1278	0,2579	0,5357	0,8662	1,3406	1,7531	2,1314	2,6025	2,9467
16	0,1277	0,2576	0,5350	0,8647	1,3368	1,7459	2,1199	2,5835	2,9208
17	0,1276	0,2573	0,5344	0,8633	1,3334	1,7396	2,1098	2,5669	2,8982
18	0,1274	0,2571	0,5338	0,8620	1,3304	1,7341	2,1009	2,5524	2,8784
19	0,1274	0,2569	0,5333	0,8610	1,3277	1,7291	2,0930	2,5395	2,8609
20	0,1273	0,2567	0,5329	0,8600	1,3253	1,7247	2,0860	2,5280	2,8453
21	0,1272	0,2566	0,5325	0,8591	1,3232	1,7207	2,0796	2,5176	2,8314
22	0,1271	0,2564	0,5321	0,8583	1,3212	1,7171	2,0739	2,5083	2,8188
23	0,1271	0,2563	0,5317	0,8575	1,3195	1,7139	2,0687	2,4999	2,8073
24	0,1270	0,2562	0,5314	0,8569	1,3178	1,7109	2,0639	2,4922	2,7969
25	0,1269	0,2561	0,5312	0,8562	1,3163	1,7081	2,0595	2,4851	2,7874
26	0,1269	0,2560	0,5309	0,8557	1,3150	1,7056	2,0555	2,4786	2,7787
27	0,1268	0,2559	0,5306	0,8551	1,3137	1,7033	2,0518	2,4727	2,7707
28	0,1268	0,2558	0,5304	0,8546	1,3125	1,7011	2,0484	2,4671	2,7633
29	0,1268	0,2557	0,5302	0,8542	1,3114	1,6991	2,0452	2,4620	2,7564
30	0,1267	0,2556	0,5300	0,8538	1,3104	1,6973	2,0423	2,4573	2,7500
40	0,1265	0,2550	0,5286	0,8507	1,3031	1,6839	2,0211	2,4233	2,7045
50	0,1263	0,2547	0,5278	0,8489	1,2987	1,6759	2,0086	2,4033	2,6778
60	0,1262	0,2545	0,5272	0,8477	1,2958	1,6706	2,0003	2,3901	2,6603
80	0,1261	0,2542	0,5265	0,8461	1,2922	1,6641	1,9901	2,3739	2,6387
100	0,1260	0,2540	0,5261	0,8452	1,2901	1,6602	1,9840	2,3642	2,6259
120	0,1259	0,2539	0,5258	0,8446	1,2886	1,6577	1,9799	2,3578	2,6174
∞	0,126	0,253	0,524	0,842	1,282	1,645	1,960	2,327	2,576

Tabla A.4: Tabla de la distribución t de Student.

Tabla resumen de tests estadísticos

Estadística Computacional — 2C 2026

Qué se contrasta	Estadístico	Bajo H_0	Supuestos
Media, σ conocida $H_0 : \mu = \mu_0$	$\dfrac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}}$	$\mathcal{N}(0,1)$	Normalidad, o n grande por TCL
Media, σ desconocida $H_0 : \mu = \mu_0$	$\dfrac{\bar{X} - \mu_0}{\frac{S}{\sqrt{n}}}$	t_{n-1}	Normalidad; con n chico es **un supuesto real**, **no** una aproximación
Proporción $H_0 : p = p_0$	$\dfrac{\hat{p} - p_0}{\sqrt{p_0 \frac{1-p_0}{n}}}$	$\mathcal{N}(0,1)$ aprox.	$np_0 \geq 10$ y $n(1-p_0) \geq 10$; ensayos **independientes**
Varianza $H_0 : \sigma = \sigma_0$	$\dfrac{(n-1)S^2}{\sigma_0^2}$	χ^2_{n-1}	Normalidad, y acá es **crítica**: a diferencia del *t*, este **test** no es **robusto**
Dos medias, pareadas $H_0 : \mu_D = 0$	$\dfrac{\bar{D}}{\frac{S_D}{\sqrt{n}}}$	t_{n-1}	$D_i = X_i - Y_i$ sobre las mismas *unidades*; normalidad de las *diferencias*
Dos medias, independientes $H_0 : \mu_X = \mu_Y$	$\dfrac{\bar{X} - \bar{Y}}{S_P \sqrt{\frac{1}{n} + \frac{1}{m}}}$	t_{n+m-2}	Normalidad, varianzas **iguales**, y grupos **independientes entre sí**
Dos proporciones $H_0 : p_1 = p_2$	$\dfrac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$	$\mathcal{N}(0,1)$ aprox.	Al menos **10** éxitos y **10** fracasos en cada **grupo**

$$S_P^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2} \qquad \hat{p} = \frac{X_1 + X_2}{n_1 + n_2} \text{ (proporción combinada de los dos grupos)}$$